

Ludwig-Maximilians-Universität München

Department Psychologie



SOFTWAREBASIERTE BLICKRICHTUNGSERKENNUNG ZUR DIAGNOSTIK  
RÄUMLICHEN NEGLECTS: EINE EMPIRISCHE EVALUATION

**Masterarbeit**

zur Erlangung des akademischen Grades

Master of Science im Studiengang Klinische Psychologie und Psychotherapie

eingereicht von Imanuel Köthnig

(Matrikelnummer: 12446694)

Gutachterin: Dr. Karin Ludwig

Lehrstuhl für Klinische Neuropsychologie

München, den 19.02.2026

## Inhaltsverzeichnis

|                                                                               |     |
|-------------------------------------------------------------------------------|-----|
| Abstract .....                                                                | 2   |
| Einleitung .....                                                              | 3   |
| Theoretischer Hintergrund und Entwicklung .....                               | 3   |
| Bestehende Diagnostik .....                                                   | 4   |
| Alternativen zu klassischen Eyetracking-Systemen .....                        | 9   |
| Methodenvergleich: MediaPipe vs. PTGaze .....                                 | 11  |
| Kamerasysteme .....                                                           | 14  |
| Kalibrierungsstrategie .....                                                  | 15  |
| Synchronisation .....                                                         | 17  |
| Blink-Detektion .....                                                         | 18  |
| Abhängige Variablen und Forschungsfragen .....                                | 20  |
| Methode .....                                                                 | 23  |
| Versuchspersonen .....                                                        | 23  |
| Material und Versuchsablauf .....                                             | 24  |
| Datenauswertung .....                                                         | 27  |
| Ergebnisse .....                                                              | 30  |
| Deskriptive Statistiken .....                                                 | 30  |
| Inferenzstatistik .....                                                       | 32  |
| Interindividuelle Unterschiede .....                                          | 41  |
| Explorative Analyse .....                                                     | 44  |
| Diskussion .....                                                              | 46  |
| Forschungsfragen .....                                                        | 46  |
| Einordnung der Ergebnisse in den aktuellen Forschungsstand .....              | 50  |
| Praktische Implikationen .....                                                | 52  |
| Stärken .....                                                                 | 55  |
| Limitationen .....                                                            | 56  |
| Implikationen für zukünftige Forschung .....                                  | 59  |
| Fazit .....                                                                   | 61  |
| Literaturverzeichnis .....                                                    | 63  |
| Appendix A: Eigenständigkeitserklärung und Erklärung zur Nutzung von KI ..... | 69  |
| Appendix B: Zusätzliche Ergebnisse .....                                      | 71  |
| Appendix C: Pipelineübersicht .....                                           | 80  |
| Appendix D: Versionsübersicht Experimentalsoftware .....                      | 100 |
| Appendix E: Transkript Instruktionen .....                                    | 101 |

## Abstract

Die Freie Visuelle Exploration (FVE) stellt ein sensitives Verfahren zur Neglect-Diagnostik dar, dessen klinische Verbreitung bislang jedoch durch die Notwendigkeit spezialisierter Eyetracking-Hardware limitiert ist. Die vorliegende Pilotstudie untersuchte erstmals, ob Computer-Vision-basierte (CV) Blickerfassungsmethoden eine praktikable Alternative darstellen können. Hierzu wurden zwei CV-Methoden – ein feature-based Verfahren mittels MediaPipe und das appearance-based Deep-Learning-Verfahren PTGaze –, zwei Kamerasysteme (Webcam mit 60 Hz, Systemkamera mit 25 Hz) und zwei Kalibrierungsstrategien (vollständig, reduziert) in einem 2×2×2-Design systematisch verglichen und ihre Übereinstimmung mit einem EyeLink 1000 als Referenzstandard evaluiert. Zwölf gesunde ältere Erwachsene ( $M = 66$  Jahre,  $SD = 7.36$ ; 8 weiblich) absolvierten das FVE-Paradigma. Die Ergebnisse zeigen, dass die Übereinstimmung stark von der Bedingungskombination abhängt: Die beste Konfiguration (PTGaze, Systemkamera, vollständige Kalibrierung) erreichte eine Korrelation von  $r = .91$  mit dem Referenzsystem. Die Systemkamera übertraf die Webcam deutlich in Korrelation und Steigung (große Effektstärke) – Bildqualität erwies sich als wichtiger als zeitliche Auflösung. PTGaze übertraf MediaPipe konsistent in der Steigung (mittlere Effektstärke), während die Kalibrierungskomplexität nur marginale Effekte zeigte. Die Befunde legen nahe, dass CV-basierte Blickerfassung unter günstigen Bedingungen eine vielversprechende Übereinstimmung mit etablierten Eyetracking-Systemen erreichen kann. Für eine klinische Anwendung sind jedoch weitere Validierungsschritte an Patientenstichproben erforderlich.

## **Einleitung**

Jeder vierte Mensch über 25 Jahren wird im Laufe seines Lebens einen Schlaganfall erleiden (Feigin et al., 2022, 2025). Diese Zahl verdeutlicht die enorme gesellschaftliche Relevanz einer Erkrankung, deren Inzidenz nach Jahren des Rückgangs seit 2015 stagniert, während das individuelle Risiko mit dem Alter deutlich ansteigt: Von etwa 2 % in der Altersgruppe 60–64 Jahre erhöht sich die 10-Jahres-Prävalenz auf über 9 % bei Personen ab 90 Jahren (Anton et al., 2025). Weltweit leben 95 Millionen Menschen mit den Folgen eines Schlaganfalls (Feigin et al., 2025).

Wenn von diesen Folgen die Rede ist, dominieren in der öffentlichen Wahrnehmung meist motorische und sprachliche Beeinträchtigungen wie Lähmung oder Sprachstörung. Der räumliche Neglect – die häufigste kognitive Störung nach rechtshemisphärischer Schädigung – findet hingegen deutlich weniger Beachtung (Karnath et al., 2023). Dabei ist seine Prävalenz beträchtlich: Je nach Studie zeigen zwischen 25 % und 80 % der Schlaganfallüberlebenden einen räumlichen Neglect (Bosma et al., 2023; Williams et al., 2021), in der akuten Phase ist etwa jeder dritte Überlebende betroffen (Esposito et al., 2021). Um die klinische Bedeutung dieser Zahlen zu verstehen und die Anforderungen an eine adäquate Diagnostik abzuleiten, ist zunächst ein genauerer Blick auf das Störungsbild erforderlich.

## **Theoretischer Hintergrund und Entwicklung**

Definiert wird Neglect als eine häufig durch rechtshemisphärische Schädigung hervorgerufene, kontraläsionale Vernachlässigung verschiedener Reize (z. B. visuell, taktil, auditiv, motorisch) sowie oft fehlende spontane Bewegungen zur oder in Richtung der kontraläsionalen Seite, wobei die Symptome nicht durch ein sensomotorisches Defizit erklärt werden können (Bonato, 2012; Karnath & Thier, 2012; Kaufmann et al., 2020; Williams et al., 2021). Die Heterogenität des Störungsbildes spiegelt sich in einer Vielzahl taxonomischer Begrifflichkeiten wider. Zur Systematisierung lassen sich Neglect und seine Subtypen anhand von drei Dimensionen gruppieren: dem Bezugsrahmen (egozentrisch oder allozentrisch), der Verarbeitungsebene (perzeptive Subtypen wie visuell, taktil oder auditiv sowie repräsentationale und motorische Anteile) und dem räumlichen Umfeld (personal, peripersonal oder extrapersonal) (Pitteri et al., 2018; Williams et al., 2021). Da Neglect in verschiedenen Kombinationen dieser Dimensionen auftreten kann, ergibt sich ein komplexes klinisches Bild. Neuroanatomisch lassen sich die ursächlichen Läsionen meist im oberen und

mittleren Temporallappen, im inferioren parietalen Kortex oder im inferioren frontalen Kortex lokalisieren (Karnath et al., 2023; Karnath & Rorden, 2012).

Abhängig von Schweregrad und Stadium hat Neglect weitreichende Folgen – nicht nur für die Betroffenen selbst, sondern auch für deren Angehörige (Bosma et al., 2020; Esposito et al., 2021). Die Defizite manifestieren sich in nahezu allen Lebensbereichen: Alltägliche Handlungen wie Zähneputzen oder Anziehen werden zur Herausforderung (Chen et al., 2012), die Mobilität ist eingeschränkt – etwa bei der Wegfindung oder beim Überqueren von Straßen (Aravind & Lamontagne, 2014; Tromp et al., 1995)–, das Gleichgewicht leidet (Nijboer et al., 2014), und auch das Lesen kann betroffen sein (Galletta et al., 2014). Insgesamt beeinträchtigt Neglect die Teilhabe am gesellschaftlichen Leben erheblich (Bosma et al., 2020). Auch im klinischen Kontext zeigen sich negative Assoziationen: Neglect geht mit schlechteren kognitiven Outcomes, längerer Rehabilitationsdauer und verzögerter Entlassung einher (Bosma et al., 2023).

Ein zusätzliches Hindernis stellt die häufig fehlende Krankheitseinsicht dar: Viele Betroffene sind sich ihrer Symptome und der daraus resultierenden Einschränkungen nicht bewusst (Esposito et al., 2021). Eine mögliche Erklärung liegt darin, dass die Symptome für Betroffene und Angehörige weniger offensichtlich sind als etwa bei einer Aphasie (Karnath et al., 2023). Dieses mangelnde Störungsbewusstsein verzögert häufig die diagnostische Abklärung und Behandlung (Esposito et al., 2021). Auch im klinischen Kontext ist Neglect vermutlich unterdiagnostiziert und wird entsprechend seltener adäquat behandelt (Chen et al., 2012). Die bereits beschriebene Multimodalität und Heterogenität des Störungsbildes erschweren die Diagnostik zusätzlich.

In Kombination mit den beschriebenen Einschränkungen unterstreicht das die Notwendigkeit einer frühzeitigen, gründlichen und zielgerichteten Diagnostik mit einheitlich sensitiven, reliablen und evidenzbasierten Verfahren (Karnath et al., 2023; Williams et al., 2021, 2025). Ein Blick auf die derzeit verfügbaren Verfahren zeigt jedoch, dass diese Anforderungen nur teilweise erfüllt werden.

### **Bestehende Diagnostik**

Klinischer Standard sind nach wie vor neuropsychologische Paper-Pencil-Tests wie der Random Shape Cancellation Test (Weintraub & Mesulam, 1988), der Line Bisection Test (Wilson et al., 1987) oder der Two-Part Picture Test (Brunila et al., 2003). Allen drei

Verfahren haben gemeinsam, dass Patienten ein bestimmtes Merkmal visuell detektieren oder einschätzen und ihre Antwort motorisch auf dem Papier kennzeichnen müssen.

Beim Random Shape Cancellation Test suchen und markieren Patienten geometrische Zielsymbole, die unstrukturiert zwischen Distraktoren verteilt sind. Die fehlende Zeilenstruktur stellt hohe Anforderungen an die selbstgenerierte visuelle Explorationsstrategie, wodurch räumliche Aufmerksamkeitsdefizite deutlicher hervortreten. Der Line Bisection Test fordert Patienten auf, die subjektive Mitte horizontaler Linien zu markieren – Patienten mit visuellem Neglect verschieben den Mittelpunkt typischerweise zur ipsiläsionalen Seite. Beim Two-Part Picture Test identifizieren Patienten Objekte in einer komplexen Strichzeichnung mit zwei symmetrischen, durch eine Lücke getrennten Raumszenen. Da die rechte Bildhälfte bereits isoliert interpretierbar ist, fehlt ein impliziter Hinweis, die Aufmerksamkeit auf die linke Seite auszuweiten.

Die Vorteile dieser Verfahren liegen in ihrer einfachen, kostengünstigen und effizienten Anwendbarkeit, wobei insbesondere für den Line Bisection Test und bestimmte Cancellation-Aufgaben Nachweise für hohe Validität vorliegen (Williams et al., 2025). Allerdings sind diese Tests strukturiert und erfordern top-down orientierte Aufmerksamkeit: Patienten werden z. B. explizit aufgefordert, Ziele zu suchen, oder die Tests weisen eine klare räumliche Begrenzung auf. Dadurch können Betroffene kognitive Strategien nutzen, um ihre Wahrnehmungsdefizite kurzzeitig zu kompensieren (Bonato, 2012; Kaufmann et al., 2020). Diese Kompensationsfähigkeit reduziert die Sensitivität der Verfahren: Sie identifizieren zuverlässig mittlere bis schwere Neglect-Formen, übersehen jedoch häufig subtilere Beeinträchtigungen, die für Patienten im Alltag dennoch relevant sind (Bonato, 2012; Williams et al., 2025). Zudem erlauben Paper-Pencil-Verfahren keine Differenzierung zwischen visuellen und motorischen Neglect-Komponenten, da die visuelle Suche untrennbar mit einer motorischen Antwort gekoppelt ist. Eine Subtypendifferenzierung ist also nur über die Kombination mehrerer Testverfahren z. B. in Form von Testbatterien möglich (Williams et al., 2025).

**Die Catherine Bergego Scale (CBS)** (Bergego et al., 1995) bietet ein valides Verfahren zur Erfassung und quantitativen Bewertung von Neglect-Symptomen im direkten Alltagshandeln des Patienten (Azouvi et al., 2003). Geschultes Personal beobachtet zehn funktionelle Aktivitäten wie Essen, Ankleiden, Körperpflege oder die Fortbewegung und bewertet die Leistung auf einer Skala von 0 (kein Neglect) bis 3 (schwerer Neglect) woraus sich ein

Gesamtwert zwischen 0 und 30 Punkten ergibt. Parallel kann eine Selbsteinschätzung des Patienten zur Erfassung von Anosognosie erfolgen.

Der Vorteil der CBS liegt in ihrer höheren Sensitivität und ökologischen Validität gegenüber konventionellen Verfahren. Azouvi et al. (2003) konnten zeigen, dass die CBS Neglect-Symptome signifikant zuverlässiger detektiert als klassische Paper-Pencil-Tests; so konnten in Untersuchungen über 96 % der betroffenen Patienten mittels CBS identifiziert werden, während Testbatterien aus Zeichen- und Durchstreichaufgaben lediglich rund 65 % der Fälle erfassten. Dieser diagnostische Vorteil begründet sich wahrscheinlich darin, dass die CBS Defizite in der automatischen, stimulus-getriebenen (bottom-up) Aufmerksamkeit aufdeckt, die im komplexen Alltag gefordert ist, während Patienten in strukturierten Testsituationen ihre Defizite oft kurzzeitig durch bewusste Strategien kompensieren können (Azouvi, 2017; Kaufmann et al., 2020). Zudem ist die CBS eines der wenigen Instrumente, das nicht nur den peripersonalen (greifnahen) Raum prüft, sondern auch den personalen (körperbezogenen) und extrapersonalen Raum sowie motorische Aspekte integriert (Azouvi et al., 2003; Williams et al., 2025).

Diesen diagnostischen Stärken stehen jedoch Limitationen in der klinischen Praktikabilität und diagnostischen Differenzierung gegenüber. Die Durchführung der CBS ist zeitintensiv (ca. 30 bis 40 Minuten pro Erfassung; Williams et al., 2025) und erfordert geschultes Personal sowie wiederholte Beobachtungen in verschiedenen Alltagssituationen, weshalb das Verfahren in zeitsensitiven Settings wie Stroke Units oft nicht angewendet werden kann (Kaufmann et al., 2020; Williams et al., 2025). Aus psychometrischer Sicht wird zudem bemängelt, dass die Qualität der Evidenz für die Reliabilität (insbesondere Test-Retest-Reliabilität) aufgrund methodischer Schwächen in verfügbaren Studien oft als niedrig eingestuft wird (Williams et al., 2025). Ein weiteres differenzialdiagnostisches Problem ist die mangelnde Trennschärfe hinsichtlich der Neglect-Modalitäten: Das Scoring-System erlaubt keine isolierte Betrachtung visueller, taktiler, auditiver oder motorischer Neglect-Komponenten, da diese in den beobachteten Alltagshandlungen meist eng miteinander verwoben sind (Williams et al., 2025).

Zusammenfassend steht die klinische Diagnostik vor einem Dilemma: Die gängigen Paper-Pencil-Verfahren sind zwar schnell und einfach durchzuführen, übersehen jedoch häufig leichtere Formen des Neglects (Williams et al., 2021, 2025). Die CBS hingegen ist sensitiver und alltagsnäher, lässt sich aber aufgrund des hohen Zeitaufwands schlechter in Klinikalltag

und besonders in die Akutdiagnostik integrieren (Kaufmann et al., 2020; Williams et al., 2025). Es fehlt folglich ein Verfahren, das beides verbindet: Die hohe Sensitivität und Alltagsnähe der CBS sowie die schnelle, standardisierte Durchführbarkeit der Paper-Pencil-Tests.

**Diagnostik mit FVE.** Einen vielversprechenden Lösungsansatz für das beschriebene Dilemma bietet die Video-Okulographie in Kombination mit dem Paradigma der Freien Visuellen Exploration (FVE). Im Gegensatz zu den strukturierten Paper-Pencil-Tests basiert die FVE auf einer automatischen, stimulus-getriebenen (bottom-up) Aufmerksamkeitsorientierung – einem Mechanismus, der auch den Alltagssituationen zugrunde liegt, die mit der CBS erfasst werden (Kaufmann et al., 2020; Paladini et al., 2019). Das Verfahren nutzt die natürliche Tendenz des visuellen Systems, bei der Betrachtung komplexer Szenen bestimmte Regionen bevorzugt zu fixieren. Paladini et al. (2019) zeigen, dass die Salienz – also die visuelle Auffälligkeit bestimmter Bildregionen – das Blickverhalten bei freier Exploration maßgeblich beeinflusst. Bei Neglect-Patienten ist dieser Mechanismus gestört: Sie fixieren bevorzugt Regionen im ipsiläsionalen Raum und vernachlässigen kontraläsionale Bildbereiche selbst dann, wenn diese hohe Salienz aufweisen. Dieses Muster spiegelt die im Alltag auftretenden Aufmerksamkeitsdefizite wider und erklärt die hohe ökologische Validität des Verfahrens.

Der Ablauf ist für Patienten einfach und intuitiv: Sie betrachten auf einem Bildschirm nacheinander verschiedene naturalistische Fotografien, die alltägliche Szenen wie Landschaften oder öffentliche Plätze zeigen. Anders als bei klassischen Suchtests gibt es dabei keine explizite Aufgabe. Die Patienten lassen den Blick frei über die Bilder schweifen, während ein Eyetracker die Augenbewegungen aufzeichnet. Aus diesen Daten wird die mittlere horizontale Blickposition berechnet: Liegt dieser Wert signifikant von der Bildmitte verschoben, deutet dies auf einen Neglect hin.

Kaufmann et al. (2020) validierten dieses Verfahren an einer Stichprobe von Schlaganfallpatienten. Im experimentellen Ablauf betrachteten die Teilnehmer 24 Bilder (12 Originale und 12 horizontal gespiegelte Versionen) in randomisierter Reihenfolge, wobei jedes Bild für sieben Sekunden präsentiert wurde. Zwischen den Bildern erschien ein zentrales Fixationskreuz, das die Blickposition vor jedem neuen Stimulus standardisierte. Als diagnostischer Cut-off erwies sich eine mittlere horizontale Blickposition von  $1,333^\circ$  Sehwinkel als

sinnvoll: Patienten, deren Blickschwerpunkt diesen Wert überschritt, wurden als Neglect-positiv klassifiziert.

Die Ergebnisse bestätigen das diagnostische Potenzial der Methode: Die FVE identifizierte 85 % der Neglect-Patienten korrekt – eine Sensitivität, die einzelne Paper-Pencil-Tests (21–52 %) deutlich übertrifft. Zudem korrelierte die mittlere Blickposition signifikant mit neun der zehn CBS-Subskalen, was darauf hindeutet, dass das Verfahren dieselben alltagsrelevanten Defizite erfasst wie die verhaltensbasierte Beobachtung. Dieser Zusammenhang stützt die theoretische Annahme, dass die FVE – wie die CBS – primär Defizite in der bottom-up gesteuerten Aufmerksamkeitsorientierung aufdeckt (Bonato, 2012; Kaufmann et al., 2020). Ein weiterer diagnostischer Vorteil betrifft die Differenzierung der Neglect-Modalitäten. Da die Video-Okulographie keine motorische Antwort erfordert – Patienten müssen weder Symbole markieren noch Linien zeichnen –, erfasst sie primär visuelle Aufmerksamkeitsdefizite, ohne dass diese durch motorische Komponenten konfundiert werden. Diese Eigenschaft ermöglicht eine Abgrenzung zwischen visuellem und motorischem Neglect, die mit Paper-Pencil-Verfahren nicht möglich ist (Kaufmann et al., 2020; Williams et al., 2025). Auch hinsichtlich der praktischen Durchführbarkeit bietet die FVE Vorteile: Der gesamte Test dauert etwa zehn Minuten und ist für Patienten deutlich weniger belastend als längere Testbatterien oder wiederholte Alltagsbeobachtungen. Die standardisierte Durchführung reduziert zudem den Einfluss von Untersuchungseffekten und ermöglicht eine objektive, quantitative Auswertung.

Die zentrale Limitation des Verfahrens liegt in der technischen Voraussetzung: Die FVE erfordert einen Eyetracker, der in vielen Kliniken nicht zur Standardausstattung gehört. Stationäre Systeme wie der EyeLink 1000 sind kostspielig, erfordern geschultes Personal für Kalibrierung und Wartung, und stellen auch für Patienten gewisse Anforderungen – etwa längeres bewegungsarmes Sitzen mit fixiertem Kopf (Ehinger et al., 2019; Vos et al., 2022). Diese Hürden sind möglicherweise ein Grund dafür, dass das Verfahren trotz seiner vielversprechenden psychometrischen Eigenschaften bislang keinen breiten Eingang in die klinische Praxis gefunden hat.

Zusammenfassend existiert mit der FVE ein sensibles, valides und retest-reliables Verfahren, das einen vielversprechenden Ansatz zur Neglect-Diagnostik darstellt. Die entscheidende Frage für die klinische Translation lautet daher: Lassen sich die technischen Hürden reduzieren, ohne die diagnostische Validität zu gefährden?

## Alternativen zu klassischen Eyetracking-Systemen

Als Referenzstandard in der Blickbewegungsforschung gelten infrarotbasierte Eyetracker, wobei stationäre Systeme wie der EyeLink 1000 – das in der vorliegenden Studie verwendete Referenzgerät – die höchste zeitliche Auflösung (bis zu 2000 Hz) und räumliche Genauigkeit (unter 0,5° Sehwinkel) erreichen (Ehinger et al., 2019; Vos et al., 2022). Neben stationären Systemen existieren auch mobile infrarotbasierte Eyetracker wie die Pupil Labs Glasses, die Messungen in freier Bewegung ermöglichen und damit eine höhere ökologische Validität bieten (Ehinger et al., 2019). Allerdings zeigen direkte Vergleichsstudien, dass diese mobilen Systeme eine geringere räumliche Genauigkeit aufweisen und anfälliger für Calibration Decay sind – den Genauigkeitsverlust über die Zeit durch leichte Verschiebungen der Brille bei Kopfbewegungen (Ehinger et al., 2019; Vos et al., 2022). Das Hauptproblem sowohl stationärer als auch mobiler Infrarot-Systeme bleibt jedoch die Notwendigkeit spezialisierter Hardware, die in vielen klinischen Settings nicht verfügbar ist.

Parallel zur Entwicklung mobiler Alternativen hat sich durch Fortschritte im Bereich Computer Vision (CV) und Deep Learning (DL) der Fokus der Forschung zunehmend auf hardwareunabhängige Lösungen verlagert, die ohne Infrarot-Beleuchtung auskommen (Cheng et al., 2024; Pathirana et al., 2022). Dieser Ansatz, oft als Webcam-Eyetracking bezeichnet, nutzt handelsübliche Farbkameras (RGB-Kameras), wie sie standardmäßig in Laptops, Tablets oder Smartphones verbaut sind (Heck et al., 2023). Der dadurch stark reduzierte Hardwarebedarf ermöglicht theoretisch den Einsatz von Eye-Tracking auf einer Vielzahl von Plattformen und könnte die Diagnostik direkt an das Krankenbett bringen (Kaduk et al., 2024). Die zentrale Herausforderung besteht darin, mit der vergleichsweise geringen Bildqualität und Frequenz von Standardkameras eine diagnostisch verwertbare Datenqualität zu erzielen.

**Potenzial von Computer Vision.** Erste Versuche, Webcam-basiertes Eye-Tracking breit zugänglich zu machen, basieren häufig auf echtzeitfähigen, browserbasierten Bibliotheken wie WebGazer (Papoutsaki et al., 2016). Diese Tools weisen jedoch technische Limitationen auf, die ihren Nutzen für die differenzierte Neglect-Diagnostik einschränken: Solche Echtzeit-Anwendungen leiden oft unter instabilen Algorithmen, da sie stark von der momentanen Rechenleistung des Endgeräts und der Prozesspriorisierung des Browsers abhängen (Heck et al., 2023; Vos et al., 2022). Zudem erreichen diese Verfahren häufig nur eine geringe räumliche Genauigkeit. Ein weiterer Aspekt betrifft den Datenschutz: Browserbasierte Lösungen

erfordern häufig eine serverseitige Datenverarbeitung, was bei sensiblen Patientendaten besondere Anforderungen stellt (vgl. Steffan et al., 2024).

Um diese Limitationen zu überwinden, bietet der Einsatz moderner CV-Methoden in Kombination mit DL entscheidende Vorteile. Im Gegensatz zu einfachen Regressionsmodellen können moderne DL-Modelle komplexe, nicht-lineare Zusammenhänge zwischen dem Erscheinungsbild des Auges und der Blickrichtung lernen (Cheng et al., 2024; Pathirana et al., 2022). Dies führt zu einer signifikant erhöhten Robustheit gegenüber Störfaktoren wie Kopfbewegungen, unterschiedlichen Beleuchtungsverhältnissen oder individuellen Gesichtsmarkmalen, die in weniger kontrollierten klinischen Settings unvermeidbar sind (Cheng et al., 2024; Saxena et al., 2024).

Ein weiterer zentraler Vorteil ist die Entkopplung von Datenerhebung und Datenverarbeitung (Offline-Inferenz). Während browserbasierte Lösungen die Blickdaten in Echtzeit berechnen müssen und dabei Kompromisse bei der Modellkomplexität eingehen, ermöglicht die Aufzeichnung von Rohvideos und deren nachträgliche Analyse durch leistungsstarke DL-Algorithmen eine signifikant höhere Datenqualität (Saxena et al., 2024). Saxena et al. (2024) konnten zeigen, dass spezialisierte CV-Modelle in einem solchen Setup eine räumliche Genauigkeit von bis zu  $2,4^\circ$  Sehwinkel und eine Präzision von  $0,47^\circ$  Sehwinkel erreichen – Werte, die die Lücke zu laborbasierten Eyetrackern deutlich verkleinern. Kaduk et al. (2024) demonstrierten zudem, dass die für die FVE besonders relevante horizontale Blickachse mit CV-Modellen gut erfassbar ist ( $r = .86$ ,  $p < .01$ ). Somit stellt die Nutzung dedizierter CV-Pipelines einen vielversprechenden Weg dar, die Hürde spezialisierter Hardware zu umgehen.

**Computer Vision-Methoden.** Die Literatur zu CV-Ansätzen klassifiziert Gaze-Estimation-Systeme primär anhand der Art der Informationsverarbeitung. Grundsätzlich lassen sich zwei Kategorien unterscheiden: feature-based (modellbasierte) Methoden und appearance-based (erscheinungsbasierte) Methoden (Cheng et al., 2024; Pathirana et al., 2022).

**Feature-based Methoden** detektieren zunächst spezifische geometrische Merkmale im Bild – etwa das Pupillenzentrum, die Iris-Konturen, Augenwinkel oder Hornhautreflexionen. Aus diesen Merkmalen berechnen sie mittels eines mathematischen 3D-Augenmodells die Blickrichtung. Der Vorteil dieses Ansatzes liegt in seiner Ressourceneffizienz: Da die Verarbeitung auf eine optimierte Merkmalsextraktion beschränkt bleibt und keine rechenintensiven neuronalen Netzwerke für die finale Blickschätzung benötigt werden, können

solche Methoden auch auf Standard-Hardware ohne dedizierte Grafikkarte flüssig operieren (Cheng et al., 2024; Heck et al., 2023). Allerdings sind feature-based Ansätze traditionell anfälliger für Störvariablen wie schlechte Beleuchtung oder teilweise Verdeckungen des Gesichts, da sie auf die präzise Detektion der geometrischen Punkte angewiesen sind (Cheng et al., 2024; Pathirana et al., 2022; Rathnayake et al., 2023).

**Appearance-based Methoden mit Deep Learning** verfolgen einen grundlegend anderen Ansatz: Sie verzichten auf die explizite Extraktion geometrischer Merkmale und verwenden stattdessen das gesamte Augen- oder Gesichtsbild als Eingabe für ein tiefes neuronales Netzwerk. Das Netzwerk lernt, direkt aus den Pixeldaten die Blickrichtung vorherzusagen – ein Prozess, der als End-to-End-Lernen bezeichnet wird (Pathirana et al., 2022). Konkret bedeutet dies: Während des Trainings werden dem Netzwerk große Mengen an Augen- oder Gesichtsbildern zusammen mit den zugehörigen Ground-Truth-Blickrichtungen präsentiert. Diese Referenzdaten (Ground Truth) stammen typischerweise aus kontrollierten Laboraufnahmen, bei denen Versuchspersonen (VP) bekannte Punkte auf einem Bildschirm fixieren. Das Netzwerk lernt dabei selbstständig, welche Bildmerkmale für die Blickschätzung relevant sind – etwa subtile Veränderungen in der Irisposition oder der Lidöffnung –, ohne dass diese Merkmale manuell definiert werden müssen (Cheng et al., 2024; Pathirana et al., 2022).

### **Methodenvergleich: MediaPipe vs. PTGaze**

Um zu evaluieren, welcher technologische Ansatz das beste Verhältnis aus Genauigkeit und klinischer Praktikabilität bietet, implementiert und vergleicht die vorliegende Arbeit zwei CV-Verfahren als unabhängige Variable (UV1): einen feature-based Ansatz (MediaPipe) und einen appearance-based Ansatz (PTGaze).

**MediaPipe Face Mesh.** Der erste Ansatz nutzt das MediaPipe Face Mesh Framework (Lugaresi et al., 2019), das sich taxonomisch in die Kategorie der feature-based bzw. hybriden modellbasierten Ansätze einordnen lässt. Das Verfahren detektiert zunächst 478 spezifische Landmarken im Gesicht, darunter fünf Punkte pro Iris sowie die Augenwinkel. Aus diesen geometrischen Merkmalen berechnet ein nachgeschaltetes Regressionsmodell die Blickrichtung. Die Wahl dieses Verfahrens begründet sich wie bei anderen feature-based Ansätzen primär in seiner hohen Ressourceneffizienz (Cheng et al., 2024; Heck et al., 2023). Dies adressiert direkt die Anforderung an eine breite klinische Verfügbarkeit.


**PTGaze (ETH-XGaze).** Als Vergleichsmethode dient PTGaze (Liu, 2024; Wang et al., 2025), das auf dem ETH-XGaze-Modell basiert (Zhang et al., 2020). Dieser Ansatz repräsentiert die Kategorie der appearance-based Methoden mit Deep Learning: Im Gegensatz zu MediaPipe wird hier wie oben beschrieben das gesamte Augen- bzw. Gesichtsbild zur Vorhersage der Blickrichtung verwendet, ohne dass geometrische Merkmale explizit extrahiert werden müssen. Da das zugrundeliegende ETH-XGaze-Modell auf umfangreichen Datensätzen mit extremen Kopfposen und variierenden Beleuchtungsbedingungen trainiert wurde, bietet es eine hohe Generalisierungsfähigkeit in unkontrollierten Umgebungen (Cheng et al., 2024; Zhang et al., 2020). Die Wahl von PTGaze dient somit als Benchmark, um zu prüfen, ob die rechenintensivere Analyse des gesamten Gesichtsbildes für die notwendige Präzision der Neglect-Diagnostik erforderlich ist, oder ob ressourcenschonende Verfahren ausreichen. In der Klasse der appearance-based Methoden existieren zwar noch leistungsfähigere Systeme wie FAZE (Park et al., 2019). Diese waren jedoch innerhalb des zeitlichen Rahmens dieser Arbeit aufgrund ihrer höheren Implementierungskomplexität nicht ohne Weiteres integrierbar.

**Pipeline-Integration.** Um einen validen Vergleich zu gewährleisten, wurden beide Methoden in eine modulare Python-Pipeline integriert (für eine detaillierte technische Beschreibung siehe Appendix C). Die Pipeline verarbeitet die Videodaten parallel, sodass für jeden Frame sowohl eine Prädiktion durch MediaPipe als auch durch PTGaze generiert wird. Da der EyeLink 1000 mit einer deutlich höheren Frequenz (1000 Hz) aufzeichnet als die verwendeten Kameras (25–60 Hz), müssen die Datenströme synchronisiert werden. Hierzu wird ein Nearest-Neighbor-Downsampling angewendet: Für jeden Frame der CV-Pipeline wird derjenige EyeLink-Messpunkt ausgewählt, dessen Zeitstempel dem Frame-Zeitstempel am nächsten liegt. Auf diese Weise entstehen zeitlich korrespondierende Datenpaare, die einen direkten Vergleich zwischen CV-Schätzung und Referenzmessung ermöglichen (für einen Ablaufüberblick siehe Abbildung 1).

Neben den CV-Methoden beeinflussen weitere Rahmenbedingungen die Qualität der Blickerkennung. Um ihre Bedeutung zu quantifizieren und relevante Wirkmechanismen zu identifizieren, berücksichtigt das experimentelle Design dieser Pilotstudie zusätzlich Variationen im Kamerasystem (UV2) sowie der Kalibrierungsstrategie (UV3).

## Abbildung 1

*Ablauf der entwickelten CV-Pipeline anhand der wichtigsten Pythonskripte*



## Kamerasysteme

Die Wahl des Kamerasystems stellt einen potenziell kritischen Faktor für die Qualität CV-basierter Blickerfassung dar. Unterschiedliche Kameramodelle und -auflösungen können die Ergebnisse CV-basierter Eyetracking-Systeme erheblich beeinflussen (Cheng et al., 2024; Heck et al., 2023). Um diese Variabilität systematisch zu untersuchen, erfolgte die Datenerhebung parallel mit zwei Kamerasystemen, die unterschiedliche Qualitätsstufen und Schwerpunkte repräsentieren. Zur Minimierung von Störeinflüssen durch variierende Lichtverhältnisse und Sitzpositionen gewährleistete das experimentelle Setup eine konstante Raumbeleuchtung sowie einen über eine Kopfstütze gleichbleibenden Abstand zum Bildschirm (68 bzw. 70 cm, abhängig von der Softwareversion; siehe Appendix D) (Ehinger et al., 2019).

**Kamerasystem 1 (Webcam, 60 Hz).** Das erste System besteht aus einer handelsüblichen Webcam mit einer nominellen Bildwiederholrate von 60 Hz und einer Auflösung von  $1920 \times 1080$  Pixeln. In der praktischen Anwendung unterliegt die Framerate von Webcams jedoch oft automatischen Anpassungen durch Belichtung und CPU-Last (Heck et al., 2023), was in dieser Studie zu einer realen, variierenden Frequenz im Bereich von 40 bis 50 Hz führte. Der Schwerpunkt bei diesem System liegt auf einer hohen zeitlichen Auflösung. Diese könnte zu einer präziseren Blickerfassung beitragen, da mehr Datenpunkte pro Zeiteinheit erfasst werden.

**Kamerasystem 2 (Systemkamera, 25 Hz).** Als Referenz für hochwertiges Videomaterial diente eine Sony Alpha 6000 Systemkamera (25 Hz,  $1440 \times 1080$  Pixel). Obwohl die zeitliche Auflösung mit 25 Hz deutlich unter der nominellen Webcam-Frequenz liegt, bietet die Systemkamera eine höhere Bildqualität hinsichtlich Schärfe, Dynamikumfang und Rauschverhalten. Diese Eigenschaft ist besonders relevant für appearance-based Methoden wie PTGaze: Da solche Deep-Learning-Modelle direkt auf den Pixeldaten operieren, sollten sie von höherer Bildqualität stärker profitieren als feature-based Ansätze, die lediglich diskrete Landmarken detektieren (Cheng et al., 2024). Der systematische Vergleich beider Kamerasysteme als unabhängige Variable (UV2) erlaubt Rückschlüsse darauf, ob eine höhere Bildqualität eine niedrigere zeitliche Auflösung kompensieren kann und wie robust die CV-Methoden gegenüber der variablen Abtastrate der Webcam sind.

## **Kalibrierungsstrategie**

Während stationäre Eyetracking-Systeme wie der EyeLink 1000 über integrierte Kalibrierungsroutinen verfügen, die hardwareseitig optimiert sind und vom Hersteller bereitgestellt werden, erfordert CV-basierte Blickerfassung die Entwicklung einer eigenen Kalibrierungsstrategie. Diese stellt eine kritische Komponente dar, um individuelle anatomische Gegebenheiten und Positionsschwankungen auszugleichen (Heck et al., 2023; Saxena et al., 2022).

**Grundprinzip der Videokalibrierung.** Die Kalibrierung ist erforderlich, um die Modellvorhersagen der CV-Pipelines – rohe Pupillenpositionen (MediaPipe) bzw. Blickwinkel (PTGaze) – auf 2D-Blickpunkte auf dem Bildschirm zu projizieren. Diese Transformation basiert auf setup-spezifischen Parametern wie dem VP-Bildschirm-Abstand, den intrinsischen Kameraparametern und der Monitor-Kamera-Beziehung (Saxena et al., 2022). Für die Kalibrierung fixieren VP eine Reihe von Punkten auf dem Display, deren Positionen bekannt sind. Aus der Abweichung zwischen den CV-Schätzungen und den tatsächlichen Bildschirmpositionen wird ein Kalibrierungsmodell trainiert, das anschließend auf alle Blickschätzungen angewendet wird (Heck et al., 2023). Je mehr Kalibrierungspunkte gesammelt werden, desto präziser kann das Modell individuelle Verzerrungen korrigieren. Für CV-basierte Studien empfehlen Saxena et al. (2022) eine wiederholte Kalibrierung zu mehreren Zeitpunkten, um dem Calibration Decay entgegenzuwirken. Dabei ist nicht die zeitliche Nähe zwischen Kalibrierung und Datenerhebung entscheidend, sondern die erhöhte Gesamtdatenmenge: Das Hinzufügen einer mittleren Kalibrierungsphase zu einer initialen Kalibrierung verbessert die Genauigkeit ebenso signifikant wie das zusätzliche Hinzufügen einer Endkalibrierung.

**Neglectspezifische Anpassungen.** Standardkalibrierungen präsentieren typischerweise eine Sequenz von Fixationspunkten, die entweder in zufälliger Reihenfolge oder nach einem festen Raster erscheinen und zwischen den Positionen springen. Für Personen mit Neglect kann dieses Vorgehen problematisch sein: Das plötzliche Erscheinen von Punkten in der kontraläsionalen Raumhälfte wird möglicherweise nicht wahrgenommen, und häufige Blicksprünge über die gesamte Bildschirmfläche sind kognitiv belastend.

Für die vorliegende Studie wurde daher eine angepasste Kalibrierungsstrategie entwickelt, die exemplarisch mit einer Neglect-Patientin (siehe Methoden) erprobt wurde. Die Modifikationen umfassen vier zentrale Aspekte: (1) Der Kalibrierungspunkt bleibt dauerhaft

sichtbar und springt nicht zwischen den Positionen, sondern wandert kontinuierlich über den Bildschirm. (2) Die Bewegungsgeschwindigkeit ist reduziert, um das Verfolgen zu erleichtern. (3) Das Bewegungsmuster folgt einem zusammenhängenden Pfad, der keine Sprünge erfordert. (4) An jedem Kalibrierungspunkt verweilt das Fixationskreuz für eine erhöhte Dauer von 4–5 Sekunden.

**Konkrete Implementierung.** Basierend auf diesen Überlegungen wurde eine 9-Punkte-Kalibrierung implementiert, die insgesamt 10 Fixationspunkte pro Durchlauf umfasst (der Mittelpunkt wird zur Validierung doppelt abgefragt). Als Stimulus dient ein optimiertes Fixationskreuz (Thaler et al., 2013). Die Kalibrierung erfolgt zu drei Zeitpunkten: zu Beginn, in der Mitte (nach dem ersten Block von Trials) und am Ende des Experiments.

Um systematische Verzerrungen durch die Bewegungsrichtung zu minimieren, wurde die Anfangskalibrierung bidirektional gestaltet: Das Fixationskreuz durchläuft – ständig sichtbar – das 9-Punkte-Raster zunächst mit Start nach links oben und anschließend in entgegengesetzter Richtung mit Start nach rechts unten. Die Mittel- und Endkalibrierung werden hingegen nur einfach durchlaufen, wobei die Endkalibrierung erneut mit Start nach rechts unten erfolgt. Zusätzlich werden für eine noch präzisere Erfassung der Bildschirmmitte auch während der Fixationskreuzphasen zwischen den Trials Kalibrierungsdaten entnommen.

**Trade-off und experimentelle Variation.** In Bezug auf die optimale Häufigkeit der Kalibrierung besteht ein Trade-off zwischen Genauigkeit und Praktikabilität, der sorgfältig auf die Anforderungen des jeweiligen Anwendungsfalls abgestimmt werden sollte (Heck et al., 2023). Einerseits erhöht jeder zusätzliche Datenpunkt die Genauigkeit des Kalibrierungsmodells, andererseits können lange Kalibrierungszeiten zu Ermüdung und Leistungsabfall führen (Saxena et al., 2024).

Um zu untersuchen, wie viel Kalibrierungsaufwand für eine valide Blickerkennung tatsächlich notwendig ist, wird die Datenmenge der Kalibrierung als unabhängige Variable (UV3) variiert: Die **vollständige Kalibrierung** (Variante 1) umfasst alle verfügbaren Kalibrierungsdaten zu allen drei Zeitpunkten (Anfang, Mitte, Ende) sowie zusätzliche Fixationspunkte aus den Phasen zwischen den Trials. Bei der **reduzierten Kalibrierung** (Variante 2) werden lediglich die ersten 10 Punkte der Anfangskalibrierung (nur Start nach links oben) sowie die Endkalibrierung und die Fixationspunkte aus den Phasen zwischen den Trials einbezogen – die mittlere Kalibrierungsphase entfällt vollständig.

## Synchronisation

Eine zentrale Herausforderung bei der Entwicklung der CV-Pipeline besteht darin, dass die Videoaufnahmen und die Experimentalsoftware auf unterschiedlichen Systemen laufen und daher technisch entkoppelt sind: Die Kamera beginnt mit der Aufzeichnung zu einem anderen Zeitpunkt als softwareseitig das Experiment startet. Um die CV-Blickschätzungen mit den EyeLink-Daten vergleichen zu können, müssen diese beiden Zeitachsen jedoch präzise aufeinander abgestimmt werden. Konkret bedeutet dies: Für jeden Frame der Videoaufnahme muss bekannt sein, welchem Zeitpunkt im Experiment er entspricht – und damit, welchem Trial und welcher Phase (Fixation oder Stimulus) er zuzuordnen ist.

**Audio-basiertes Marker-System.** Zur Lösung dieses Problems wurde ein audio-basiertes Synchronisationssystem implementiert. Die Experimentalsoftware generiert zu definierten Zeitpunkten akustische Signale mit spezifischen Frequenzen, die von den Kameras als Teil der Tonspur aufgezeichnet werden:

- 440 Hz: Start einer Fixationskreuzphase (vor jedem Trial)
- 880 Hz: Start einer Stimulusphase (Bildpräsentation)
- 1760 Hz: Kalibrierungspunkt erreicht

Die Detektion dieser Marker in den Audiospuren der Videoaufnahmen erfolgt durch einen frequenzspezifischen Algorithmus. Dieser nutzt einen frequenzspezifischen Bandpass-Filter (Butterworth-Filter 4. Ordnung), der nur Signale im Bereich der Zielfrequenz durchlässt und so die Marker vom Umgebungslärm isoliert. Eine anschließende mathematische Transformation (Hilbert-Transformation) berechnet die Signaleinhüllende, aus der die Zeitpunkte der Tonsignale bestimmt werden.

**Initialer Synchronisationspunkt.** Zur Bestimmung des globalen Zeitversatzes zwischen Video und Experiment identifiziert der Algorithmus zunächst den ersten 1760-Hz-Kalibriererton als Anker. Dieser Ton markiert das Erreichen des ersten Kalibrierungspunkts und eignet sich als Referenz, da er zu einem bekannten Zeitpunkt zu Beginn des Experiments auftritt und somit einen eindeutigen Ankerpunkt für die Zeitachsensynchronisation bietet. Um Fehldetektionen durch Störgeräusche zu vermeiden, wird ein Isolationskriterium angewendet: Der Ton wird nur akzeptiert, wenn in den 30 Sekunden davor kein anderes spezifisches Tonsignal detektiert wurde.

**Abgleich mit dem JSON-Log.** Die reine Tondetektion erwies sich in der Praxis jedoch als fehleranfällig: Störgeräusche und über die Videos variierende Signalstärken machten häufig manuelle Nachjustierungen erforderlich. Um die Robustheit zu erhöhen, wurde daher ein Abgleich mit dem JSON-Log der Experimentalsoftware implementiert. Dieses Log dokumentiert für jede VP automatisch alle relevanten Events mit ihren geplanten Zeitstempeln: den Start jedes Trials, den Beginn jeder Kalibrierungsphase sowie die exakten Zeitpunkte und Bildschirmpositionen aller Kalibrierungspunkte. Der Algorithmus nutzt diese Informationen, um die detektierten Audio-Marker zu validieren: Die zeitlichen Abstände zwischen aufeinanderfolgenden Tönen im Video werden mit den erwarteten Abständen aus dem JSON-Log verglichen. Stimmen diese überein, gilt der Marker als verifiziert; weichen sie ab, wird nach alternativen Kandidaten gesucht.

**Drift-Korrektur.** Ein zusätzliches Problem entsteht dadurch, dass Video und Experiment nicht exakt synchron laufen – die Zeitachsen driften auseinander, typischerweise um wenige Millisekunden pro Minute. Um diese Drift zu korrigieren, wird eine Multi-Anchor-Regression durchgeführt: Alle erfolgreich detektierten und validierten Marker dienen als Referenzpunkte, aus denen eine lineare Regression die optimale Zeitverschiebung und -streckung berechnet. Diese Korrektur wird auf alle nachfolgenden Blickdaten angewendet.

**Entwicklungsgeschichte und Limitationen.** Die aktuelle Implementierung stellt einen Kompromiss dar. Zu Beginn der Softwareentwicklung wurde das Video noch manuell in die relevanten Abschnitte unterteilt (z. B. Kalibrierungsphase 1, Trialblock 1). Mit dieser Methode war eine reine Tonsynchronisation möglich, die händische Videosequenzierung war jedoch zeitaufwendig und nicht für eine größere Anzahl von VP geeignet. Der Abgleich mit dem JSON-Log schaffte Abhilfe und erhöhte gleichzeitig die Präzision der Synchronisation, bedeutet aber, dass die Pipeline nicht mehr vollständig autonom auf Basis der Tondetektion arbeitet. Versuche, eine VP-übergreifende Lösung zu entwickeln, scheiterten an versionsabhängigen Zeitunterschieden zwischen den Experimentaldurchläufen (siehe Versionsdokumentation in Appendix D). Eine mögliche Weiterentwicklung wäre ein systemseitiger Kamerastart durch die Experimentalsoftware, der die gesamte Tonsynchronisierung obsolet machen würde (siehe Diskussion).

## **Blink-Detektion**

Eine valide Blickdatenerfassung setzt voraus, dass Phasen, in denen keine visuellen Informationen aufgenommen werden können (Lidschlag), zuverlässig aus der Analyse

ausgeschlossen werden. Der EyeLink 1000 übernimmt diese Aufgabe systemseitig. Für die CV-Pipelines wurde ein eigener Blink-Detektions-Algorithmus implementiert, der auf der Eye Aspect Ratio (EAR) basiert (Soukupová & Čech, 2016). Die EAR ist ein skalares Maß, das das Öffnungsverhältnis des Auges anhand der Abstände zwischen den vertikalen und horizontalen Augenlid-Landmarken berechnet. Sinkt dieser Wert unter einen definierten Schwellenwert, wird das Auge als geschlossen interpretiert.

**Adaptive Schwellenwertbestimmung.** Die initiale Implementierung verwendete einen fixen EAR-Schwellenwert von 0.16, der bewusst niedrig gewählt wurde, um bei älteren VP mit hängenden Augenlidern falsch-positive Blink-Detektionen zu vermeiden. In der Praxis zeigte sich jedoch, dass ein universeller Schwellenwert den interindividuellen Unterschieden in der Augenöffnung nicht gerecht wird: Bei einigen VP führte der fixe Wert zu einer Überdetektion (normale Lidschläge wurden als Blinks klassifiziert), bei anderen zu einer Underdetektion (tatsächliche Blinks wurden übersehen).

Zur Lösung dieses Problems wurde ein adaptives Verfahren entwickelt, das den Schwellenwert personenspezifisch bestimmt. Der Algorithmus berechnet zunächst die EAR-Verteilung über alle Frames einer VP und setzt den Schwellenwert relativ zum Median dieser Verteilung. Dabei zeigte sich, dass unterschiedliche Multiplikatoren für die beiden Kamerasysteme und VPs erforderlich sind. Diese Unterschiede sind vermutlich auf die unterschiedliche zeitliche Auflösung zurückzuführen: Bei niedrigerer Framerate werden Blinks in weniger Frames erfasst, was zu anderen EAR-Verteilungen führt. Zur Qualitätssicherung generiert der Algorithmus diagnostische Visualisierungen, die das EAR-Signal zusammen mit den detektierten Blinks und Exklusionszonen darstellen. Basierend auf diesen Plots wurden die Multiplikatoren bei Bedarf manuell nachjustiert.

Zusätzlich zur EAR-basierten Detektion wurden Validierungskriterien implementiert, um Fehldetektionen zu reduzieren: Blinks mit einer Dauer unter 40 ms oder über 2000 ms werden verworfen, und zwischen zwei Blinks muss eine Mindestpause von 200 ms liegen (Refraktärzeit) – diese Pause verhindert, dass ein einzelner Blink fälschlicherweise als mehrere separate Blinks gezählt wird (Hollander & Huette, 2022). Um sowohl Vor- als auch Nachartefakte durch Lidbewegungen, Signalverluste und Tracker-Recovery zuverlässig zu entfernen, wurde ein symmetrisches Exklusionsfenster von 80 ms vor und 80 ms nach jedem Blink definiert (Hollander & Huette, 2022). Alle Frames innerhalb dieses Fensters werden von der Analyse ausgeschlossen.

**Limitationen und Ausblick.** Das beschriebene Verfahren stellt eine Übergangslösung dar, die für die vorliegende Pilotstudie praktikabel war, jedoch nicht ohne Weiteres auf größere Stichproben skalierbar ist. Die manuelle Nachkorrektur der Schwellenwerte erfordert visuelle Inspektion jeder VP und ist entsprechend zeitaufwendig. Für zukünftige Anwendungen wäre die Implementierung eines vollständig automatisierten, selbstkalibrierenden Algorithmus erforderlich – beispielsweise durch maschinelles Lernen auf Basis der manuell validierten Daten dieser Studie. Die pro VP ermittelten optimalen Schwellenwerte wurden dokumentiert und könnten bei einem Retest als personenspezifische Startwerte dienen.

### **Abhängige Variablen und Forschungsfragen**

Zur Bewertung der Übereinstimmung zwischen den CV-Pipelines und dem Referenzstandard (EyeLink 1000) werden drei zentrale Validierungsmetriken herangezogen. Steigung und Bias werden pro Trial und Person aus der linearen Regression der CV-Schätzung auf die EyeLink-Messung berechnet:  $CV = \beta_0 + \beta_1 \times \text{EyeLink}$ .

Die **Korrelation** ( $r$ ) erfasst die Stärke des linearen Zusammenhangs zwischen CV-Schätzung und EyeLink-Messung über alle Frames eines Trials und reflektiert damit die Präzision der Blickbewegungserfassung. Ein Wert von  $r = 1$  würde perfekte Übereinstimmung anzeigen – in Abbildung 2 (Panel A, grüne Punkte) liegen alle Werte exakt auf der Diagonalen. Messrauschen führt zu Streuung einzelner Punkte um diese Ideallinie (rote Punkte), wodurch die Korrelation sinkt. Je größer die vertikale Abweichung einzelner Frames von der Diagonalen, desto niedriger der resultierende  $r$ -Wert. Für die FVE-basierte Neglect-Diagnostik ist eine hohe Korrelation zentral, da sie sicherstellt, dass die CV-Pipeline die tatsächlichen Blickbewegungsmuster zuverlässig abbildet. Für inferenzstatistische Analysen wurde die Fisher-z-Transformation angewendet – ein Standardverfahren, das Korrelationskoeffizienten in eine normalverteilte Metrik überführt und damit die Anwendung parametrischer Verfahren ermöglicht.


Die **Steigung** ( $\beta_1$ ) beschreibt das Verhältnis der CV-Schätzung zur EyeLink-Messung und quantifiziert damit den Verstärkungsfaktor der Blickbewegungserfassung. Ein Wert von 1 indiziert perfekte Amplitudenübereinstimmung – in Abbildung 2 (Panel B, grüne Punkte und gestrichelte Linie) werden Blickpositionen proportional abgebildet. Werte unter 1 zeigen eine Unterschätzung (Kompression peripherer Blickpositionen zur Bildschirmmitte hin): In Panel B ist erkennbar, dass bei einer Steigung von 0.6 (rote Punkte und durchgezogene Linie) ein Blick auf  $10^\circ$  Schwinkel nur als  $6^\circ$  Schwinkel registriert wird – die Distanz

zwischen den beiden Geraden nimmt zu größeren Blickwinkeln hin zu. Für die Neglect-Diagnostik ist eine Steigung nahe 1 wichtig, damit die räumliche Verteilung der Blickpositionen – insbesondere die Lateralisierung bei Neglect – korrekt erfasst wird.

Der **Bias** entspricht dem Intercept ( $\beta_0$ ) der Regression und quantifiziert die systematische Verschiebung der CV-Schätzung bei zentraler Blickposition (Eyetracker = 0° Sehwinkel, d.h. Bildschirmmitte). Ein Wert nahe null indiziert, dass bei Fixation der Bildschirmmitte kein systematischer Offset zwischen CV-Pipeline und Referenzstandard vorliegt – in Abbildung 2 (Panel C, grüne Punkte) schneidet die Ideallinie die Y-Achse bei null. Ein positiver Bias (rote Punkte) verschiebt alle Schätzungen parallel nach oben: In Panel C ist erkennbar, dass bei einem Bias von 3° Sehwinkel selbst bei Fixation der Bildschirmmitte (Eyetracker = 0° Sehwinkel) die CV-Pipeline eine Position von 3° rechts davon registriert. Diese Metrik ist für die FVE-basierte Neglect-Diagnostik besonders relevant: Da der Fixationspunkt zwischen den Stimuli stets in der Bildschirmmitte liegt und die mittlere horizontale Blickposition als diagnostischer Indikator dient, könnte ein systematischer Bias fälschlicherweise als Neglect-Symptom interpretiert werden.

## Abbildung 2

*Beispielhafte Illustration der drei Validierungsmetriken*



*Anmerkung.* Die drei Panels illustrieren anhand simulierter Beispieldaten die Bedeutung der Validierungsmetriken. (A) **Korrelation:** Grüne Punkte zeigen perfekte Übereinstimmung ( $r = 1$ ) auf der Diagonalen, rote Punkte eine durch Rauschen reduzierte Korrelation. Der schwarze Pfeil markiert die Streuung eines einzelnen Messpunkts. (B) **Steigung:** Bei Slope = 1 (grüne gestrichelte Linie) werden Blickpositionen proportional abgebildet. Eine Steigung von 0.6 (rote durchgezogene Linie) komprimiert periphere Positionen zur Mitte. Der Pfeil zeigt den Unterschied zwischen den Geraden bei peripherer Blickposition. (C) **Bias:** Bei Bias = 0° Sehwinkel (grüne gestrichelte Linie) liegt kein systematischer Offset vor. Ein Bias von 3° Sehwinkel (rote durchgezogene Linie) verschiebt alle Schätzungen um diesen Betrag. Der Pfeil auf der Y-Achse markiert den konstanten Offset bei zentraler Blickposition (Eyetracker = 0° Sehwinkel).

Ergänzend zu diesen regressionsbasierten Validierungsmetriken, die als abhängige Variablen in die inferenzstatistische Analyse eingehen, wird ein weiterer Kennwert für die deskriptive Charakterisierung der Messqualität herangezogen: Der **Mean Absolute Error (MAE)** quantifiziert die durchschnittliche absolute Abweichung zwischen der CV-Schätzung und der EyeLink-Referenzmessung in Grad Schwinkel. Er wird pro Frame berechnet und anschließend über alle Frames eines Trials gemittelt. Im Gegensatz zur Korrelation, die lediglich die lineare Übereinstimmung der Zeitreihen erfasst, und zur Steigung, die das Verhältnis der Amplituden beschreibt, gibt der *MAE* direkt die praktisch relevante Messungsgenauigkeit in der Einheit der Messung an – ein *MAE* von  $2^\circ$  Schwinkel bedeutet, dass die CV-Schätzung im Mittel um  $2^\circ$  Schwinkel von der tatsächlichen Blickposition abweicht.

Zusammenführend zielt diese Pilotstudie darauf ab, die Eignung moderner CV-Algorithmen mittels der entwickelten Python-Pipeline als Ersatz für spezialisierte Hardware in der Neglect-Diagnostik zu evaluieren. Denn trotz vielversprechender Ergebnisse computergestützter Assessment-Tools für räumlichen Neglect ist eine weitere Validierung und Standardisierung dieser Methoden erforderlich, bevor sie flächendeckend in der klinischen Praxis eingesetzt werden können (Terruzzi et al., 2024). Da es sich um eine explorative Pilotstudie handelt, werden keine gerichteten Hypothesen formuliert. Stattdessen leiten sich aus der vorangegangenen Argumentation folgende Forschungsfragen ab:

1. Wie hoch ist die Übereinstimmung zwischen den Computer-Vision-Pipelines (MediaPipe, PTGaze) und dem stationären EyeLink 1000 hinsichtlich Korrelation, Steigung und Bias?
2. Unterscheiden sich Methode 1 (MediaPipe) und Methode 2 (PTGaze) in ihrer Übereinstimmung mit dem EyeLink 1000?
3. Beeinflusst das Kamerasystem (Webcam vs. Systemkamera) die Übereinstimmung der CV-Pipelines mit dem EyeLink 1000?
4. Beeinflusst die Komplexität der Kalibrierung (vollständig vs. reduziert) die Übereinstimmung der CV-Pipelines mit dem EyeLink 1000?

## Methode

Um diese Fragestellungen zu untersuchen, wurden Versuchspersonen im Labor in einem an dem Verfahren von Kaufmann et al. (2020) orientierten experimentellen Setting von einem Eyetracker und parallel von zwei Kameras erfasst.

### Versuchspersonen

Da es sich um eine Pilotstudie handelt, wurde keine a-priori-Poweranalyse durchgeführt. Ziel war vielmehr, einen möglichst breiten Eindruck von den Möglichkeiten und Herausforderungen einer CV-Pipeline im Kontext der Neglect-Diagnostik zu gewinnen. Die Stichprobe umfasste 12 Versuchspersonen (VP; 8 weiblich, 4 männlich) im Alter von 51 bis 74 Jahren ( $M = 66$ ,  $SD = 7.36$ ). Zusätzlich nahmen zwei Pilotpersonen (Alter < 50 Jahre) an der Erprobung des Versuchsablaufs teil, deren Daten nicht in die Auswertung eingingen. Ergänzend zur Hauptstichprobe wurde eine einzelne Neglect-Patientin (52 Jahre, weiblich) für die explorative Evaluation der CV-Pipeline und die Entwicklung der neglectspezifischen Kalibrierungsstrategie herangezogen. Die Patientin wies einen multimodalen linksseitigen Neglect nach rechtshemisphärischer Brückenvenenthrombose mit parietaler Beteiligung auf. Ihre Daten dienten ausschließlich der explorativen Analyse und der Optimierung der Kalibrierungsparameter. Rekrutiert wurden die VP über persönliche Kontakte und den E-Mail-Verteiler des Lehrstuhls für Klinische Neuropsychologie. Eine Aufwandsentschädigung von 10 € wurde unabhängig vom erfolgreichen Abschluss des Versuchsablaufs ausgezahlt. Einschlusskriterien waren ein Mindestalter von 50 Jahren, normale oder korrigierte Sehfähigkeit und kein diagnostizierter Neglect (gesunde Kontrollgruppe).

Bedingt durch kleinere Anpassungen am Versuchsablauf (siehe Versionsübersicht in Appendix D) kamen insgesamt vier Versionen der Experimentalsoftware zum Einsatz: Drei VP durchliefen Version 1, eine VP Version 2, zwei VP Version 3 und sechs VP Version 4. Abgesehen von diesen technischen Anpassungen war der Versuchsablauf für alle VP identisch.

**Technische Einschränkungen bei einzelnen VP.** Bei den 60-Hz-Videos von VP 2, VP 4, VP 7 und VP 10 trat ein aufnahmetechnisches Problem auf, das nicht mit der Kamera selbst zusammenhing: Die für die Synchronisation erforderlichen Audiosignale waren stark beschädigt und nur noch sehr leise detektierbar. Die Standard-Tonsynchronisation war dadurch nicht anwendbar. Stattdessen wurden die Startpunkte der drei Videokalibrierungen manuell eingegeben und anschließend eine verstärkte Tonsuche durchgeführt. Dieses Vorgehen

lieferte grundsätzlich verwertbare Ergebnisse, die Synchronisationsqualität ist bei diesen VP jedoch eingeschränkt.

### **Material und Versuchsablauf**

Um die Forschungsfragen zu untersuchen, absolvierten die VP in einem Laborsetup das FVE-Paradigma nach Kaufmann et al. (2020), wobei parallel ein EyeLink 1000 als Referenzsystem und zwei Kameras für die CV-Pipelines die Blickbewegungen erfassen.

**Setup.** Nach der Begrüßung erhielten die VP schriftliche Informationen zum Ablauf sowie eine datenschutzrechtliche Aufklärung. Nach Unterzeichnung der Einverständniserklärung und Klärung offener Fragen wurde das Versuchssetup (siehe Abbildung 3) individuell angepasst. Die Stuhlhöhe wurde so eingestellt, dass eine angenehme und stabile Position in der Kopfstütze eingenommen werden konnte. Der Abstand zum Bildschirm betrug 68 cm (Version 1) bzw. 70 cm (Version 2–4). Die Raumbeleuchtung blieb während der gesamten Erhebung konstant.

**Bestimmung des dominanten Auges.** Zur Festlegung des zu trackenden Auges wurden zwei Tests durchgeführt. Beim Hole-in-Card-Test hielten die VP eine Karte mit einem Loch in der Mitte bei ausgestreckten Armen vor sich und fixierten durch das Loch einen Punkt an der Wand. Anschließend führten sie die Karte langsam zum Gesicht – sie endet vor dem dominanten Auge. Zur Bestätigung diente der Abdecktest (Miles-Test): Bei erneut ausgestreckten Armen und fixiertem Punkt wurde abwechselnd ein Auge abgedeckt. Beim Abdecken des dominanten Auges „springt“ der Punkt scheinbar zur Seite und verschwindet meistens aus dem Blickfeld. Das so bestimmte dominante Auge wurde im EyeLink hinterlegt.

**EyeLink-Kalibrierung.** Nach dem Start der Experimentalsoftware (MATLAB) und einer informierenden Tonansage (siehe Transkript in Appendix E) erfolgte die Kalibrierung des EyeLink. Zunächst wurde die Optik des Eyetrackers auf das dominante Auge eingestellt und scharfgestellt. Die automatische Iris- und Pupillendetektion wurde visuell geprüft und bei Bedarf manuell nachjustiert. Anschließend durchliefen die VP die standardmäßige EyeLink-Kalibrierung und -Validierung. Bei einigen VP traten Probleme bei der Pupillenerfassung auf, die vermutlich auf Sehhilfen (Bifokalbrillen, Keratokonuslinsen) zurückzuführen sind. Entsprechend konnte nicht bei allen VP die vorgesehene 13-Punkt-Kalibrierung durchgeführt werden: Acht VP absolvierten eine 13-Punkt-Kalibrierung, zwei VP eine 5-Punkt-Kalibrierung, eine VP eine 9-Punkt-Kalibrierung und eine VP eine 3-Punkt-Kalibrierung.

### Abbildung 3

*Versuchssetup mit Kopfstütze beiden Kameras und Eyetracker*



Bei allen VP konnte jedoch eine verwertbare Kalibrierung erreicht werden (durchschnittlicher Error:  $0.41^\circ$  Schwinkel,  $SD = 0.25$ ; durchschnittlicher Offset:  $0.16^\circ$  Schwinkel,  $SD = 0.25$ ). Nach Bestätigung der Validierung durch den Versuchsleiter lief der weitere Versuch automatisch ab. Spätestens zu diesem Zeitpunkt wurde die Aufzeichnung auf beiden Kameras manuell gestartet.

**Videokalibrierung.** Im Anschluss folgte nach einer weiteren Tonansage die erste von drei Videokalibrierungen für die CV-Pipelines. Das Vorgehen orientierte sich an der in der

Einleitung beschriebenen neglectspezifischen Kalibrierungsstrategie: Die VP verfolgten ein dauerhaft sichtbares Fixationskreuz, das mit einer Geschwindigkeit von 400 px/s über das 9-Punkte-Raster wanderte und an jedem Punkt für 4–5 Sekunden (versionsabhängig) verweilte. Die Anfangskalibrierung wurde bidirektional durchgeführt, die Mittel- und Endkalibrierung jeweils nur einfach. Für eine detaillierte Beschreibung der Kalibrierungsstrategie siehe den Abschnitt „Kalibrierungsstrategie“ in der Einleitung.

**Bildpräsentation (FVE-Paradigma).** Nach einer weiteren Tonansage begann die Bildpräsentation. In einer pro VP automatisch randomisierten Reihenfolge erschienen 12 verschiedene Bilder – jeweils einmal im Original und einmal an der vertikalen Achse gespiegelt – auf dem Bildschirm (insgesamt 24 Trials). Die Bilder zeigten alltägliche Szenen wie Landschaften oder öffentliche Plätze mit bewusst gesetzten optischen Schwerpunkten. Jedes Bild wurde für 7 Sekunden präsentiert und konnte in dieser Zeit frei exploriert werden (Stimulusphase). Vor jedem Bild erschien für ca. 2 Sekunden (leichte Varianz durch unterschiedliche Länge der gleichzeitig laufenden Ansage der Trialnummer) ein Fixationskreuz in der Bildschirmmitte (Fixationskreuzphase). Die Kombination aus Fixationskreuz- und Stimulusphase bildet einen Trial. Zu Beginn jeder Phase wurden akustische Marker ausgegeben, die für die spätere Synchronisation der Videodaten mit den EyeLink-Daten erforderlich sind (440 Hz: Start Fixationskreuzphase; 880 Hz: Start Stimulusphase; 1760 Hz: Kalibrierungspunkt erreicht). Ein Beispieltrial mit einem zusätzlichen Bild zu Beginn ermöglichte es den VP, sich mit dem Ablauf vertraut zu machen.

Anders als bei Kaufmann et al. (2020) wurden die 24 Trials in zwei Blöcke à 12 Trials aufgeteilt. Zwischen den beiden Blöcken sowie am Ende erfolgte jeweils eine weitere Videokalibrierung (nur ein Durchlauf des 9-Punkte-Rasters). Nach einer Abschlussmeldung auf dem Bildschirm war der Versuch beendet. Die Gesamtdauer betrug ca. 15 Minuten. Die Auswertung der aufgezeichneten Videos mittels der CV-Pipelines erfolgte asynchron nach Abschluss der Datenerhebung.

**Evaluation der Kalibrierungsparameter.** Um für zukünftige Versuchsabläufe die optimalen Parameter für die Videokalibrierung zu bestimmen, wurden mit der im vorangegangenen Abschnitt beschriebenen Neglect-Patientin explorativ und außerhalb der eigentlichen Versuchsreihe acht Kalibrierungsdurchgänge mit variierender Fixationskreuzgeschwindigkeit (200, 300, 400 und 500 px/s) durchgeführt. Wie bei der normalen Videokalibrierung bewegte sich das Kalibrierungsziel kontinuierlich über das 9-Punkte-Raster, wobei für jede

Geschwindigkeitsstufe zwei Durchgänge absolviert wurden: einer mit Startrichtung links oben (Durchgänge 1–4) und einer mit Startrichtung rechts unten (Durchgänge 5–8). Die Blickpositionen wurden simultan mit dem EyeLink sowie der Systemkamera für die nachträgliche CV-Analyse erfasst.

### **Datenauswertung**

Zur Vorbereitung der Daten erzeugte ein Python-Skript einen gemeinsamen Datensatz aus dem Output des EyeLink und der CV-Pipelines. Da für die Analyse eine gleichmäßige Messpunktmenge vorliegen muss, wurde ein Downsampling der EyeLink-Daten mittels der Nearest-Neighbor-Methode angewendet (vgl. Abschnitt „Pipeline-Integration“ in der Einleitung). Die weitere Datenvorbereitung und die Datenanalyse erfolgten mit R (Version 4.4.2) in RStudio. Die verwendeten wichtigsten Pakete umfassen tidyverse (Wickham et al., 2019) für Datenmanipulation, lme4 (Bates et al., 2015) und lmerTest (Kuznetsova et al., 2017) für lineare gemischte Modelle, emmeans (Lenth, 2023) für Post-hoc-Vergleiche, afex (Singmann et al., 2015) für Repeated-Measures-ANOVAs sowie performance (Lüdtke et al., 2021) für Modelldiagnostik.

**Datenbereinigung und Ausschlüsse.** Um Ergebnisverfälschungen durch beschädigte Daten zu vermeiden, wurden Frames nach zwei Kriterien ausgeschlossen: Erstens alle Frames, während derer ein Lidschlag detektiert wurde. Der Blink-Detektions-Algorithmus basiert auf adaptiven, kameraspezifischen EAR-Schwellenwerten und schließt zusätzlich ein symmetrisches Exklusionsfenster von 80 ms vor und nach jedem Blink ein (für Details siehe Abschnitt „Blink-Detektion“ in der Einleitung). Zweitens alle Frames, bei denen die Blickpunkte außerhalb des Versuchsbildschirms lagen (Ehinger et al., 2019; Holmqvist et al., 2011). Frames ohne verfügbare Daten (z. B. durch Pupillenverlust) wurden mit NaN codiert.

Über alle 12 VP und die verschiedenen Auswertungssettings wurden 757.528 Frames gesammelt. Davon entfallen 562.908 auf die für die Auswertung relevante Stimulusphase und 194.620 auf die Fixationsphase. Aufgrund detektierter Blinks wurden insgesamt 61.352 Frames (8,1 %) ausgeschlossen; aufgrund von Blickpunkten außerhalb des Versuchsbildschirms wurden keine Frames ausgeschlossen. Insgesamt gingen 527.028 Frames (93,6 %) aus der Stimulusphase in die weitere statistische Analyse ein.

**Aggregationsverfahren.** Um die Abhängigkeit der Daten zwischen zeitlich benachbarten Frames zu berücksichtigen, erfolgte für alle deskriptiven Statistiken eine Aggregation:

Zunächst wurde der Mittelwert über alle Frames eines Trials gebildet (Trial-Level), anschließend der Mittelwert über alle Trials einer Versuchsperson (VP-Level), und schließlich der Mittelwert und die Standardabweichung über alle Versuchspersonen (globale Statistik).

**Lineare gemischte Modelle.** Die Trial-Level-Metriken (Fisher-z-transformierte Korrelation, Steigung, Bias) wurden mithilfe von linearen gemischten Modellen (LMMs) analysiert. LMMs berücksichtigen die hierarchische Datenstruktur (Trials geschachtelt in VP) und ermöglichen die simultane Schätzung von Fixed Effects (experimentelle Faktoren) und Random Effects (interindividuelle Variabilität).

Zur Überprüfung der Voraussetzungen für die Multilevel-Modellierung wurden zunächst Intraklassenkorrelationen (ICC) aus Nullmodellen berechnet. Diese geben an, welcher Anteil der Gesamtvarianz auf Unterschiede zwischen den Versuchspersonen (Level 2) zurückgeht. Die ICCs lagen für alle abhängigen Variablen über dem empfohlenen Schwellenwert von .05 (Korrelation: ICC = .187; Steigung: ICC = .140; Bias: ICC = .179), was auf substantielle Varianzanteile zwischen den VP hinweist und die Verwendung von LMMs rechtfertigt (Snijders & Bosker, 2011).

Die Modellselektion erfolgte zweistufig: Zunächst wurde die Fixed-Effects-Struktur datengetrieben mittels Likelihood-Ratio-Tests (LRT) und Informationskriterien (AIC, BIC) bestimmt. Anschließend wurde die Random-Effects-Struktur nach dem Parsimonious-Ansatz durchgeführt, wobei ein  $\alpha$ -Niveau von .20 verwendet wurde, um relevante Varianzkomponenten nicht vorschnell auszuschließen (Bates et al., 2018; Matuschek et al., 2017).

Alle finalen Modelle wurden mittels Restricted Maximum Likelihood (REML) geschätzt, was im Vergleich zu Maximum Likelihood (ML) weniger verzerrte Varianzschätzungen liefert (Edwards et al., 2008). Die Fixed Effects wurden unter Verwendung von Quadratsummen vom Typ III mit der Satterthwaite-Approximation für die Nenner-Freiheitsgrade getestet (Luke, 2017). Die Effektstärken für das Gesamtmodell werden nach Nakagawa und Schielzeth (2013) als marginales  $R^2$  ( $R_m^2$ ; durch Fixed Effects erklärte Varianz) und konditionales  $R^2$  ( $R_c^2$ ; durch Fixed und Random Effects erklärte Varianz) berichtet. Post-hoc-Paarvergleiche wurden anhand Estimated Marginal Means (EMM) – modellbasierte Schätzungen der Gruppenmittelwerte unter Berücksichtigung aller Modellterme – mit dem Paket emmeans durchgeführt, wobei erneut die Satterthwaite-Methode zur Schätzung der Freiheitsgrade Anwendung fand. Als Effektstärke für die Paarvergleiche wird Hedges'  $g$  berichtet.

Für alle kategorialen Prädiktoren wurden Sum-to-Zero-Kontraste verwendet, um sicherzustellen, dass die Haupteffekte die durchschnittlichen Effekte über die Stufen der anderen Faktoren hinweg repräsentieren und eine angemessene Interpretation der Typ-III-Tests bei Vorliegen von Interaktionen zu ermöglichen (Schad et al., 2020).

Die visuelle Inspektion der Quantil-Quantil-Plots (QQ-Plots) deutete auf leichte Abweichungen von der Normalverteilung bei den Residuen hin (Bias: schwere Ränder; Steigung: Linksschiefe). Da LMMs bei ausreichend großen Stichproben auf Level 1 robust gegenüber moderaten Verletzungen der Normalverteilungsannahme sind (Schielzeth et al., 2020) und die Random Effects approximativ normalverteilt waren, wurden keine Transformationen vorgenommen.

**Repeated-Measures-ANOVA.** Zur Überprüfung der Robustheit der LMM-Ergebnisse wurden ergänzend Repeated-Measures-ANOVAs mit auf VP-Ebene aggregierten Daten durchgeführt. Das Design umfasste die drei Faktoren Methode (MediaPipe, PTGaze), Kamera (Systemkamera, Webcam) und Kalibrierung (vollständig, reduziert).

Die Voraussetzungsprüfung ergab keine Verletzungen: Es wurden keine extremen Ausreißer identifiziert (alle  $|z| < 3.29$ ), und die Shapiro-Wilk-Tests zeigten keine signifikanten Abweichungen von der Normalverteilung in den einzelnen Bedingungszellen (alle  $p > .05$ ). Die visuelle Inspektion der QQ-Plots bestätigte die approximative Normalverteilung der Daten. Da alle Faktoren zweistufig sind, ist die Sphärizitätsannahme für Haupteffekte automatisch erfüllt; die Freiheitsgrade wurden dennoch nach Greenhouse-Geisser korrigiert.

## Ergebnisse

### Deskriptive Statistiken

Über alle Bedingungen hinweg lag die mittlere Korrelation zwischen CV-Pipelines und EyeLink bei  $r = .75$  ( $SD = .17$ ), die mittlere Steigung bei  $0.68$  ( $SD = 0.17$ ), der mittlere Bias bei  $0.07^\circ$  Schwinkel ( $SD = 0.15^\circ$  Schwinkel) und der mittlere  $MAE$  bei  $3.77^\circ$  Schwinkel ( $SD = 1.22^\circ$  Schwinkel). Diese globalen Kennwerte verdecken jedoch Unterschiede zwischen den Bedingungskombinationen, die sich in Tabelle 1 abzeichnen.

**Tabelle 1**

*Deskriptive Statistik der Validierungsmetriken für die horizontale Blickposition*

| Methode   | Kamera | Kalibrierung | $X_{CV}$ ( $SD$ ) | $r$ ( $SD$ ) | Steigung ( $SD$ ) | Bias ( $SD$ )   | $MAE$ ( $SD$ ) |
|-----------|--------|--------------|-------------------|--------------|-------------------|-----------------|----------------|
| MediaPipe | 25Hz   | voll         | 0.18 (1.60)       | .89<br>(.05) | 0.77<br>(0.14)    | 0.09<br>(1.67)  | 3.37<br>(0.81) |
|           |        | reduziert    | 0.24 (1.39)       | .89<br>(.05) | 0.74<br>(0.15)    | 0.16<br>(1.61)  | 3.40<br>(0.90) |
|           | 60Hz   | voll         | 0.27 (1.81)       | .60<br>(.17) | 0.48<br>(0.14)    | 0.17<br>(1.91)  | 5.06<br>(1.02) |
|           |        | reduziert    | 0.36 (1.51)       | .59<br>(.16) | 0.46<br>(0.14)    | 0.28<br>(1.73)  | 5.07<br>(0.99) |
| PTGaze    | 25Hz   | voll         | 0.00 (0.80)       | .91<br>(.05) | 0.89<br>(0.11)    | -0.15<br>(0.63) | 2.09<br>(0.58) |
|           |        | reduziert    | 0.00 (0.79)       | .91<br>(.05) | 0.88<br>(0.11)    | -0.14<br>(0.63) | 2.10<br>(0.61) |
|           | 60Hz   | voll         | 0.24 (0.82)       | .59<br>(.17) | 0.62<br>(0.18)    | 0.09<br>(0.82)  | 4.56<br>(1.06) |
|           |        | reduziert    | 0.17 (0.78)       | .59<br>(.17) | 0.60<br>(0.18)    | 0.04<br>(0.80)  | 4.53<br>(1.04) |

*Anmerkung.*  $N = 12$ . Alle Winkelangaben ( $X_{CV}$ , Bias, MAE) erfolgen in Grad Schwinkel ( $^\circ$ ). Die Daten wurden über Trials und Versuchspersonen aggregiert.  $X_{CV}$  = mittlerer horizontaler Blickwinkel der Computer-Vision-Schätzung;  $r$  = Pearson-Korrelation zwischen CV und EyeLink; Steigung = Regressionsgewicht; Bias = Intercept der Regression; MAE = Mean Absolute Error;  $SD$  = Standardabweichung über Versuchspersonen. 25 Hz = Systemkamera; 60 Hz = Webcam.


In den Daten zeigen sich außerdem mehrere Muster, die durch die nachfolgende Inferenzstatistik auf ihre Generalisierbarkeit geprüft werden: Die Korrelationen und Steigungswerte fallen bei der Systemkamera (25 Hz) durchgängig höher aus als bei der Webcam (60 Hz). Bei der Systemkamera erreicht PTGaze höhere Steigungswerte als MediaPipe; bei der Webcam sind die Unterschiede zwischen beiden Methoden geringer. Die Differenzen zwischen vollständiger und reduzierter Kalibrierung innerhalb derselben Methoden-Kamera-Kombination sind gering – die Korrelationen unterscheiden sich maximal um .01, die *MAE*-Werte um weniger als  $0.05^\circ$  Schwinkel. Die mittlere horizontale Blickposition ( $X_{CV}$ ) lag über alle Bedingungen nahe null ( $0.00^\circ$  bis  $0.36^\circ$  Schwinkel). Dies entspricht dem erwarteten Muster bei einer gesunden Stichprobe ohne systematische Blickverlagerung und deutet darauf hin, dass die CV-Pipelines bei zentraler Blickposition keinen bedeutsamen systematischen Offset produzieren.

Abbildung 4 visualisiert die globalen Validierungsmetriken – gemittelt über alle Bedingungen. Die farbigen Punkte repräsentieren die zwölf VP-Mittelwerte und verdeutlichen zwei Aspekte: Zum einen streuen sie um den Gruppenmittelwert, was zeigt, dass die verwendeten Stimulusbilder unterschiedliche Explorationsmuster evozieren – eine Voraussetzung für die FVE-Diagnostik, die auf der Erfassung individueller Blickmuster basiert. Zum anderen wird die Abweichung vom Idealwert sichtbar: Die gestrichelten Referenzlinien markieren perfekte Übereinstimmung (Korrelation = 1, Steigung = 1, Bias =  $0^\circ$  Schwinkel), und die Distanz der empirischen Werte zu diesen Linien zeigt das theoretische Verbesserungspotenzial der CV-Pipelines.

Ob die deskriptiv beobachteten Unterschiede zwischen Methoden, Kameras und Kalibrierungsvarianten über die zufällige Stichprobenvariabilität hinausgehen, prüft die nachfolgende Inferenzstatistik.

## Abbildung 4

### Globale Validierungsmetriken über alle Bedingungen



*Anmerkung.*  $N = 12$ . Dargestellt sind die über alle acht Bedingungskombinationen gemittelten Validierungsmetriken: Korrelation zwischen CV-Schätzung und EyeLink-Referenz, Steigung der Regression  $CV \sim \text{EyeLink}$ , Bias (Intercept der Regression). Jeder farbige Punkt repräsentiert den Mittelwert einer Versuchsperson (VP 1–12), gemittelt über alle Bedingungen. Der rote Punkt mit Fehlerbalken zeigt den Gruppenmittelwert mit 95 %-Konfidenzintervall. Die gestrichelten Referenzlinien markieren die Idealwerte:  $r = 1$  (perfekte Übereinstimmung), Steigung = 1 (proportionale Abbildung), Bias =  $0^\circ$  (kein systematischer Offset). Die Streuung der VP-Punkte um den Mittelwert reflektiert sowohl interindividuelle Unterschiede im Blickverhalten als auch die durch die Stimulusbilder evozierte Varianz.

## Inferenzstatistik

Zur inferenzstatistischen Prüfung der Übereinstimmung zwischen CV-Pipelines und EyeLink wurden für jede der drei abhängigen Variablen lineare gemischte Modelle (LMM) auf Basis der Trial-Level-Metriken berechnet. Da alle Prädiktoren kategorial und zweistufig sind, werden zur Prüfung der Fixed Effects F-Tests (Typ III) mit der Satterthwaite-Approximation für die Nenner-Freiheitsgrade berichtet (Luke, 2017; Meteyard & Davies, 2020). Die vollständigen Parameterschätzungen sind in Tabelle 2 dokumentiert. Da Sum-to-Zero Kontraste verwendet wurden, repräsentieren die Koeffizienten die Abweichung jeder Faktorstufe vom Gesamtmittel; für die inhaltliche Interpretation der Gruppenunterschiede werden daher die geschätzten Randmittel (EMMs) herangezogen.

## Korrelation

Die Korrelation zwischen CV-Schätzung und EyeLink-Messung bildet die zentrale Metrik dieser Studie: Sie erfasst, wie präzise die CV-Pipelines die tatsächlichen Blickbewegungen abbilden. Ein Wert von  $r = 1$  würde perfekte Übereinstimmung anzeigen; niedrigere Werte deuten auf erhöhtes Rauschen oder systematische Abweichungen hin (siehe Abschnitt Abhängige Variablen).

**Modellselektion Fixed Effects.** Ausgehend vom vollständigen Modell mit Drei-Wege-Interaktion wurden schrittweise nicht-signifikante Terme entfernt. Der Vergleich des Modells mit versus ohne Drei-Wege-Interaktion (Methode  $\times$  Kamera  $\times$  Kalibrierung) zeigte, dass diese nicht zur Modellpassung beitrug,  $\chi^2(1) = 0.12$ ,  $p = .729$ ,  $\Delta\text{AIC} = -2.1$ . Anschließend wurden die Zwei-Wege-Interaktionen geprüft: Die Methode  $\times$  Kamera-Interaktion verbesserte die Modellpassung signifikant gegenüber dem Haupteffekte-Modell,  $\chi^2(1) = 14.38$ ,  $p < .001$ ,  $\Delta\text{AIC} = -12.4$ , während die verbleibenden Interaktionen (Methode  $\times$  Kalibrierung, Kamera  $\times$  Kalibrierung) keinen zusätzlichen Beitrag leisteten,  $\chi^2(2) = 0.31$ ,  $p = .855$ ,  $\Delta\text{AIC} = 3.7$ . Das finale Fixed-Effects-Modell enthielt daher die Methode  $\times$  Kamera-Interaktion sowie den Haupteffekt der Kalibrierung.

**Modellselektion Random Effects.** Die Auswahl der Random-Effects-Struktur erfolgte nach dem im Abschnitt Datenauswertung beschriebenen schrittweisen Vorgehen, statend mit dem maximalen Modell. Da komplexere Modelle (mehrere Random Slopes mit Korrelationen) bei der vorliegenden Stichprobengröße ( $N = 12$ ) nicht konvergierten oder singuläre Fits produzierten, wurden die Random Slopes einzeln getestet. Der Vergleich eines Modells mit Random Slope für Kamera gegen das Random-Intercept-Only-Modell zeigte eine signifikante Verbesserung,  $\chi^2(2) = 28.25$ ,  $p < .001$ ,  $\Delta\text{AIC} = -25.7$ . Dies deutet darauf hin, dass der Kameraeffekt zwischen Versuchspersonen variiert – ein inhaltlich plausibler Befund, da individuelle Faktoren wie Gesichtsgeometrie oder Brillentyp die Empfindlichkeit gegenüber Bildqualität modulieren könnten.

**Ergebnisse.** Das finale Modell ( $r_z \sim \text{Methode} \times \text{Kamera} + \text{Kalibrierung} + (1 + \text{Kamera} | \text{VP})$ ) zeigte signifikante Effekte für Methode,  $F(1, 2277) = 14.00$ ,  $p < .001$ , Kamera,  $F(1, 11) = 338.61$ ,  $p < .001$ , und die Methode  $\times$  Kamera-Interaktion,  $F(1, 2277) = 14.70$ ,  $p < .001$ . Die Kalibrierung hatte hingegen keinen signifikanten Einfluss,  $F(1, 2277) = 0.44$ ,  $p = .506$  (siehe Tabelle 2 für Parameterschätzungen und Abbildung 5A für die grafische Darstellung der Haupteffekte).

Die Fixed Effects erklärten 35.7 % der Varianz ( $R_m^2 = .357$ ), unter Einbezug der Random Effects 55.5 % ( $R_c^2 = .555$ ). Dies zeigt, dass die experimentellen Faktoren – insbesondere Methode und Kamera – einen substanziellen Anteil der Varianz in der Korrelation aufklären. Gleichzeitig gehen knapp 20 Prozentpunkte der erklärten Varianz auf interindividuelle Unterschiede zurück, was die Bedeutung personenspezifischer Faktoren für die Präzision der Blickerfassung unterstreicht.

Die F-Tests zeigen, dass Methode, Kamera und deren Interaktion die Korrelation signifikant beeinflussen – welche Faktorstufen überlegen sind und wie groß die praktischen Unterschiede ausfallen, klären die nachfolgenden Post-hoc-Analysen. Die signifikante Interaktion erforderte dabei eine Aufschlüsselung der Haupteffekte mittels Simple-Effects-Analysen (siehe Tabelle 3 und Abbildung 6). Bei der Systemkamera erreichte PTGaze ( $EMM = 1.65$ , 95 %-KI [1.48, 1.81], entspricht  $r = .93$ ) eine signifikant höhere Korrelation als MediaPipe ( $EMM = 1.52$ , 95 %-KI [1.36, 1.69], entspricht  $r = .91$ ),  $\Delta z = 0.13$ ,  $t(2277) = 5.36$ ,  $p < .001$ ,  $g = 0.32$ . Beide Werte liegen allerdings nahe dem Idealwert von 1. Das bedeutet, dass unter dieser Bedingung beide Methoden die Blickbewegungen zuverlässig erfassen, wobei PTGaze einen kleinen, aber konsistenten Vorteil zeigt. Bei der Webcam hingegen verschwand der Methodenunterschied (MediaPipe:  $EMM = 0.86$ , 95 %-KI [0.68, 1.05],  $r = .70$ ; PTGaze:  $EMM = 0.86$ , 95 %-KI [0.68, 1.05],  $r = .70$ ),  $t(2277) = 0.07$ ,  $p = .948$ .

Dieser Kontrast verdeutlicht die zentrale Bedeutung der Bildqualität: Die Präzision sinkt bei der Webcam von  $r > .90$  auf  $r = .70$  – ein erheblicher Rückgang, der zeigt, dass selbst leistungsfähigere Algorithmen bei unzureichender Bildqualität keine besseren Ergebnisse erzielen können. Beide Methoden profitierten signifikant von der Systemkamera, wobei PTGaze den größeren Gewinn verzeichnete ( $\Delta z = 0.79$ ,  $t(15.5) = 18.41$ ,  $p < .001$ ,  $g = 1.94$ ) als MediaPipe ( $\Delta z = 0.66$ ,  $t(15.5) = 15.37$ ,  $p < .001$ ,  $g = 1.62$ ).

Die leicht negative Korrelation zwischen Random Intercept und Random Slope ( $r = -.28$ ) deutet zusätzlich darauf hin, dass Versuchspersonen mit einer bereits hohen Baseline-Korrelation tendenziell einen etwas geringeren Kameravorteil zeigten. Dieser Zusammenhang ist jedoch schwach ausgeprägt und sollte angesichts der kleinen Stichprobe zurückhaltend interpretiert werden. Trotz dieser interindividuellen Variabilität war die Richtung des Kameraeffekts konsistent – alle 12 Versuchspersonen erreichten mit der Systemkamera höhere Korrelationswerte als mit der Webcam.

**Robustheitscheck.** Die ergänzende rm-ANOVA auf VP-Ebene bestätigte das Muster: Haupteffekt Kamera,  $F(1, 11) = 338.62, p < .001, \eta_p^2 = .97$ ; Haupteffekt Methode,  $F(1, 11) = 22.97, p < .001, \eta_p^2 = .68$ ; Methode  $\times$  Kamera-Interaktion,  $F(1, 11) = 59.73, p < .001, \eta_p^2 = .84$ . Zusätzlich zeigte die rm-ANOVA einen signifikanten Effekt für die Kalibrierung,  $F(1, 11) = 6.09, p = .031, \eta_p^2 = .36$ , der im LMM nicht auftrat ( $p = .506$ ).

**Tabelle 2**

*Parameterschätzungen und Modellgüte der finalen linearen gemischten Modelle*

| Effect                         | Parameter       | Korrelation     | Steigung        | Bias            |
|--------------------------------|-----------------|-----------------|-----------------|-----------------|
| Fixed effects                  |                 |                 |                 |                 |
| Intercept                      | $\gamma_{00}$   | 1.22*** (0.08)  | 0.68*** (0.03)  | 0.07 (0.31)     |
| Methode                        | $\gamma_{10}$   | -0.06*** (0.02) | -0.14*** (0.01) | 0.21 (0.34)     |
| Kamera                         | $\gamma_{20}$   | 0.72*** (0.04)  | 0.28*** (0.04)  | -0.16 (0.09)    |
| Kalibrierung                   | $\gamma_{30}$   | 0.01 (0.02)     | 0.02* (0.01)    | -0.03 (0.09)    |
| Methode $\times$ Kamera        | $\gamma_{12}$   | -0.13*** (0.03) | -               | -               |
| Random effects                 |                 |                 |                 |                 |
| Level 1 (Residual)             | $\sigma_e^2$    | 0.166           | 0.047           | 4.977           |
| Level 2 (VP)                   | $\sigma_{u0}^2$ | 0.070           | 0.012           | 1.153           |
| Random Slope                   | $\sigma_{u1}^2$ | 0.015 (Kamera)  | 0.017 (Kamera)  | 1.271 (Methode) |
| Korrelation (intercept, slope) | $r_{u01}$       | -.28            | -.38            | .91             |
| Goodness of fit                |                 |                 |                 |                 |
| Marginal $R^2$                 | $R_m^2$         | .357            | .277            | .003            |
| Conditional $R^2$              | $R_c^2$         | .555            | .465            | .230            |

Anmerkung.  $N = 12$ . Standardfehler stehen in Klammern. Korrelation, Steigung und Bias beziehen sich auf die Validierungsmetriken der horizontalen Blickachse.  $\gamma_{00}$  = Intercept (Gesamtmittel);  $\gamma_{10}$ – $\gamma_{30}$  = Fixed-Effects-Koeffizienten;  $\gamma_{12}$  = Interaktionskoeffizient;  $\sigma_e^2$  = Residualvarianz;  $\sigma_{u0}^2$  = Varianz des Random Intercepts (Level 2);  $\sigma_{u1}^2$  = Varianz der Random Slopes;  $r_{u01}$  = Korrelation zwischen Random Intercept und Random Slope.  $R_m^2$  = durch Fixed Effects erklärte Varianz;  $R_c^2$  = durch das Gesamtmodell erklärte Varianz; \* $p < .05$ . \*\* $p < .01$ . \*\*\* $p < .001$ .

Diese Diskrepanz könnte sich durch die unterschiedliche Datenstruktur erklären: Die rm-ANOVA testet auf VP-Ebene mit aggregierten Daten, das LMM berücksichtigt die vollständige Trial-Level-Varianz und schätzt Freiheitsgrade konservativer. Der LMM-Befund ist daher als belastbarer einzustufen.

Zusammenfassend hängt die Präzision der Blickerfassung primär von der Kameraqualität ab. Unter optimalen Bedingungen (Systemkamera) erreichen beide CV-Methoden eine

hohe Übereinstimmung mit dem Referenzsystem ( $r > .90$ ), wobei PTGaze einen kleinen, aber signifikanten Vorteil zeigt. Bei der Webcam sinkt die Präzision auf ein moderates Niveau ( $r = .70$ ), und der Methodenunterschied verschwindet vollständig.

### **Steigung**

Neben der Korrelation ist für die Anwendung entscheidend, ob die CV-Pipelines die Amplitude der Blickbewegungen korrekt abbilden. Die Steigung der Regression (CV ~ EyeLink) quantifiziert diesen Verstärkungsfaktor: Der Idealwert von 1 würde perfekte Amplitudenübereinstimmung anzeigen, Werte darunter bedeuten, dass periphere Blickpositionen zur Bildschirmmitte hin komprimiert werden (siehe Abschnitt Abhängige Variablen).

**Modellselektion Fixed Effects.** Die schrittweise Modellselektion zeigte ein einfacheres Muster als bei der Korrelation: Der Vergleich des Modells mit versus ohne Drei-Wege-Interaktion ergab keine Verbesserung,  $\chi^2(1) = 0.01$ ,  $p = .920$ ,  $\Delta AIC = 2.0$ . Ebenso leisteten die Zwei-Wege-Interaktionen keinen signifikanten Beitrag gegenüber dem Haupteffekte-Modell,  $\chi^2(3) = 0.74$ ,  $p = .864$ ,  $\Delta AIC = 5.3$ . Das finale Fixed-Effects-Modell enthielt daher nur die drei Haupteffekte.


**Modellselektion Random Effects.** Analog zum Vorgehen bei der Korrelation wurden die Random Slopes einzeln getestet. Der Vergleich eines Modells mit Random Slope für Kamera gegen das Random-Intercept-Only-Modell zeigte eine hochsignifikante Verbesserung,  $\chi^2(2) = 145.92$ ,  $p < .001$ ,  $\Delta AIC = -144.4$ . Dies deutet auf interindividuelle Unterschiede im Kameraeffekt hin.

**Ergebnisse.** Das finale Modell (Steigung ~ Methode + Kamera + Kalibrierung + (1 + Kamera | VP)) zeigte signifikante Haupteffekte für alle drei Faktoren: Methode,  $F(1, 2278) = 224.57$ ,  $p < .001$ ; Kamera,  $F(1, 11) = 53.84$ ,  $p < .001$ ; Kalibrierung,  $F(1, 2278) = 4.16$ ,  $p = .042$  (siehe Tabelle 2 und Abbildung 5B).

Die Fixed Effects erklärten 27.7 % der Varianz ( $R_m^2 = .277$ ), unter Einbezug der Random Effects 46.5 % ( $R_c^2 = .465$ ). Die experimentellen Faktoren – vor allem Methode und Kamera – erklären damit gut ein Viertel der Varianz in der Steigung. Ähnlich wie bei der Korrelation tragen auch hier interindividuelle Unterschiede substanziell zur Varianzaufklärung bei: Knapp 19 Prozentpunkte der erklärten Varianz entfallen auf die Personenebene.

## Abbildung 5


Haupteffekte der linearen gemischten Modelle für Korrelation, Steigung und Bias



Anmerkung.  $N = 12$ . Alle Metriken beziehen sich auf die horizontale Blickachse. Dargestellt sind die Ergebnisse für (A) Korrelation, (B) Steigung und (C) Bias, jeweils aufgeschlüsselt nach Methode, Kamera und Kalibrierung. Jeder farbige Punkt repräsentiert den Mittelwert einer Versuchsperson, gemittelt über alle Trials der jeweiligen Faktorstufe. Die blaue horizontale Linie markiert den beobachteten Gruppenmittelwert. Die roten Punkte mit Fehlerbalken rechts neben den Violins zeigen die EMM mit 95 %-KI. Gestrichelte Referenzlinien: Bias =  $0^\circ$  (kein systematischer Offset bei zentraler Blickposition), Steigung = 1 (perfekte Verstärkung), Korrelation = 1 (perfekte Übereinstimmung). \* $p < .05$ . \*\* $p < .01$ . \*\*\* $p < .001$ , ns = nicht signifikant.

## Abbildung 6

*Methode × Kamera Interaktion für die Korrelation*



*Anmerkung.*  $N = 12$ . Dargestellt ist die signifikante Methode  $\times$  Kamera Interaktion für die Korrelation (Präzision). Jeder farbige Punkt repräsentiert den Mittelwert einer Versuchsperson (VP 1-12), gemittelt über beide Kalibrierungsbedingungen. Die blaue horizontale Linie markiert den beobachteten Gruppenmittelwert pro Zelle. Die roten Punkte mit Fehlerbalken zeigen die EMM mit 95 %-KI. Die gestrichelte Linie bei  $r = 1$  markiert perfekte Übereinstimmung.

Im Gegensatz zur Korrelation zeigt sich bei der Steigung keine signifikante Interaktion – alle drei Faktoren wirken additiv. Die nachfolgenden Paarvergleiche quantifizieren Größe und praktische Bedeutung dieser Haupteffekte (siehe Tabelle 3). PTGaze ( $EMM = 0.75$ , 95 %-KI [0.68, 0.82]) zeigte eine signifikant höhere Steigung als MediaPipe ( $EMM = 0.61$ , 95 %-KI [0.54, 0.69]),  $\Delta = 0.14$ ,  $t(2278) = 14.99$ ,  $p < .001$ , Hedges'  $g = 0.62$ . Beide Werte liegen unter dem Idealwert von 1, was eine systematische Unterschätzung der Blickpositionsamplituden durch beide CV-Pipelines anzeigt – die geschätzten Blickpositionen werden zur Bildschirmmitte hin komprimiert. Diese Kompression fällt bei PTGaze jedoch geringer aus (25 % Unterschätzung vs. 39 % bei MediaPipe), was auf eine akkuratere Erfassung peripherer Blickpositionen hindeutet.

Der Kameraeffekt war noch ausgeprägter: Die Systemkamera ( $EMM = 0.82$ , 95 %-KI [0.75, 0.89]) übertraf die Webcam ( $EMM = 0.54$ , 95 %-KI [0.45, 0.64]) deutlich,  $\Delta = 0.28$ ,  $t(11) =$

7.34,  $p < .001$ , Hedges'  $g = 1.29$ . Konkret bedeutet dies: Die Systemkamera ermöglichte eine Amplitudenabbildung von 82 % – periphere Blickpositionen bei 10° Schwinkel wurden also im Mittel als etwa 8.2° Schwinkel registriert. Bei der Webcam betrug dieser Wert nur 54 %, was einer nahezu halbierten Abbildung peripherer Blickpositionen entspricht.

Die Kalibrierung zeigte einen statistisch signifikanten, aber praktisch vernachlässigbaren Effekt: Die volle Kalibrierung ( $EMM = 0.69$ , 95 %-KI [0.62, 0.76]) führte zu einer geringfügig höheren Steigung als die reduzierte ( $EMM = 0.67$ , 95 %-KI [0.60, 0.74]),  $\Delta = 0.02$ ,  $t(2278) = 2.04$ ,  $p = .041$ , Hedges'  $g = 0.08$ . Eine aufwendigere Kalibrierung verbessert die Steigung also kaum.

Die moderate negative Korrelation zwischen Random Intercept und Random Slope ( $r = -.38$ ) weist auf einen Deckeneffekt hin: Versuchspersonen mit bereits hoher Steigung profitierten weniger vom Wechsel zur Systemkamera. Personen, deren Blickbewegungen bereits gut erfasst werden, haben also weniger Verbesserungspotenzial durch höhere Bildqualität.

**Tabelle 3**

*Paarweise Post-hoc-Vergleiche und Simple Effects für signifikante Effekte*

| AV          | Effekt          | $\Delta$ | SE    | 95 % KI        | $t$    | $df$   | $p$    | $g$   |
|-------------|-----------------|----------|-------|----------------|--------|--------|--------|-------|
| Steigung    | Methode         | -0.135   | 0.009 | [-0.15, -0.12] | -14.99 | 2278.0 | < .001 | -0.62 |
|             | Kamera          | 0.280    | 0.038 | [0.21, 0.36]   | 7.34   | 11.0   | < .001 | 1.29  |
|             | Kalibrierung    | 0.018    | 0.009 | [0.00, 0.04]   | 2.04   | 2278.0 | .041   | 0.08  |
| Korrelation | Method   Kamera | -0.129   | 0.024 | [-0.18, -0.08] | -5.36  | 2277.0 | < .001 | -0.32 |
|             |                 | 0.002    | 0.024 | [-0.05, 0.05]  | 0.07   | 2277.0 | .948   | 0.00  |
|             | Kamera   Method | 0.659    | 0.043 | [0.57, 0.74]   | 15.37  | 15.5   | < .001 | 1.62  |
|             |                 | 0.789    | 0.043 | [0.71, 0.87]   | 18.41  | 15.5   | < .001 | 1.94  |

Anmerkung.  $N = 12$ . Alle Kennwerte beziehen sich auf die horizontale Blickachse. AV = abhängige Variable;  $\Delta$  = mittlere Differenz; SE = Standardfehler; KI = Konfidenzintervall;  $g$  = Hedges'  $g$ . Kontraste: Methode = MediaPipe – PTGaze; Kamera = 25 Hz – 60 Hz; Kalibrierung = Voll – Reduziert. Bei Simple Effects („|“) entspricht obere Zeile der ersten Stufe des Bedingungsfaktors (Systemkamera bzw. MediaPipe) und die untere Zeile der zweiten Stufe (Webcam bzw. PTGaze). Freiheitsgrade wurden nach Kenward-Roger approximiert. Effektstärken: |.2| klein, |.5| mittel, |.8| groß (Cohen, 2013).

**Robustheitscheck.** Die rm-ANOVA bestätigte die Haupteffekte: Methode,  $F(1, 11) = 15.01$ ,  $p = .003$ ,  $\eta_p^2 = .58$ ; Kamera,  $F(1, 11) = 53.84$ ,  $p < .001$ ,  $\eta_p^2 = .83$ ; Kalibrierung,  $F(1, 11) = 7.26$ ,  $p = .021$ ,  $\eta_p^2 = .40$  (siehe Tabelle B1). Ein abweichender Befund betrifft die Drei-

Wege-Interaktion: Diese erreichte in der rm-ANOVA Signifikanz,  $F(1, 11) = 6.82, p = .024$ ,  $\eta_p^2 = .38$ , nicht jedoch im LMM. Angesichts der kleinen Stichprobe und der marginalen Signifikanz sollte dieser Befund jedoch zurückhaltend interpretiert werden – eine Replikation in größeren Stichproben wäre erforderlich.

Zusammenfassend unterschätzen beide CV-Pipelines die Blickpositionsamplituden systematisch, wobei PTGaze und die Systemkamera diese Tendenz zur Mitte deutlich reduzieren. Die Kalibrierungskomplexität spielt hingegen eine untergeordnete Rolle.

### **Bias**

Abschließend wurde geprüft, ob die CV-Pipelines bei zentraler Blickposition einen systematischen Versatz aufweisen. Der Bias entspricht dem Intercept der Regression ( $CV \sim \text{EyeLink}$ ) und quantifiziert die Abweichung der CV-Schätzung bei Fixation der Bildschirmmitte ( $\text{EyeLink} = 0^\circ$  Schwinkel). Ein Wert nahe null bedeutet, dass kein systematischer Offset vorliegt; positive Werte zeigen eine Verschiebung nach rechts, negative nach links an (siehe Abschnitt Abhängige Variablen).

**Modellselektion Fixed Effects.** Die Modellselektion ergab das einfachste Muster aller drei AVs: Der Vergleich des Modells mit versus ohne Drei-Wege-Interaktion zeigte keine Verbesserung,  $\chi^2(1) = 0.76, p = .384, \Delta\text{AIC} = 1.2$ . Ebenso leisteten die Zwei-Wege-Interaktionen keinen Beitrag,  $\chi^2(3) = 0.68, p = .879, \Delta\text{AIC} = 5.3$ . Das finale Fixed-Effects-Modell enthielt nur die drei Haupteffekte.

**Modellselektion Random Effects.** Anders als bei Korrelation und Steigung erwies sich hier ein Random Slope für Methode (nicht Kamera) als optimal. Der Vergleich gegen das Random-Intercept-Only-Modell zeigte eine hochsignifikante Verbesserung,  $\chi^2(2) = 116.79, p < .001, \Delta\text{AIC} = -113.8$ . Dies deutet darauf hin, dass der Methodeneffekt auf den Bias zwischen Versuchspersonen stärker variiert als der Kameraeffekt – ein Hinweis auf individuelle Unterschiede in der Reaktion auf die CV-Methode.

**Ergebnisse.** Das finale Modell ( $\text{Bias} \sim \text{Methode} + \text{Kamera} + \text{Kalibrierung} + (1 + \text{Methode} | \text{VP})$ ) zeigte keine signifikanten Haupteffekte: Methode,  $F(1, 11) = 0.40, p = .540$ ; Kamera,  $F(1, 2278) = 2.79, p = .095$ ; Kalibrierung,  $F(1, 2278) = 0.11, p = .735$  (siehe Tabelle 2 und Abbildung 5C).

Die Fixed Effects erklärten lediglich 0.3 % der Varianz ( $R_m^2 = .003$ ), während unter Einbezug der Random Effects 23.0 % erklärt wurden ( $R_c^2 = .230$ ). Dieses Muster unterscheidet

sich von Korrelation und Steigung: Der Bias wird wahrscheinlich primär durch interindividuelle Unterschiede bestimmt – nicht durch die experimentellen Faktoren. Manche Versuchspersonen zeigen einen leichten Rechtsversatz, andere einen Linksversatz, aber diese Muster scheinen weder von der CV-Methode noch von Kamera oder Kalibrierung abzuhängen.

Da keine signifikanten Haupteffekte vorliegen, erübrigen sich Post-hoc-Paarvergleiche. Der marginale Kameratrend deutet auf einen tendenziell niedrigeren Bias bei der Systemkamera hin, der Unterschied war jedoch nicht statistisch abzusichern ( $p = .095$ ) und praktisch vernachlässigbar ( $\Delta < 0.3^\circ$  Schwinkel).

Die hohe Random-Intercept-Varianz ( $\sigma^2_{\text{no}} = 1.15$ ) und die starke positive Korrelation zwischen Random Intercept und Random Slope ( $r = .91$ ) legen nahe, dass Versuchspersonen mit höherem durchschnittlichem Bias auch größere Methodenunterschiede aufwiesen. Möglicherweise verstärken individuelle Faktoren (z. B. Gesichtsgeometrie, Brillentyp), die den Bias generell erhöhen, auch die Sensitivität gegenüber der Methodenwahl.

**Robustheitscheck.** Die rm-ANOVA bestätigte das Ausbleiben signifikanter Effekte: Methode,  $F(1, 11) = 0.40$ ,  $p = .540$ ,  $\eta_p^2 = .04$ ; Kamera,  $F(1, 11) = 1.53$ ,  $p = .241$ ,  $\eta_p^2 = .12$ ; Kalibrierung,  $F(1, 11) = 0.03$ ,  $p = .857$ ,  $\eta_p^2 = .00$ . Auch die Interaktionen erreichten keine Signifikanz (alle  $p > .40$ ; siehe Tabelle B1). Die Konsistenz zwischen LMM und rm-ANOVA unterstreicht die Robustheit dieses Nullbefunds.


Zusammenfassend wird der systematische Fehler von den untersuchten Faktoren kaum beeinflusst und geht vermutlich primär auf interindividuelle Unterschiede zurück. Da der Bias über alle Bedingungen hinweg nahe null liegt ( $-0.15^\circ$  bis  $0.28^\circ$  Schwinkel), ist keine systematische Verzerrung durch die experimentellen Faktoren zu erwarten.

### **Interindividuelle Unterschiede**

Die vorangegangenen Analysen zeigen konsistente Effekte von Methode und Kamera auf die Übereinstimmung zwischen CV-Pipelines und EyeLink. Für eine potenzielle klinische Anwendung ist jedoch nicht nur das durchschnittliche Leistungsniveau relevant, sondern auch die Frage, unter welchen individuellen Bedingungen die Blickerfassung problematisch werden kann.

## Abbildung 7

### Zeitreihen der X-Koordinaten für alle zwölf Versuchspersonen



*Anmerkung.* Dargestellt ist jeweils ein vollständiges Trial pro Versuchsperson. Die schwarze Linie zeigt die EyeLink-Referenzmessung, die rote Linie die MediaPipe-Schätzung und die blaue Linie die PTGaze-Schätzung. Grau schattierte Bereiche markieren detektierte Blinks. Die Hintergrundfarben kennzeichnen die Versuchsphasen (grün = Fixation, blau = Stimulus). Einheit X-Achse = Millisekunden; Einheit Y-Achse = ° Sehwinkel

Da die Stichprobe gezielt aus Personen im Alter typischer Schlaganfallpatienten ( $M = 66$  Jahre) rekrutiert wurde, ermöglicht die Einzelfallbetrachtung eine erste Einschätzung möglicher Herausforderungen bei der klinischen Zielpopulation. Abbildung 7 zeigt exemplarisch ausgewählte Zeitreihen der horizontalen Blickposition für alle zwölf Versuchspersonen.

Bei VP 5, VP 6, VP 7, VP 9 und VP 12 zeigten sich keine Auffälligkeiten. Insbesondere mit PTGaze und der Systemkamera war auch visuell eine hohe Übereinstimmung mit den EyeLink-Daten erkennbar (siehe Abbildung 7). Diese Versuchspersonen repräsentieren den „Idealfall“ für CV-basierte Blickerfassung bei älteren Erwachsenen. Bei VP 1 hingegen traten während des Experiments, vermutlich aufgrund einer Bifokalbrille, Pupillenerfassungsprobleme mit dem EyeLink auf. VP 1 war die einzige Person, bei der lediglich eine 3-Punkt-Kalibrierung des Referenzsystems sinnvoll umsetzbar war. Das zugehörige Panel ist aber eher unauffällig. Bei VP 4 kam nur eine 5-Punkt-Kalibrierung des EyeLink zum Einsatz. Besonders beim Blick in den oberen rechten Bildschirmbereich trat wiederholt Erfassungsverlust auf. Gleichzeitig verdeutlicht das entsprechende Panel in Abbildung 7 die beeinträchtigte Synchronisation zwischen CV und EyeLink infolge der stark beschädigten Audiomarker (siehe Abschnitt Synchronisation in der Einleitung). Bei VP 2 kam es ebenfalls zu Verzerrungen im oberen und unteren rechten Bereich; auch hier wurde nur eine 5-Punkt-Kalibrierung durchgeführt. Bei VP 10 wurde die Bildschirmmitte durch den EyeLink tendenziell etwas zu niedrig verortet, wobei sich bei den X-Werten – der für die FVE-Diagnostik relevanten horizontalen Achse – keine größeren Auffälligkeiten zeigten. VP 3 musste während des Versuchsablaufs überdurchschnittlich häufig blinzeln, wodurch der EyeLink wiederholt das getrackte Auge verlor und die Datenqualität entsprechend litt. In Abbildung 7 wird die mit dem EyeLink synchrone Blink-Detektion der CV-Pipelines gut sichtbar (grau schattierte Bereiche). Bemerkenswert ist, dass die CV-Pipelines während der Datenverlustphasen des EyeLink eine fortlaufend plausible Blickdetektion zeigten – ein Hinweis auf eine möglicherweise erhöhte Robustheit der CV-Methoden gegenüber kurzzeitigen Signalverlusten. Ein ähnliches Muster zeigte VP 11: Nach einer suboptimalen EyeLink-Kalibrierung

kam es durch häufiges Blinzeln wiederholt zum Pupillenverlust. Bei der Videokalibrierung zeigten sich sowohl auf der Y-Achse als auch auf der X-Achse Verzerrungen. Während PTGaze mit der eingeschränkten Kalibrierungsqualität zurechtkam, lässt sich bei MediaPipe ein deutlicher Rechtsversatz feststellen – besonders während der Fixationskreuzphasen. Ein Grund dafür könnten die getragenen Keratokoniuslinsen gewesen sein. Dieser Befund deutet auf eine höhere Robustheit von PTGaze gegenüber suboptimalen Kalibrierungsbedingungen hin. Bei VP 8 kam es während der Fixationskreuzphasen immer wieder zu Blickbewegungen. Bei Trial 21 trat ein Pupillenverlust durch den EyeLink auf. Die letzte Videokalibrierungsphase zeigte eine eingeschränkte Fixationskreuzverfolgung – möglicherweise traten hier Ermüdungserscheinungen durch die wiederholte Kalibrierung auf. Dadurch bedingt könnten die Fixationskreuzphasen zum „Ausruhen der Augen“ genutzt worden sein. Sichtbar wird außerdem erneut die Anfälligkeit von MediaPipe bei weniger präzisen Kalibrierungen (systematische Verlagerung nach rechts).

Insgesamt zeigen diese Einzelfallbeobachtungen, dass die CV-basierte Blickerfassung bei der Mehrheit der älteren Versuchspersonen zuverlässig funktioniert, jedoch bei bestimmten individuellen Faktoren – insbesondere Sehhilfen und suboptimalen EyeLink-Kalibrierungen – Einschränkungen auftreten können.

### **Explorative Analyse**

Ergänzend zur Hauptstichprobe wurde eine einzelne Neglect-Patientin (siehe Methoden) explorativ untersucht – dieselbe Person, mit der die neglectspezifische Kalibrierungsstrategie entwickelt wurde (vgl. Abschnitt „Kalibrierungsstrategie“ in der Einleitung). Einerseits wurde ein vollständiger Versuchsablauf durchgeführt. Andererseits wurde zusätzlich die Videokalibrierung evaluiert. Diese Daten sind nicht Teil der inferenzstatistischen Analyse, liefern jedoch erste Anhaltspunkte zur Anwendbarkeit der CV-Pipeline bei Patienten mit dem charakteristischen Neglect-Blickmuster.

Extrahiert direkt aus dem Python-Output zeigt die Patientin nach Auswertung der Daten für den normalen Versuchsablauf das für einen rechtshemisphärischen Neglect typische ipsiläsionale Verlagerungsmuster mit einer über alle Trials mittleren horizontalen Blickposition von  $5.52^\circ$  Schwinkel nach rechts im EyeLink-Referenzsystem. Auch beide CV-Pipelines erfassten auf Basis eines Videos der Systemkamera (es wurde kein Webcamvideo aufgezeichnet) dieses Muster: PTGaze erreichte eine Korrelation von  $r = .92$  mit dem EyeLink und eine mittlere Blickposition von  $4.12^\circ$  Schwinkel, MediaPipe eine Korrelation von  $r =$

.86 und eine mittlere Position von  $4.30^\circ$  Sehwinkel. Der *MAE* lag bei  $1.52^\circ$  Sehwinkel (PTGaze) bzw.  $1.75^\circ$  Sehwinkel (MediaPipe) und damit im Bereich der besten Bedingungen der gesunden Stichprobe. Alle drei Methoden überschreiten damit den diagnostischen Cutoff von  $1.333^\circ$  Sehwinkel (Kaufmann et al., 2020) deutlich.

### **Graphische Analyse der Kalibrierungsparameter**

Die Qualität der Videokalibrierung wurde in einem zweiten Schritt evaluiert. Die graphische Analyse der EyeLink-Daten (Abbildung B1) zeigt einen sichtbaren Zusammenhang zwischen Zielgeschwindigkeit und Verfolgungsqualität. Bei der niedrigsten Geschwindigkeit (200 px/s) folgt der Blickverlauf dem vorgegebenen Pfad weitgehend kontinuierlich mit meistens eng um die Sollpositionen gruppierten Blickpositionen (vor allem bei Start rechts unten). Bei mittleren Geschwindigkeiten (300–400 px/s) treten vereinzelt Abweichungen auf, insbesondere bei Richtungswechseln an den Eckpunkten des linken Kalibrierungsrasters. Bei der höchsten Geschwindigkeit (500 px/s) zeigen sich deutliche Verfolgungsdefizite: Der Blick verliert wiederholt den Kontakt zum Ziel, gefolgt von unstrukturierten Suchsakkaden bis zur Wiederaufnahme der Verfolgung. Besonders ausgeprägt sind diese Schwierigkeiten im linken Bildschirmbereich, wo mehrfach großflächige explorative Augenbewegungen erkennbar sind. Die Startrichtung (links oben vs. rechts unten) scheint einen leichten Einfluss auf die Verfolgungsqualität zu haben. Tendenziell zeigen die Durchgänge mit Startrichtung rechts unten ein etwas günstigeres Verfolgungsmuster, dieser Unterschied könnte jedoch auch auf Übungseffekte oder zufällige Variation zurückzuführen sein. Die CV-basierten Blickschätzungen (Abbildung B2) zeigen erwartungsgemäß eine höhere räumliche Streuung und einen deutlich weniger klaren Verlauf als die EyeLink-Referenzdaten. Beide Methoden erfassen das grundlegende Muster der Kalibrierungsbewegung, unterscheiden sich jedoch in der Präzision: PTGaze weist tendenziell kompaktere Cluster um die Sollpositionen auf als MediaPipe, bei dem eine stärkere Streuung der Datenpunkte erkennbar ist. Bei höheren Geschwindigkeiten (500 px/s) zeigen beide CV-Methoden ähnliche Schwierigkeiten wie das Referenzsystem, wobei die Verfolgungsverluste in den CV-Daten stärker ausgeprägt erscheinen. Gleichzeitig kann auch bei den CV-Methoden eine etwas bessere Punkteverteilung in der Variante mit Start rechts unten anhand einer besseren Clusterung erkannt werden. Diese Einzelfallbeobachtungen sind aufgrund ihrer Natur ausdrücklich nicht generalisierbar. Dennoch liefern die Befunde ein erstes ermutigendes Signal für die weitere Validierung an Patientenstichproben.

## Diskussion

Die vorliegende Pilotstudie untersuchte, inwieweit Computer-Vision-basierte Blickerfassungsmethoden als Alternative zu spezialisierten Eyetracking-Systemen für die FVE-basierte Neglect-Diagnostik geeignet sind. Hierzu wurden zwei CV-Methoden (MediaPipe und PTGaze), zwei Kamerasysteme (Webcam mit 60 Hz und Systemkamera mit 25 Hz) sowie zwei Kalibrierungsstrategien (vollständig und reduziert) systematisch verglichen und ihre Übereinstimmung mit dem EyeLink 1000 als Referenzstandard evaluiert.

### Forschungsfragen

**Forschungsfrage 1:** Zur ersten Forschungsfrage, wie hoch die Übereinstimmung zwischen den CV-Pipelines und dem EyeLink hinsichtlich Korrelation, Steigung und Bias ausfällt, zeigt sich ein differenziertes Bild: Die Übereinstimmung variiert stark in Abhängigkeit von der jeweiligen Bedingungskombination. Über alle Bedingungen hinweg erreicht die für die FVE-basierte Neglect-Diagnostik zentrale horizontale Blickachse eine moderate bis gute Korrelation mit dem Referenzsystem. Die beste Übereinstimmung erzielt die Kombination aus PTGaze, Systemkamera und vollständiger Kalibrierung. Hier zeigt die CV-Pipeline eine hohe zeitliche Kopplung der Signale, und die Steigung liegt nahe dem Idealwert von 1 – die CV-Pipeline bildet die Blickbewegungen also nahezu proportional zum Referenzsystem ab. Die geringste Übereinstimmung weist hingegen die Kombination aus MediaPipe, Webcam und reduzierter Kalibrierung auf: Die Korrelation mit dem EyeLink fällt deutlich niedriger aus, und die Steigung zeigt eine Unterschätzung der Blickpositionsamplituden. Der Bias liegt über alle Bedingungen hinweg nahe null, was darauf hindeutet, dass beide CV-Pipelines bei zentraler Blickposition (Bildschirmmitte) keinen bedeutsamen systematischen Offset aufweisen. Die Varianz im Bias wird primär durch interindividuelle Unterschiede bestimmt, nicht durch die experimentellen Faktoren.

**Forschungsfrage 2:** Zur zweiten Forschungsfrage, ob sich MediaPipe und PTGaze in ihrer Übereinstimmung mit dem EyeLink unterscheiden, ergibt der Methodenvergleich ein mehrschichtiges Bild: Bei der Korrelation zeigt sich eine Interaktion mit dem verwendeten Kamerasystem: PTGaze ist MediaPipe nur bei Verwendung der Systemkamera überlegen. Bei der Webcam nivelliert sich dieser Methodenunterschied vollständig – beide Verfahren erreichen hier vergleichbare, jedoch insgesamt niedrigere Korrelationswerte. Dieser Interaktionseffekt repliziert sich sowohl in den linearen gemischten Modellen als auch in der ergänzenden rm-ANOVA und kann damit als robuster Befund eingestuft werden. Bei der Steigung

übertrifft PTGaze MediaPipe hingegen konsistent – das heißt, PTGaze bildet die tatsächlichen Blickpositionsamplituden präziser ab. Konkret bedeutet eine höhere Steigung, dass periphere Blickpositionen weniger stark zur Bildschirmmitte hin komprimiert werden: Während MediaPipe Blickbewegungen um etwa 39 % unterschätzt (Steigung von 0.61), fällt diese Unterschätzung bei PTGaze mit etwa 25 % (Steigung von 0.75) geringer aus. Die inferenzstatistische Prüfung bestätigt diesen Unterschied als substanziell (mittlere Effektstärke). Beim Bias zeigt sich ein differenzierteres Bild als der Haupteffekt vermuten lässt. Zwar wird der Bias von der Methodenwahl inferenzstatistisch kaum beeinflusst, doch lassen sich auf deskriptiver Ebene vorsichtige Hinweise auf systematische Unterschiede ableiten: MediaPipe zeigt tendenziell leicht positive Bias-Werte, was auf einen geringfügigen systematischen Rechtsversatz in den FVE-Daten hindeutet – also bei Blickpositionen, die laut EyeLink-Referenzmessung der Bildschirmmitte entsprechen. PTGaze hingegen bleibt näher am Nullpunkt. Zudem weist MediaPipe eine höhere Variabilität im Bias zwischen den VP auf als PTGaze, was auf eine geringere Robustheit gegenüber individuellen Unterschieden hindeuten könnte. Diese Muster sollten jedoch angesichts der geringen Stichprobengröße als vorläufige Beobachtungen betrachtet werden.

**Forschungsfrage 3:** Zur dritten Forschungsfrage, ob das Kamerasystem die Übereinstimmung der CV-Pipelines mit dem EyeLink beeinflusst, erweist sich die Wahl der Kamera als der einflussreichste Faktor der Studie. Die Systemkamera liefert durchgängig bessere Ergebnisse als die Webcam – sowohl hinsichtlich der Korrelation als auch der Steigung. Die Effektstärken für diesen Kameraunterschied sind die größten der gesamten Studie und übertreffen deutlich die konventionelle Schwelle für große Effekte. Die höhere Bildqualität der Systemkamera kompensiert offenbar die niedrigere zeitliche Auflösung (25 Hz vs. 60 Hz der Webcam). Beide CV-Methoden profitieren von der Systemkamera, wobei PTGaze den Kameravorteil stärker nutzen kann als MediaPipe – ein Befund, der sich in der signifikanten Methode  $\times$  Kamera Interaktion bei der Korrelation niederschlägt. Bemerkenswert ist die Konsistenz des Effekts: Alle zwölf VP erreichen mit der Systemkamera höhere Korrelationswerte als mit der Webcam. Der Bias wird hingegen von der Kamerawahl nicht signifikant beeinflusst: Weder die LMM-Analyse noch die rm-ANOVA weisen einen bedeutsamen Kameraeffekt nach. Der marginale Trend im LMM deutet lediglich darauf hin, dass die Systemkamera tendenziell einen geringfügig niedrigeren Bias produziert als die Webcam. Dieser Unterschied ist jedoch bei der vorliegenden Stichprobengröße nicht statistisch abzuschließen und praktisch vernachlässigbar.

**Forschungsfrage 4:** Zur vierten Forschungsfrage, ob die Komplexität der Kalibrierung die Übereinstimmung beeinflusst, zeigt die Kalibrierungsmethode lediglich marginale Effekte. Die reduzierte Kalibrierung führt nicht zu deutlich schlechteren Ergebnissen. Für die Korrelation lässt sich kein konsistenter Kalibrierungseffekt nachweisen: In der rm-ANOVA erreicht der Effekt knapp Signifikanz, im LMM hingegen nicht. Diese Diskrepanz ist bei der geringen Stichprobengröße erwartbar und deutet darauf hin, dass ein etwaiger Kalibrierungseffekt sehr klein ist. Die Analyse auf Ebene der einzelnen Versuchspersonen bestätigt dieses Bild: Bei den meisten Personen unterscheiden sich die Korrelationswerte zwischen vollständiger und reduzierter Kalibrierung nur minimal. Zwar erreicht die vollständige Kalibrierung eine geringfügig höhere Steigung, der praktische Unterschied ist jedoch mit einer vernachlässigbaren Effektstärke minimal. Für den Bias zeigt sich ebenfalls kein bedeutsamer Kalibrierungseffekt. Für die praktische Anwendung bedeutet dies, dass ein reduzierter Kalibrierungsaufwand – und damit eine kürzere Belastung der untersuchten Personen – ohne nennenswerten Präzisionsverlust möglich sein könnte.

### **Interindividuelle Unterschiede**

Interindividuelle Unterschiede spielen in dieser Pilotstudie eine bemerkenswerte Rolle und verdienen besondere Aufmerksamkeit, da sie bei einer klinischen Anwendung mit heterogenen Patientengruppen von zentraler Bedeutung sein dürften. Der Bias wird überwiegend durch Unterschiede zwischen den VP erklärt, nicht durch die experimentellen Faktoren – knapp ein Fünftel der Bias-Varianz entfällt auf die Personenebene. Die detaillierte Analyse offenbart eine erhebliche Bandbreite in der Übereinstimmung zwischen CV-Pipeline und EyeLink: Während einige VP unter optimalen Bedingungen (PTGaze, Systemkamera) eine sehr hohe Übereinstimmung mit niedrigen absoluten Fehlern erreichen, zeigen andere deutlich schlechtere Werte.

Die Bedeutung interindividueller Unterschiede spiegelt sich auch in der Modellstruktur wider: Bei Korrelation und Steigung erwies sich ein Random Slope für den Faktor Kamera als optimal – der Kameravorteil variiert also zwischen Versuchspersonen. Manche VP profitieren deutlich stärker von der Systemkamera als andere. Die leicht negative Korrelation zwischen Random Intercept und Random Slope ( $r = -.28$  für die Korrelation) deutet zudem auf einen Ceiling-Effekt hin: Versuchspersonen, bei denen die Blickerfassung bereits unter ungünstigen Bedingungen gut funktioniert, zeigen einen geringeren Zugewinn durch die bessere Kamera. Für die klinische Anwendung impliziert dies, dass die Wahl des

Kamerasystems bei manchen Patienten kritischer sein könnte als bei anderen – insbesondere bei Personen mit erschwerter Blickerfassung (z. B. durch Sehhilfen oder ungewöhnliche Gesichtsgeometrie) könnte eine hochwertige Kamera den Unterschied zwischen verwertbaren und unbrauchbaren Daten ausmachen.

Die beobachteten interindividuellen Unterschiede lassen sich teilweise auf spezifische Bedingungen während der Datenerhebung zurückführen – etwa Probleme bei der EyeLink-Kalibrierung durch Sehhilfen, erhöhte Blinzelfrequenz oder Ermüdungserscheinungen (siehe Ergebnisteil). Auffällig ist zudem, dass der Kameraeffekt bei einigen VP besonders stark ausgeprägt ist: VP 3 erreicht mit der Systemkamera noch akzeptable Korrelationen, mit der Webcam hingegen bricht die Übereinstimmung drastisch ein – die niedrigsten Werte der gesamten Stichprobe. Bei dieser VP nivelliert sich auch der Methodenunterschied zwischen MediaPipe und PTGaze vollständig, was die Interpretation stützt, dass bei unzureichender Bildqualität selbst leistungsfähigere Algorithmen keine besseren Ergebnisse erzielen können. Im Gegensatz dazu erreichen VP 4 und VP 10 auch mit der Webcam noch vergleichsweise hohe Korrelationen, was auf günstigere Aufnahmebedingungen oder individuelle Merkmale (z.B. deutlichere Iriskontraste) hindeuten könnte.

Diese individuellen Befunde unterstreichen einerseits die Heterogenität, die bei einer klinischen Anwendung zu erwarten ist, und liefern andererseits wertvolle Hinweise für die Weiterentwicklung der CV-Pipeline. Gleichzeitig ist bei der Interpretation Vorsicht geboten: Die geringe Stichprobengröße erlaubt keine belastbaren Rückschlüsse auf systematische Zusammenhänge zwischen Personenmerkmalen und Übereinstimmungsqualität. Für eine fundierte Analyse solcher Moderatoreffekte wären größere Stichproben erforderlich.

Zusammenfassend zeigen die Ergebnisse, dass CV-basierte Blickerfassung unter günstigen Bedingungen – insbesondere bei Verwendung von PTGaze und einer hochwertigen Kamera – eine vielversprechende Übereinstimmung mit etablierten Eyetracking-Systemen erreichen kann. Die horizontale Blickachse lässt sich mit der besten Bedingungskombination gut erfassen. Die zentralen Befunde – die Überlegenheit von PTGaze gegenüber MediaPipe bei der Steigung, der starke Einfluss der Kameraqualität und der marginale Effekt der Kalibrierungskomplexität – erweisen sich als robust über verschiedene Analysemethoden hinweg. Gleichzeitig verdeutlichen die substantiellen Unterschiede zwischen den Bedingungen und die interindividuelle Variabilität, dass die technischen Rahmenbedingungen und individuellen Merkmale der untersuchten Personen sorgfältig berücksichtigt werden müssen.

## Einordnung der Ergebnisse in den aktuellen Forschungsstand

Die vorliegende Studie ist nach aktuellem Kenntnisstand die erste, die CV-basierte Blickerfassungsmethoden spezifisch für die FVE-basierte Neglect-Diagnostik evaluiert. Dadurch ist ein direkter Vergleich mit anderen Studien schwierig. Insgesamt fügen sich die Ergebnisse aber gut in die bisherige CV-Forschung ein.

**Leistungsvergleich mit anderen CV-Studien.** Aufgrund der unterschiedlichen methodischen Ansätze ist ein Vergleich mit klassischen CV-Studien nur eingeschränkt möglich: Während Kaduk et al. (2024) und Saxena et al. (2024) klassische Accuracy- und Precision-Maße auf Basis fixer Bildschirmpunkte berichten, basiert die vorliegende Studie auf dem FVE-Paradigma, bei dem keine festen Blickziele vorgegeben werden. Stattdessen dient hier der EyeLink als Referenzstandard – eine Vorgehensweise, die der klinischen Anwendungssituation näherkommt, in der ebenfalls keine Ground-Truth-Blickpositionen verfügbar sind.

Unter Berücksichtigung dieser methodischen Unterschiede lassen sich die Ergebnisse dennoch grob einordnen: Kaduk et al. (2024) berichten für ihr Webcam-basiertes System eine Korrelation von  $r = .86$  für die horizontale Blickachse bei Smooth-Pursuit-Aufgaben und eine Accuracy von  $1,4^\circ$ . Saxena et al. (2024) erreichen mit dem FAZE-Modell eine Accuracy von  $2,4^\circ$  und eine Precision von  $0,47^\circ$ . Die beste Bedingungskombination der vorliegenden Studie (PTGaze, Systemkamera, vollständige Kalibrierung) erreicht eine geschätzte Korrelation von  $r = .93$  – ein Wert, der über dem von Kaduk et al. (2024) berichteten liegt. Der MAE von etwa  $2^\circ$  auf Frame-Ebene für die beste Kombination ist wiederum mit den Accuracy-Werten vergleichbarer Studien vereinbar. Insgesamt kann man also von einem konsistenten Bild ausgehen. Bemerkenswert ist außerdem, dass diese Ergebnisse trotz einer deutlich älteren Stichprobe ( $M = 66$  Jahre) erzielt wurden – einer Altersgruppe, die der klinischen Zielpopulation für die Neglect-Diagnostik entspricht. Kaduk et al. (2024), Saxena et al. (2024) und Ehinger et al. (2019) testeten vorwiegend jüngere Probanden (Durchschnittsalter 20–35 Jahre), was die Generalisierbarkeit ihrer Befunde auf ältere Patientengruppen einschränkt.

**Einfluss der Kameraqualität.** Der in dieser Studie beobachtete starke Kameraeffekt – die Systemkamera übertrifft die Webcam deutlich sowohl in der Korrelation als auch in der Steigung – steht im Einklang mit der aktuellen Literatur. Die Befunde bestätigen die theoretische Erwartung, dass appearance-based Deep-Learning-Methoden wie PTGaze besonders von hochwertigen Eingabebildern profitieren (vgl. Abschnitt „Computer Vision“).

Methoden" in der Einleitung). Die vorliegende Studie liefert erstmals empirische Evidenz für diesen Zusammenhang im Kontext der FVE-Diagnostik und zeigt, dass Bildqualität für die getesteten CV-Methoden wichtiger ist als Framerate.

Die Interaktion zwischen Methode und Kamera bei der Korrelation verdient dabei besondere Aufmerksamkeit: Während PTGaze bei der Systemkamera einen klaren Vorteil gegenüber MediaPipe zeigt, nivelliert sich dieser Methodenunterschied bei der Webcam vollständig. Eine mögliche Erklärung für dieses Muster liegt in der unterschiedlichen Funktionsweise der beiden CV-Ansätze: PTGaze als appearance-based Deep-Learning-Verfahren operiert direkt auf den Pixeldaten des gesamten Gesichtsbildes und kann daher von höherer Bildqualität stärker profitieren als MediaPipe, das lediglich diskrete geometrische Landmarken detektiert. Bei der Webcam scheint die geringere Bildqualität – trotz höherer Framerate – einen Flaschenhals darzustellen, der die potenziellen Vorteile des komplexeren PTGaze-Algorithmus neutralisiert. Anders formuliert: Bei unzureichender Bildqualität kann selbst ein leistungsfähigerer Algorithmus keine besseren Ergebnisse erzielen, da die notwendigen Bildinformationen für eine präzisere Schätzung schlicht nicht vorhanden sind.

**Befund zur Kalibrierung.** Ein bemerkenswertes Ergebnis dieser Studie ist der nur marginale Effekt der Kalibrierungskomplexität. Saxena et al. (2022, 2024) berichten hingegen, dass zusätzliche Kalibrierungspunkte die Genauigkeit signifikant verbessern. Für diese unterschiedlichen Befunde kommen mehrere Erklärungen in Betracht: Erstens unterscheiden sich das experimentelle Vorgehen – Saxena et al. (2022) haben ihre Kalibrierungsstrategie optimiert und getestet für die Anwendung auf einem Laptop im Heimgebrauch im Rahmen einer Online-Studie. Hierbei handelt es sich um ein deutlich weniger kontrolliertes und störungsarmes Umfeld als bei dieser Studie, die vollständig im Labor durchgeführt wurde. Durch die Verwendung einer Kopfstütze wurde zusätzliche Varianz in der Kopf-/Augenposition in der Videoaufnahme reduziert. Dadurch bedingt ist in dieser Studie möglicherweise weniger Kalibrierungsaufwand nötig bzw. fällt der Calibration Decay – der Genauigkeitsverlust über die Zeit – nicht so stark aus, weshalb die wiederholte Kalibrierung keinen entscheidenden Vorteil bringen könnte. Zweitens könnten auch die beschriebenen Stichprobenunterschiede eine Rolle spielen: Bei älteren Personen, könnte eine längere Kalibrierung durch Ermüdungseffekte stärker kontraproduktiv wirken – ein Trade-off, der auch von Heck et al. (2023) thematisiert wird. Die bei VP 8 beobachteten Ermüdungserscheinungen während der letzten Kalibrierungsphase stützen diese Interpretation. Ergänzend zur Frage der Kalibrierungskomplexität wurde in einer explorativen Analyse anhand einer Neglect-

Patientin (siehe Methoden) auch der Einfluss der Zielgeschwindigkeit auf die Verfolgungsqualität untersucht (siehe Ergebnisse). Die Befunde liefern erste Hinweise darauf, dass neben der Datenmenge in einer Patientenpopulation auch die Bewegungsparameter des Kalibrierungsziels für die Datenqualität relevant sein könnten.

### **Praktische Implikationen**

Neben der Einordnung in den Forschungsstand erlauben die Ergebnisse dieser Pilotstudie erste Einschätzungen hinsichtlich der praktischen Anwendbarkeit CV-basierter Blickerfassung für die Neglect-Diagnostik.

**Prognose für die FVE-basierte Neglect-Diagnostik.** Die zentrale Frage für die klinische Anwendbarkeit lautet, ob die erreichte Genauigkeit für die FVE-Diagnostik ausreicht. Der von Kaufmann et al. (2020) ermittelte Cut-off von  $1.333^\circ$  Schwinkel mittlerer horizontaler Blickposition erreichte in ihrer Studie eine Sensitivität von 85 % und eine Spezifität von 94.4 %. Die beste CV-Bedingung dieser Studie erreicht auf Frame-Ebene einen *MAE* von etwa  $2^\circ$  Schwinkel – ein Wert, der den diagnostischen Cut-off übersteigt. Auf den ersten Blick erscheint dies problematisch: Wenn die Messungenauigkeit größer ist als der Schwellenwert, anhand dessen zwischen Neglect und Nicht-Neglect unterschieden wird, könnte dies die diagnostische Differenzierung beeinträchtigen.

Ein differenzierterer Blick offenbart jedoch ein komplexeres Bild. Der *MAE* beschreibt die Abweichung auf Frame-Ebene, während die FVE-Diagnostik auf der mittleren Blickposition aggregiert über alle 24 Trials basiert. Diese zweifache Aggregation – zunächst über die Frames eines Trials, dann über alle Trials – reduziert das zufällige Rauschen erheblich. Entscheidender für die diagnostische Genauigkeit ist daher die Frage, ob die CV-Pipeline systematische Verzerrungen zeigt, die zu Fehlklassifikationen führen könnten.

Hier liefern die Ergebnisse ein gemischtes Bild. Der Bias liegt über alle Bedingungen nahe null, was bei zentraler Blickposition keine systematische Verschiebung anzeigt. Die Steigung hingegen liegt mit einem EMM von 0.68 (beste Bedingung: 0.82) unter dem Idealwert von 1, was eine systematische Unterschätzung peripherer Blickpositionen bedeutet – je weiter die tatsächliche Blickposition von der Mitte entfernt liegt, desto stärker komprimiert die CV-Pipeline diesen Wert zur Bildschirmmitte hin. Die explorative Einzelfallbeobachtung einer Neglect-Patientin (siehe Ergebnisteil) illustriert die praktischen Konsequenzen: Bei einer deutlichen Neglect-Ausprägung ( $5.52^\circ$  Schwinkel im EyeLink) erfassten beide CV-

Pipelines das Muster und hätten die Patientin korrekt klassifiziert – trotz systematischer Unterschätzung um etwa  $1.4^\circ$  Schwinkel. Bei Grenzfällen nahe dem Cut-off könnte diese Unterschätzung jedoch zu Fehlklassifikationen führen: Eine hypothetische Patientin mit  $2.0^\circ$  Schwinkel tatsächlicher Blickposition würde von der CV-Pipeline möglicherweise nur mit  $0.6^\circ$  Schwinkel registriert und fälschlicherweise als Neglect-negativ eingestuft. Die diagnostische Konsequenz wäre eine reduzierte Sensitivität für leichte Neglect-Formen.

Für die praktische Anwendung ergeben sich daraus mehrere mögliche Strategien: Erstens könnte eine mathematische Korrektur der Werte basierend auf der geschätzten Steigung erfolgen. Zweitens – und möglicherweise am vielversprechendsten – könnte der Komprimierungseffekt selbst Gegenstand weiterer Forschung sein: Die Ursachen der Unterschätzung (etwa Limitationen der Kalibrierungsmethode, Eigenschaften der CV-Modelle oder Bildqualitätsfaktoren) könnten systematisch untersucht und adressiert werden. Alle Ansätze erfordern jedoch eine systematische Validierung an Patientenstichproben mit unterschiedlichen Schweregraden. Zusammenfassend legen die Befunde nahe, dass CV-basierte Blickerfassung unter günstigen Bedingungen das Potenzial hat, als Grundlage für ein Neglect-Screening zu dienen – insbesondere für moderate bis schwere Ausprägungen. Die systematische Unterschätzung der Blickpositionsamplituden stellt jedoch eine relevante Limitation dar, die bei einer klinischen Implementierung berücksichtigt und idealerweise durch Weiterentwicklung der Pipeline reduziert werden sollte.

**Reduzierte Patientenbelastung durch vereinfachte Kalibrierung.** Ein weiterer praktisch bedeutsamer Befund dieser Studie ist der nur marginale Effekt der Kalibrierungskomplexität. Unter Berücksichtigung der genannten Einschränkungen (vgl. Einordnung der Ergebnisse in den aktuellen Forschungsstand) könnte das für die klinische Praxis bedeuten, dass ein vereinfachtes Kalibrierungsprotokoll eingesetzt werden kann. Dadurch könnte die Belastung für Patienten reduziert werden, ohne die diagnostische Validität wesentlich zu beeinträchtigen. Uimonen et al. (2024) zeigen in ihrer Studie zu VR-basierter Neglect-Diagnostik bei akuten Schlaganfallpatienten, dass technologiegestützte Verfahren bei angemessener Gestaltung gut akzeptiert werden und keine relevanten Nebenwirkungen auftreten – ein ermutigendes Signal auch für CV-basierte Ansätze.

**Implikationen der Kalibrierungsgeschwindigkeit.** Neben der Kalibrierungskomplexität wurde explorativ anhand einer Neglect-Patientin auch der Einfluss der Zielgeschwindigkeit auf die Qualität der Videokalibrierung untersucht (siehe Abbildungen B1 und B2). Die

graphische Analyse zeigt einen sichtbaren Zusammenhang zwischen Bewegungsgeschwindigkeit und Verfolgungsqualität: Bei 200 px/s folgt der Blickverlauf dem vorgegebenen Pfad weitgehend kontinuierlich, während bei 500 px/s wiederholt Verfolgungsverluste auftreten – gekennzeichnet durch unstrukturierte Suchsakkaden und großflächige explorative Augenbewegungen, insbesondere im linken Bildschirmbereich. Die Startrichtung (links oben vs. rechts unten) scheint auch einen gewissen Einfluss zu haben: die Durchgänge mit Startrichtung rechts unten zeigen tendenziell ein etwas günstigeres Verfolgungsmuster.

Der Vergleich zwischen EyeLink-Referenzdaten und CV-Schätzungen verdeutlicht zudem die Limitationen der CV-basierten Blickerfassung bei schnellen Bewegungen: Während das infrarotbasierte Referenzsystem auch bei 500 px/s noch eine erkennbare – wenn auch beeinträchtigte – Verfolgungsstruktur zeigt, weisen die CV-Methoden unter diesen Bedingungen eine deutlich erhöhte Streuung auf. Dies unterstreicht die Bedeutung einer angemessenen Kalibrierungsgeschwindigkeit nicht nur für die Versuchsperson (besonders für eine Neglect-Stichprobe), sondern auch für die technische Qualität der CV-Pipelines. Gleichzeitig stellt die annehmbare Clusterung um die Sollposition bei niedrigeren Geschwindigkeiten (200 – 300 px/s) eine vielversprechende Basis für die weitere Optimierung von CV-Methodiken für die Neglect-Diagnostik dar.

Allerdings ist zu betonen, dass diese Befunde auf der graphischen Analyse einer einzelnen Patientin basieren und daher nicht generalisierbar sind. Für belastbare Empfehlungen zur optimalen Kalibrierungsgeschwindigkeit wäre eine systematische Untersuchung an größeren Stichproben mit variierendem Neglect-Schweregrad erforderlich. Auf Basis der vorliegenden explorativen Daten erscheint aber eine Zielgeschwindigkeit von 200–300 px/s als vielversprechender Ausgangspunkt für weitere Forschung, da sie einen Kompromiss zwischen Durchführbarkeit und Datenqualität darstellen könnte.

**Empfehlungen zur Kameraqualität.** Auch der starke Kameraeffekt hat unmittelbare Implikationen für eine potenzielle klinische Implementierung. Die Ergebnisse legen nahe, dass Investitionen in die Bildqualität vielversprechender sind als eine Erhöhung der Framerate. Für die praktische Umsetzung bedeutet dies, dass bei einer zukünftigen Anwendung nicht zwingend auf High-Speed-Webcams gesetzt werden muss. Stattdessen könnte eine Webcam mit moderater Framerate und guter Bildqualität in Kombination mit kontrollierter Beleuchtung bessere Ergebnisse liefern als eine Standard-Webcam mit höherer zeitlicher Auflösung.

Diese Erkenntnis könnte die Hardwarekosten reduzieren und die technische Implementierung vereinfachen.

**Perspektive für den Einsatz in ressourcenbegrenzten Settings.** Die in der Einleitung formulierte Hoffnung, dass CV-basiertes Eye-Tracking die Hürde spezialisierter Hardware überwinden könnte, wird durch die vorliegenden Ergebnisse teilweise gestützt. Dies eröffnet perspektivisch die Möglichkeit, FVE-basierte Diagnostik in Settings einzusetzen, in denen spezialisierte Eyetracking-Systeme nicht verfügbar sind – etwa in Rehabilitationskliniken ohne Eye-Tracking-Labor. Gleichzeitig zeigen die Ergebnisse, dass die Qualität der Blickerfassung stark von den technischen Rahmenbedingungen abhängt. Die deutliche Überlegenheit der Systemkamera gegenüber der Webcam und die höhere Robustheit von PTGaze gegenüber MediaPipe machen deutlich, dass nicht jede beliebige Kamera-Software-Kombination für diagnostische Zwecke geeignet ist. Eine unkritische Übertragung auf beliebige Consumer-Hardware ist daher nicht zu empfehlen.

## **Stärken**

**Neuartigkeit des Forschungsansatzes.** Während bisherige Validierungsstudien zu CV-basiertem Eye-Tracking überwiegend klassische Paradigmen verwendeten, wurde hier erstmals das klinisch relevante FVE-Paradigma als Evaluationsgrundlage gewählt. Dieser Ansatz erhöht die ökologische Validität der Ergebnisse, da er die tatsächliche Anwendungssituation abbildet, in der keine Ground-Truth-Blickpositionen verfügbar sind. Zudem wurde mit der eigenständig entwickelten CV-Pipeline nicht nur ein bestehendes Tool angewendet, sondern ein funktionaler Prototyp geschaffen, der spezifisch auf die Anforderungen der Neglect-Diagnostik zugeschnitten ist und als Grundlage für die Weiterentwicklung dienen kann.

**Klinisch relevante Stichprobe.** Diese methodische Neuartigkeit wird durch eine für die Fragestellung besonders geeignete Stichprobe ergänzt. Mit einem Durchschnittsalter von 66 Jahren entspricht die untersuchte Population der klinischen Zielpopulation für die Neglect-Diagnostik deutlich besser als die Stichproben vergleichbarer Validierungsstudien (vgl. Abschnitt „Einordnung in den Forschungsstand“). Die vorliegende Studie zeigt, dass CV-basierte Blickerfassung auch bei älteren Personen – die häufiger unter altersbedingten Veränderungen wie hängenden Augenlidern, reduziertem Iriskontast oder dem Tragen von Bifokalbrillen leiden – eine vielversprechende Übereinstimmung mit etablierten Eyetracking-Systemen erreichen kann. Die beobachteten interindividuellen Unterschiede liefern zudem

wertvolle Hinweise darauf, welche spezifischen Merkmale die Datenqualität beeinflussen können. Über die Testung an gesunden älteren Erwachsenen hinaus wurde eine einzelne Neglect-Patientin explorativ untersucht (siehe Ergebnisteil), was erste Hinweise auf die Anwendbarkeit bei der klinischen Zielpopulation liefert.

**Systematisches experimentelles Design.** Die Aussagekraft der Stichprobenbefunde wird durch ein differenziertes experimentelles Design gestützt. Das vollständig gekreuzte  $2 \times 2 \times 2$ -Design ermöglicht eine systematische Analyse der Einflussfaktoren auf die Übereinstimmung zwischen CV-Pipelines und dem Referenzsystem. Durch die Variation von CV-Methode, Kamerasystem und Kalibrierungsstrategie konnten nicht nur Haupteffekte, sondern auch Interaktionen identifiziert werden. Die Verwendung sowohl linearer gemischter Modelle als auch klassischer Repeated-Measures-ANOVAs ermöglicht zudem eine Einschätzung der Robustheit der Befunde: Die zentralen Ergebnisse replizieren sich über beide Analysemethoden hinweg, während Abweichungen ausschließlich Effekte nahe der Signifikanzschwelle betreffen.

**Offlinefähigkeit und Datenschutz.** Schließlich bietet die technische Architektur der entwickelten Pipeline praktische Vorteile für eine zukünftige klinische Anwendung. Die Offline-Verarbeitung der Videodaten – also die Analyse nach Abschluss der Datenerhebung – ermöglicht den Einsatz rechenintensiver Deep-Learning-Modelle wie PTGaze, die in Echtzeit auf Standard-Hardware nicht lauffähig wären. Darüber hinaus hat die Offlinefähigkeit Implikationen für den Datenschutz: Die Videodaten können vollständig lokal verarbeitet werden und müssen im Gegensatz zu browserbasierten Echtzeit-Lösungen nicht an externe Server übertragen werden (vgl. Steffan et al., 2024). Dieser Aspekt ist für den Einsatz im klinischen Kontext mit sensiblen Patientendaten besonders relevant.

## **Limitationen**

Die vorliegende Studie weist trotz ihrer Stärken mehrere methodische Einschränkungen auf, die bei der Interpretation der Ergebnisse berücksichtigt werden sollten und wichtige Hinweise für zukünftige Forschungsarbeiten liefern.

**Stichprobe und Generalisierbarkeit.** Die zentrale Limitation dieser Pilotstudie ist die kleine Stichprobengröße, die die statistische Power einschränkt und die Generalisierbarkeit der Befunde begrenzt. Insbesondere die beobachteten interindividuellen Unterschiede

lassen sich aufgrund der geringen Fallzahlen nicht systematisch analysieren. Für eine fundierte Untersuchung solcher Moderatoreffekte wären größere Stichproben erforderlich.

Eine weitere wesentliche Einschränkung betrifft die Zusammensetzung der Stichprobe: Die Studie wurde primär an gesunden älteren Erwachsenen durchgeführt. Die entscheidende Frage für die klinische Anwendbarkeit – ob die CV-Pipeline Neglect-spezifische Blickmuster zuverlässig von gesunden Mustern unterscheiden kann – bleibt ohne systematische Validierung an Patientenstichproben unbeantwortet. Die explorativen Daten einer einzelnen Patientin liefern erste ermutigende Hinweise, erlauben jedoch keine generalisierbaren Schlüsse. Neglect-Patienten könnten zusätzliche Herausforderungen für die Blickerfassung darstellen, etwa durch erhöhte motorische Unruhe, Ermüdbarkeit oder Schwierigkeiten bei der Kalibrierung. Eine Validierung an Patientenstichproben ist daher ein notwendiger nächster Schritt.

**Anpassungen im Versuchsablauf.** Während der Datenerhebung wurden kleinere Anpassungen an der Experimentalsoftware vorgenommen, sodass insgesamt vier Versionen zum Einsatz kamen (siehe Appendix D). Diese Anpassungen betrafen unter anderem den Monitor-Abstand, die Fixationsdauer bei der Kalibrierung und die Kalibrierungsmargins. Obwohl das Kernparadigma über alle Versionen hinweg identisch blieb, stellen diese Variationen eine potenzielle Störvariable dar. Die Versionsunterschiede wurden in der statistischen Analyse nicht als Kovariate berücksichtigt, da die Fallzahlen pro Version für eine sinnvolle Modellierung zu gering waren.

**Technische Probleme bei der Synchronisation.** Wie im Methodenteil beschrieben, traten bei VP 2, VP 4, VP 7 und VP 10 erhebliche Probleme mit der Tondetektion auf, die für die Synchronisation zwischen Videoaufnahme und Experimentalsoftware erforderlich ist. Die manuelle Eingabe der Startpunkte und die verstärkte Tonsuche lieferten zwar verwertbare Ergebnisse, die Synchronisationsqualität ist bei diesen VP jedoch eingeschränkt. Da diese Probleme ausschließlich die 60-Hz-Videos betrafen, könnten sie die Übereinstimmungswerte für die Webcam-Bedingung zusätzlich beeinträchtigt haben. Gleichzeitig könnten auch die Werte der anderen Personen durch leichte Abweichungen in der Synchronisierung beeinflusst sein.

**Einordnung des Kameraeffekts.** Der starke Kameraeffekt – die Systemkamera übertrifft die Webcam deutlich – ist einer der zentralen Befunde dieser Studie. Bei der Interpretation ist jedoch zu berücksichtigen, dass neben der Bildqualität weitere Faktoren konfundierend

sein könnten. Beispielsweise könnten kameraspezifische Einstellungen wie Blende oder Beleuchtung die Ergebnisse beeinflusst haben. Der beobachtete Kameraeffekt sollte daher nicht dahingehend überinterpretiert werden, dass Webcams grundsätzlich für CV-basierte Blickerfassung ungeeignet sind. Vielmehr legen die Ergebnisse nahe, dass die Bildqualität – unabhängig vom Kameratyp – ein kritischer Faktor ist. Eine hochwertige Webcam mit guter Optik und kontrollierter Beleuchtung könnte durchaus vergleichbare Ergebnisse erzielen.

**Einschränkungen des Referenzsystems.** Als Referenzstandard diente der EyeLink 1000, dessen Daten als Ground Truth für die Bewertung der CV-Pipelines verwendet wurden. Bei mehreren VP traten jedoch Kalibrierungsprobleme mit dem EyeLink auf (siehe Methoden). Diese Einschränkungen der Referenzqualität erschweren die Interpretation der Übereinstimmungswerte: Wenn die CV-Pipeline bei einer VP schlechter abschneidet, ist nicht abschließend zu klären, ob dies auf Schwächen der CV-Pipeline oder auf eingeschränkte EyeLink-Datenqualität zurückgeht.

**Analysestrategie: Einbezug von Sakkaden.** Die vorliegende Studie wertete alle Frames der Stimulusphase aus – sowohl während Fixationen als auch während Sakkaden. Dies unterscheidet sich vom Vorgehen bei Kaufmann et al. (2020), die für die FVE-Diagnostik ausschließlich Fixationsphasen berücksichtigen, da nur während Fixationen von einem aktiven Betrachten der Szene gesprochen werden kann. Die Entscheidung, keine Unterscheidung zwischen Fixationen und Sakkaden vorzunehmen, ist primär technisch begründet: Die zuverlässige Detektion von Sakkaden und Fixationen erfordert normalerweise eine hohe zeitliche Auflösung, die mit den hier verwendeten Kameras (25–60 Hz) nicht gegeben ist. Saxena et al. (2024) weisen explizit darauf hin, dass traditionelle geschwindigkeits- und beschleunigungsbasierte Algorithmen zur Fixationsdetektion bei niedrigen Abtastraten nicht zuverlässig funktionieren. Hinzu kommt, dass Sakkaden für CV-basierte Systeme besonders herausfordernd sind: Die hohe Bewegungsgeschwindigkeit führt zu Bewegungsunschärfe im Videobild, was die Blickschätzung erschwert und zu erhöhtem Rauschen führt.

**Laborumgebung und ökologische Validität.** Die Datenerhebung fand unter kontrollierten Laborbedingungen statt: Die VP saßen mit fixiertem Kopf in einer Kopfstütze, die Beleuchtung war konstant, und der Abstand zum Bildschirm war standardisiert. Diese Bedingungen sind optimal für die Blickerfassung, entsprechen jedoch nicht der klinischen Realität. Auf einer Stroke Unit oder in einer Rehabilitationsklinik wäre mit variierender Beleuchtung, Patientenbewegungen und möglicherweise liegender Position zu rechnen. Die unter

Laborbedingungen erzielten Übereinstimmungswerte stellen daher eine Obergrenze dar; unter realen klinischen Bedingungen ist mit niedrigeren Werten zu rechnen.

### **Implikationen für zukünftige Forschung**

Die vorliegende Pilotstudie liefert neben den diskutierten Befunden konkrete Ansatzpunkte für die Weiterentwicklung der CV-Pipeline und für zukünftige Forschungsarbeiten.

**Technische Optimierungspotenziale.** Mehrere Komponenten der Pipeline bieten Raum für Verbesserungen. Die audio-basierte Synchronisation erwies sich als aufwendigste Komponente der Pipeline-Entwicklung und als anfällig für Störgeräusche. Für zukünftige Implementierungen wäre ein systemseitiger Kamerastart durch die Experimentalsoftware die eleganteste Lösung. Dabei könnte die Kamera direkt über eine Softwareschnittstelle (API) gestartet und die Zeitstempel bereits bei der Aufnahme synchronisiert werden. Alternativ könnten visuelle Marker wie Bildschirmblitze als robustere Alternative zu akustischen Signalen dienen. Auch die Blink-Detection bietet Optimierungspotenzial: Der fixe EAR-Schwellenwert von 0.16 führte bei einigen VP zu Über-, bei anderen zu Unterdetektion. Die im Nachgang implementierte Lösung mit adaptiven, personenspezifischen Schwellenwerten stellt eine Übergangslösung dar; für zukünftige Versionen empfiehlt sich die Automatisierung dieses Prozesses, etwa durch maschinelles Lernen auf Basis der manuell validierten Daten dieser Studie.

Hinsichtlich der Analysestrategie legen die Ergebnisse nahe, dass eine Beschränkung auf Fixationsphasen die Datenqualität verbessern könnte, da die erhöhte Streuung während Sakkaden die Übereinstimmungswerte vermutlich verschlechtert. Für zukünftige Studien wäre zu prüfen, ob dispersionsbasierte Algorithmen für eine approximative Fixationsdetektion in den CV-Daten implementiert werden können. Bezüglich der CV-Modelle erwies sich PTGaze als die bessere Wahl gegenüber MediaPipe. Allerdings ist auch PTGaze nicht der aktuelle State-of-the-Art. Modelle wie beispielsweise FAZE erreichen höhere Genauigkeiten durch Few-Shot-Adaptation, bei der das Modell mit wenigen personenspezifischen Samples nachtrainiert wird; der modulare Aufbau der Pipeline erleichtert die Integration solcher Modelle. Schließlich sollte der starke Kameraeffekt nicht dahingehend überinterpretiert werden, dass Webcams grundsätzlich ungeeignet sind – ein systematischer Vergleich verschiedener Consumer-Kameras unter kontrollierten Bedingungen wäre aufschlussreich, um konkrete Empfehlungen zur Mindestauflösung und Optikqualität für die klinische Implementierung ableiten zu können.

**Notwendige Validierungsschritte.** Die zentrale offene Frage für die klinische Anwendbarkeit ist, ob die CV-Pipeline Neglect-spezifische Blickmuster systematisch und zuverlässig von gesunden Mustern unterscheiden kann. Eine Validierungsstudie sollte das Design von Kaufmann et al. (2020) mit Patienten replizieren, ergänzt um die parallele CV-Erfassung, und die diagnostische Genauigkeit der CV-basierten FVE mit der EyeLink-basierten FVE vergleichen. Die im Ergebnisteil berichteten explorativen Daten einer einzelnen Neglect-Patientin unterstreichen die Relevanz einer solchen systematischen Validierung: Die Patientin zeigte das typische Rechtsverlagerungsmuster, das von beiden CV-Pipelines erfasst und korrekt klassifiziert wurde. Allerdings unterschätzten die CV-Pipelines die Blickposition stärker als bei den gesunden VP, was bei Grenzfällen nahe dem Cut-off problematisch werden könnte. Eine systematische Studie sollte daher gezielt Patienten mit unterschiedlichen Schweregraden einschließen, um die diagnostische Genauigkeit auch bei subtileren Neglect-Formen zu evaluieren. Darüber hinaus stellen die unter Laborbedingungen erzielten Ergebnisse eine Obergrenze dar; für eine klinische Anwendung ist eine Evaluation unter realistischen Bedingungen erforderlich, die variierende Beleuchtung, Patientenbewegungen und möglicherweise liegende Positionen berücksichtigt.

Schließlich sollte auch die Kalibrierungsstrategie selbst Gegenstand systematischer Forschung sein: Die explorative Analyse zur Zielgeschwindigkeit liefert erste Hinweise, dass langsamere Bewegungsgeschwindigkeiten die Verfolgungsqualität verbessern könnten – ein Aspekt, der für Patienten mit Aufmerksamkeitsdefiziten besonders relevant sein dürfte. Eine systematische Variation von Geschwindigkeit, Bewegungsmuster (z. B. zusätzlich sternförmig immer von der Mitte ausgehend) und Verweildauer an den Kalibrierungspunkten könnte wertvolle Erkenntnisse für die Entwicklung neglectspezifischer Kalibrierungsprotokolle liefern.

**Weiterführende Anwendungsperspektiven.** Ein vielversprechendes Anwendungsfeld könnte die longitudinale Erfassung von Blickmustern im Rehabilitationsverlauf sein. Tang et al. (2025) demonstrieren mit ihrem multimodalen Smart-Home-System, dass kontinuierliches Post-Stroke-Monitoring während alltäglicher Aktivitäten möglich ist und therapeutisch relevante Verlaufsdaten liefern kann. Die Integration einer CV-basierten FVE in solche Systeme könnte langfristig eine objektive Erfassung von Neglect-Symptomen im häuslichen Umfeld ermöglichen. Die entwickelte Pipeline ist zudem grundsätzlich nicht auf die Neglect-Diagnostik beschränkt, da Blickverhalten in einer Vielzahl diagnostischer Kontexte genutzt wird – von der Alzheimer-Früherkennung über ADHS-Diagnostik bis zur Autismus-

Forschung. Greenaway et al. (2024) zeigen, dass Webcam-basiertes Eye-Tracking bei älteren Erwachsenen mit und ohne Alzheimer machbar ist und relevante Aufmerksamkeitsmuster erfassen kann. Die modulare Architektur der vorliegenden Pipeline erleichtert eine Adaption für andere Paradigmen, und die Erkenntnisse zur Bedeutung der Kameraqualität und zur Robustheit verschiedener CV-Methoden dürften auch für andere Anwendungsfelder relevant sein.

## **Fazit**

Die vorliegende Arbeit ging der Frage nach, ob Computer-Vision-basierte Blickerfassung eine praktikable Alternative zu spezialisierten Eyetracking-Systemen für die Neglect-Diagnostik mittels Freier Visueller Exploration darstellen kann. Ausgangspunkt war ein Dilemma in der Neglect-Diagnostik: Die gängigen Paper-Pencil-Verfahren sind schnell durchführbar, übersehen jedoch häufig leichtere Neglect-Formen. Die Catherine Bergego Scale erfasst die Defizite dort, wo sie auftreten – im Alltag –, lässt sich aber aufgrund des hohen Zeitaufwands kaum in die Akutversorgung integrieren. Die FVE-Methode verbindet die Vorteile beider Ansätze, wird jedoch bislang von der Hürde spezialisierter Eyetracking-Hardware ausgebremst. Diese Problematik bildete den Ausgangspunkt für die Entwicklung und Evaluation einer eigenständigen CV-Pipeline.

Die Ergebnisse dieser Pilotstudie stimmen optimistisch: Unter günstigen Bedingungen – insbesondere bei Verwendung von PTGaze und einer Kamera mit hoher Bildqualität – erreicht die entwickelte CV-Pipeline eine vielversprechende Übereinstimmung mit dem EyeLink-Referenzsystem. Die horizontale Blickachse lässt sich gut erfassen. Als zentrale Einflussfaktoren erweisen sich die Wahl der CV-Methode und die Kameraqualität: Das appearance-based Verfahren PTGaze übertrifft den feature-basierten Ansatz MediaPipe konsistent und zeigt eine höhere Robustheit gegenüber individuellen Unterschieden. Die Bildqualität der Kamera ist wichtiger als die zeitliche Auflösung – ein Befund mit unmittelbarer praktischer Relevanz. Die Komplexität der Kalibrierung hingegen spielt eine untergeordnete Rolle, was perspektivisch eine Vereinfachung des Kalibrierungsprotokolls und damit eine Reduktion der Patientenbelastung ermöglichen könnte. Ergänzend deuten explorative Befunde darauf hin, dass auch die Bewegungsgeschwindigkeit des Kalibrierungsziels für die Datenqualität relevant sein könnte – ein Aspekt, der für neglectspezifische Protokolle weitere Forschung verdient. Gleichzeitig verdeutlicht die Studie, dass der Weg zur klinisch einsetzbaren Lösung weitere Schritte erfordert. Die entscheidende Frage – ob die CV-Pipeline

Neglect-spezifische Blickmuster zuverlässig von gesunden Mustern unterscheiden kann – kann auf Basis einer einzelnen explorativen Patiententestung nicht abschließend beantwortet werden, wenngleich die Befunde optimistisch stimmen. Die identifizierten technischen Optimierungspotenziale bei Synchronisation, Blink-Detection und CV-Modellintegration bieten konkrete Ansatzpunkte für die Weiterentwicklung.

Die vorliegende Arbeit leistet einen ersten Beitrag dazu, die von Williams et al. (2025) kritisierte Lücke in der Neglect-Diagnostik zu adressieren. Sie zeigt, dass CV-basierte Blickerfassung das Potenzial hat, die FVE-Diagnostik aus dem spezialisierten Labor in die breitere klinische Anwendung zu bringen – und liefert empirisch fundierte Orientierungspunkte für die technischen Voraussetzungen, die dafür erfüllt sein müssen.

## Literaturverzeichnis

- Anton, A., Rommel, A., Steppuhn, H., Thamm, R., Yessimova, D., Schröder, H., Brückner, G., Schüssel, K., & Porst, M. (2025). *Schlaganfall – Prävalenz, Trends und regionale Verteilung in Deutschland. Eine Auswertung auf Basis von GKV-Routinedaten*. <https://doi.org/10.25646/13412>
- Aravind, G., & Lamontagne, A. (2014). Perceptual and locomotor factors affect obstacle avoidance in persons with visuospatial neglect. *Journal of NeuroEngineering and Rehabilitation*, 11(1), 38. <https://doi.org/10.1186/1743-0003-11-38>
- Azouvi, P. (2017). The ecological assessment of unilateral neglect. *Annals of Physical and Rehabilitation Medicine*, 60(3), 186–190. <https://doi.org/10.1016/j.rehab.2015.12.005>
- Azouvi, P., Olivier, S., de Montety, G., Samuel, C., Louis-Dreyfus, A., & Tesio, L. (2003). Behavioral assessment of unilateral neglect: Study of the psychometric properties of the Catherine Bergego Scale. *Archives of Physical Medicine and Rehabilitation*, 84(1), 51–57. <https://doi.org/10.1053/apmr.2003.50062>
- Bates, D., Kliegl, R., Vasishth, S., & Baayen, H. (2018). *Parsimonious Mixed Models* (arXiv:1506.04967). arXiv. <https://doi.org/10.48550/arXiv.1506.04967>
- Bates, D., Mächler, M., Bolker, B., & Walker, S. (2015). Fitting Linear Mixed-Effects Models Using lme4. *Journal of Statistical Software*, 67, 1–48. <https://doi.org/10.18637/jss.v067.i01>
- Bergego, C., Azouvi, P., Samuel, C., Marchal, F., Louis-Dreyfus, A., Jokic, C., Morin, L., Renard, C., Pradat-Diehl, P., & Deloche, G. (1995). Validation d'une échelle d'évaluation fonctionnelle de l'héminégligence dans la vie quotidienne: L'échelle CB. *Annales de Réadaptation et de Médecine Physique*, 38(4), 183–189. [https://doi.org/10.1016/0168-6054\(96\)89317-2](https://doi.org/10.1016/0168-6054(96)89317-2)
- Bonato, M. (2012). Neglect and Extinction Depend Greatly on Task Demands: A Review. *Frontiers in Human Neuroscience*, 6. <https://www.frontiersin.org/articles/10.3389/fnhum.2012.00195>
- Bosma, M. S., Caljouw, M. A. A., Achterberg, W. P., & Nijboer, T. C. W. (2023). Prevalence, Severity and Impact of Visuospatial Neglect in Geriatric Stroke Rehabilitation, a Cross-Sectional Study. *Journal of the American Medical Directors Association*, 24(11), 1798–1805. <https://doi.org/10.1016/j.jamda.2023.06.038>
- Bosma, M. S., Nijboer, T. C. W., Caljouw, M. A. A., & Achterberg, W. P. (2020). Impact of visuospatial neglect post-stroke on daily activities, participation and informal caregiver burden: A systematic review. *Annals of Physical and Rehabilitation Medicine*, 63(4), 344–358. <https://doi.org/10.1016/j.rehab.2019.05.006>
- Brunila, T., Jalas, M. J., Lindell, A. B., Tenovu, O., & Hämäläinen, H. (2003). The Two Part Picture in Detection of Visuospatial Neglect. *The Clinical Neuropsychologist*, 17(1), 45–53. <https://doi.org/10.1076/clin.17.1.45.15632>

- Chen, P., Hreha, K., Fortis, P., Goedert, K. M., & Barrett, A. M. (2012). Functional Assessment of Spatial Neglect: A Review of the Catherine Bergego Scale and an Introduction of the Kessler Foundation Neglect Assessment Process. *Topics in Stroke Rehabilitation, 19*(5), 423–435. <https://doi.org/10.1310/tsr1905-423>
- Cheng, Y., Wang, H., Bao, Y., & Lu, F. (2024). Appearance-Based Gaze Estimation With Deep Learning: A Review and Benchmark. *IEEE Transactions on Pattern Analysis and Machine Intelligence, 46*(12), 7509–7528. <https://doi.org/10.1109/TPAMI.2024.3393571>
- Cohen, J. (2013). *Statistical Power Analysis for the Behavioral Sciences*. Academic Press.
- Edwards, L. J., Muller, K. E., Wolfinger, R. D., Qaqish, B. F., & Schabenberger, O. (2008). An R2 statistic for fixed effects in the linear mixed model. *Statistics in Medicine, 27*(29), 6137–6157. <https://doi.org/10.1002/sim.3429>
- Ehinger, B. V., Groß, K., Ibs, I., & König, P. (2019). A new comprehensive eye-tracking test battery concurrently evaluating the Pupil Labs glasses and the EyeLink 1000. *PeerJ, 7*, e7086. <https://doi.org/10.7717/peerj.7086>
- Esposito, E., Shekhtman, G., & Chen, P. (2021). Prevalence of spatial neglect post-stroke: A systematic review. *Annals of Physical and Rehabilitation Medicine, Special issue Cognitive rehabilitation, 64*(5), 101459. <https://doi.org/10.1016/j.rehab.2020.10.010>
- Feigin, V. L., Brainin, M., Norrving, B., Martins, S. O., Pandian, J., Lindsay, P., F Grupper, M., & Rautalin, I. (2025). World Stroke Organization: Global Stroke Fact Sheet 2025. *International Journal of Stroke, 20*(2), 132–144. <https://doi.org/10.1177/17474930241308142>
- Feigin, V. L., Brainin, M., Norrving, B., Martins, S., Sacco, R. L., Hacke, W., Fisher, M., Pandian, J., & Lindsay, P. (2022). World Stroke Organization (WSO): Global Stroke Fact Sheet 2022. *International Journal of Stroke, 17*(1), 18–29. <https://doi.org/10.1177/17474930211065917>
- Galletta, E. E., Campanelli, L., Maul, K. K., & Barrett, A. M. (2014). Assessment of Neglect Dyslexia With Functional Reading Materials. *Topics in Stroke Rehabilitation, 21*(1), 75–86. <https://doi.org/10.1310/tsr2101-75>
- Greenaway, A.-M., Hwang, F., Nasuto, S., & Ho, A. (2024). Webcam-Based Eye-Tracking of Attentional Biases in Alzheimer’s Disease: A Proof-Of-Concept Study. *Clinical Gerontologist, 47*(1), 98–109. <https://doi.org/10.1080/07317115.2023.2240783>
- Heck, M., Becker, C., & Deutscher, V. (2023). *Webcam Eye Tracking for Desktop and Mobile Devices: A Systematic Review*. <https://doi.org/10.24251/HICSS.2023.825>
- Hollander, J., & Huette, S. (2022). Extracting blinks from continuous eye-tracking data in a mind wandering paradigm. *Consciousness and Cognition, 100*, 103303. <https://doi.org/10.1016/j.concog.2022.103303>
- Holmqvist, K., Nyström, M., Andersson, R., Dewhurst, R., Jarodzka, H., & Weijer, J. van de. (2011). *Eye Tracking: A comprehensive guide to methods and measures*. Oxford University Press.

- Kaduk, T., Goeke, C., Finger, H., & König, P. (2024). Webcam eye tracking close to laboratory standards: Comparing a new webcam-based system and the EyeLink 1000. *Behavior Research Methods*, 56(5), 5002–5022. <https://doi.org/10.3758/s13428-023-02237-8>
- Karnath, H.-O., & Rorden, C. (2012). The anatomy of spatial neglect. *Neuropsychologia, Special Issue: Spatial Neglect and Attention*, 50(6), 1010–1017. <https://doi.org/10.1016/j.neuropsychologia.2011.06.027>
- Karnath, H.-O., Schenk, T., & Benke, T. (2023). Diagnostik und Therapie von Neglect und anderen Störungen der Raumkognition. *Deutsche Gesellschaft für Neurologie (Hrsg.), Leitlinien für Diagnostik und Therapie in der Neurologie, Leitlinien für Diagnostik und Therapie in der Neurologie*. [www.dgn.org/leitlinien](http://www.dgn.org/leitlinien)
- Karnath, H.-O., & Thier, P. (Hrsg.). (2012). *Kognitive Neurowissenschaften*. Springer. <https://doi.org/10.1007/978-3-642-25527-4>
- Kaufmann, B. C., Cazzoli, D., Pflugshaupt, T., Bohlhalter, S., Vanbellingen, T., Müri, R. M., Nef, T., & Nyffeler, T. (2020). Eyetracking during free visual exploration detects neglect more reliably than paper-pencil tests. *Cortex*, 129, 223–235. <https://doi.org/10.1016/j.cortex.2020.04.021>
- Kuznetsova, A., Brockhoff, P. B., & Christensen, R. H. B. (2017). lmerTest Package: Tests in Linear Mixed Effects Models. *Journal of Statistical Software*, 82, 1–26. <https://doi.org/10.18637/jss.v082.i13>
- Lenth, R. (2023). *emmeans: Estimated Marginal Means, aka Least-Squares Means* [Software]. <https://cir.nii.ac.jp/crid/1370584340724217473>
- Liu, S. (2024). 3\_Gaze\_MPII [Software]. GitHub. [https://github.com/songNew/3\\_Gaze\\_MPII](https://github.com/songNew/3_Gaze_MPII)
- Lüdecke, D., Ben-Shachar, M. S., Patil, I., Waggoner, P., & Makowski, D. (2021). performance: An R package for assessment, comparison and testing of statistical models. *Journal of open source software*, 6(60). [https://pure.mpg.de/rest/items/item\\_3316363/component/file\\_3316364/content](https://pure.mpg.de/rest/items/item_3316363/component/file_3316364/content)
- Lugaresi, C., Tang, J., Nash, H., McClanahan, C., Uboweja, E., Hays, M., Zhang, F., Chang, C.-L., Yong, M. G., Lee, J., Chang, W.-T., Hua, W., Georg, M., & Grundmann, M. (2019). *MediaPipe: A Framework for Building Perception Pipelines* (arXiv:1906.08172). arXiv. <https://doi.org/10.48550/arXiv.1906.08172>
- Luke, S. G. (2017). Evaluating significance in linear mixed-effects models in R. *Behavior Research Methods*, 49(4), 1494–1502. <https://doi.org/10.3758/s13428-016-0809-y>
- Matuschek, H., Kliegl, R., Vasishth, S., Baayen, H., & Bates, D. (2017). Balancing Type I error and power in linear mixed models. *Journal of Memory and Language*, 94, 305–315. <https://doi.org/10.1016/j.jml.2017.01.001>
- Meteyard, L., & Davies, R. A. I. (2020). Best practice guidance for linear mixed-effects models in psychological science. *Journal of Memory and Language*, 112, 104092. <https://doi.org/10.1016/j.jml.2020.104092>

- Nakagawa, S., & Schielzeth, H. (2013). A general and simple method for obtaining R<sup>2</sup> from generalized linear mixed-effects models. *Methods in Ecology and Evolution*, 4(2), 133–142. <https://doi.org/10.1111/j.2041-210x.2012.00261.x>
- Nijboer, T. C. W., Ten Brink, A. F., van der Stoep, N., & Visser-Meily, J. M. A. (2014). Neglecting posture: Differences in balance impairments between peripersonal and extrapersonal neglect. *NeuroReport*, 25(17), 1381. <https://doi.org/10.1097/WNR.0000000000000277>
- Paladini, R. E., Wyss, P., Kaufmann, B. C., Urwyler, P., Nef, T., Cazzoli, D., Nyffeler, T., & Müri, R. M. (2019). Re-fixation and perseveration patterns in neglect patients during free visual exploration. *European Journal of Neuroscience*, 49(10), 1244–1253. <https://doi.org/10.1111/ejn.14309>
- Papoutsaki, A., Sangkloy, P., Laskey, J., Daskalova, N., Huang, J., & Hays, J. (2016). WebGazer: Scalable webcam eye tracking using user interactions. In *Proceedings of the 25th International Joint Conference on Artificial Intelligence* (pp. 3839–3845). AAAI Press. <https://www.ijcai.org/Proceedings/16/Papers/540.pdf>
- Park, S., Mello, S. D., Molchanov, P., Iqbal, U., Hilliges, O., & Kautz, J. (2019). *Few-Shot Adaptive Gaze Estimation*. 9368–9377. [https://openaccess.thecvf.com/content\\_ICCV\\_2019/html/Park\\_Few-Shot\\_Adaptive\\_Gaze\\_Estimation\\_ICCV\\_2019\\_paper.html](https://openaccess.thecvf.com/content_ICCV_2019/html/Park_Few-Shot_Adaptive_Gaze_Estimation_ICCV_2019_paper.html)
- Pathirana, P., Senarath, S., Meedeniya, D., & Jayarathna, S. (2022). Eye gaze estimation: A survey on deep learning-based approaches. *Expert Systems with Applications*, 199, 116894. <https://doi.org/10.1016/j.eswa.2022.116894>
- Pitteri, M., Chen, P., Passarini, L., Albanese, S., Meneghello, F., & Barrett, A. M. (2018). Conventional and functional assessment of spatial neglect: Clinical practice suggestions. *Neuropsychology*, 32(7), 835–842. <https://doi.org/10.1037/neu0000469>
- Rathnayake, R., Madhushan, N., Jeeva, A., Darshani, D., Subasinghe, A., Silva, B. N., Wijesinghe, L. P., & Wijenayake, U. (2023). Current Trends in Human Pupil Localization: A Review. *IEEE Access*, 11, 115836–115853. <https://doi.org/10.1109/ACCESS.2023.3325293>
- Saxena, S., Fink, L. K., & Lange, E. B. (2024). Deep learning models for webcam eye tracking in online experiments. *Behavior Research Methods*, 56(4), 3487–3503. <https://doi.org/10.3758/s13428-023-02190-6>
- Saxena, S., Lange, E., & Fink, L. (2022). Towards efficient calibration for webcam eye-tracking in online experiments. *2022 Symposium on Eye Tracking Research and Applications, ETRA '22*, 1–7. <https://doi.org/10.1145/3517031.3529645>
- Schad, D. J., Vasishth, S., Hohenstein, S., & Kliegl, R. (2020). How to capitalize on a priori contrasts in linear (mixed) models: A tutorial. *Journal of Memory and Language*, 110, 104038. <https://doi.org/10.1016/j.jml.2019.104038>
- Schielzeth, H., Dingemanse, N. J., Nakagawa, S., Westneat, D. F., Allegeue, H., Teplitsky, C., Réale, D., Dochtermann, N. A., Garamszegi, L. Z., & Araya-Ajoy, Y. G. (2020). Robustness of linear mixed-effects models to violations of distributional assumptions.

*Methods in Ecology and Evolution*, 11(9), 1141–1152. <https://doi.org/10.1111/2041-210X.13434>

Singmann, H., Bolker, B., Westfall, J., Aust, F., Ben-Shachar, M. S., Højsgaard, S., Fox, J., Lawrence, M. A., Mertens, U., & Love, J. (2015). *Package 'afex'* [Software]. Citeseer. <https://github.com/singmann/afex>

Snijders, T. A. B., & Bosker, R. J. (2011). *Multilevel analysis: An introduction to basic and advanced multilevel modeling* (2nd ed.). Sage.

Soukupová, T., & Čech, J. (2016). Real-time eye blink detection using facial landmarks. In *Proceedings of the 21st Computer Vision Winter Workshop (CVWW 2016)*. Slovenian Pattern Recognition Society

Steffan, A., Zimmer, L., Arias-Trejo, N., Bohn, M., Dal Ben, R., Flores-Coronado, M. A., Franchin, L., Garbisch, I., Grosse Wiesmann, C., Hamlin, J. K., Havron, N., Hay, J. F., Hermansen, T. K., Jakobsen, K. V., Kalinke, S., Ko, E.-S., Kulke, L., Mayor, J., Meristo, M., ... Schuwerk, T. (2024). Validation of an open source, remote web-based eye-tracking method (WebGazer) for research in early childhood. *Infancy*, 29(1), 31–55. <https://doi.org/10.1111/infa.12564>

Tang, C., Zhang, R., Gao, S., Zhao, Z., Zhang, Z., Wang, J., Li, C., Chen, J., Dai, Y., Wang, S., Juan, R., Li, Q., Xie, R., Chen, X., Zhou, X., Xia, Y., Chen, J., Lu, F., Li, X., ... Occhipinti, L. G. (2025). An AI-Driven Multimodal Smart Home Platform for Continuous Monitoring and Assistance in Post-Stroke Motor Impairment. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 34, 300–312. <https://doi.org/10.1109/TNSRE.2025.3645093>

Terruzzi, S., Albin, F., Massetti, G., Etzi, R., Gallace, A., & Vallar, G. (2024). The Neuropsychological Assessment of Unilateral Spatial Neglect Through Computerized and Virtual Reality Tools: A Scoping Review. *Neuropsychology Review*, 34(2), 363–401. <https://doi.org/10.1007/s11065-023-09586-3>

Thaler, L., Schütz, A. C., Goodale, M. A., & Gegenfurtner, K. R. (2013). What is the best fixation target? The effect of target shape on stability of fixational eye movements. *Vision Research*, 76, 31–42. <https://doi.org/10.1016/j.visres.2012.10.012>

Tromp, E., Dinkla, A., & Mulder, T. (1995). Walking through doorways: An analysis of navigation skills in patients with neglect. *Neuropsychological Rehabilitation*, 5(4), 319–331. <https://doi.org/10.1080/09602019508401475>

Uimonen, J., Villarreal, S., Laari, S., Arola, A., Ijäs, P., Salmi, J., & Hietanen, M. (2024). Virtual reality tasks with eye tracking for mild spatial neglect assessment: A pilot study with acute stroke patients. *Frontiers in Psychology*, 15. <https://doi.org/10.3389/fpsyg.2024.1319944>

Vos, M., Minor, S., & Ramchand, G. C. (2022). *Comparing infrared and webcam eye tracking in the Visual World Paradigm*. <https://doi.org/10.5070/G6011131>

Wang, Y., Yan, R., Lei, Y., & Fu, X. (2025). *PTGaze: Cross-Domain Gaze Estimation via Proxy Tuning*. 1–2. <https://doi.org/10.1145/3715669.3726821>

- Weintraub, S., & Mesulam, M. M. (1988). Visual hemispatial inattention: Stimulus parameters and exploratory strategies. *Journal of Neurology, Neurosurgery & Psychiatry*, 51(12), 1481–1488. <https://doi.org/10.1136/jnnp.51.12.1481>
- Wickham, H., Averick, M., Bryan, J., Chang, W., McGowan, L. D., François, R., Grolemund, G., Hayes, A., Henry, L., Hester, J., Kuhn, M., Pedersen, T. L., Miller, E., Bache, S. M., Müller, K., Ooms, J., Robinson, D., Seidel, D. P., Spinu, V., ... Yutani, H. (2019). Welcome to the Tidyverse. *Journal of Open Source Software*, 4(43), 1686. <https://doi.org/10.21105/joss.01686>
- Williams, L. J., Kernot, J., Hillier, S. L., & Loetscher, T. (2021). Spatial Neglect Subtypes, Definitions and Assessment Tools: A Scoping Review. *Frontiers in Neurology*, 12. <https://www.frontiersin.org/journals/neurology/articles/10.3389/fneur.2021.742365>
- Williams, L. J., Loetscher, T., Hillier, S., Hreha, K., Jones, J., Bowen, A., & Kernot, J. (2025). Identifying spatial neglect – an updated systematic review of the psychometric properties of assessment tools in adults post-stroke. *Neuropsychological Rehabilitation*, 35(3), 628–667. <https://doi.org/10.1080/09602011.2024.2346212>
- Wilson, B., Cockburn, J., & Halligan, P. (1987). Development of a behavioral test of visuospatial neglect. *Archives of Physical Medicine and Rehabilitation*, 68(2), 98–102.
- Zhang, X., Park, S., Beeler, T., Bradley, D., Tang, S., & Hilliges, O. (2020). ETH-XGaze: A Large Scale Dataset for Gaze Estimation Under Extreme Head Pose and Gaze Variation. In A. Vedaldi, H. Bischof, T. Brox, & J.-M. Frahm (Hrsg.), *Computer Vision – ECCV 2020* (S. 365–381). Springer International Publishing. [https://doi.org/10.1007/978-3-030-58558-7\\_22](https://doi.org/10.1007/978-3-030-58558-7_22)

## **Appendix A: Eigenständigkeitserklärung und Erklärung zur Nutzung von KI**

### **Eigenständigkeitserklärung:**

Hiermit bestätige ich, dass ich die vorliegende Arbeit (Titel: Softwarebasierte Blickrichtungserkennung zur Diagnostik räumlichen Neglects: eine empirische Evaluation) selbstständig und ohne fremde Hilfe verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Die Arbeit hat in gleicher oder ähnlicher Form noch keiner Prüfungsbehörde vorgelegen und wurde nicht veröffentlicht.

München, 19.02.2026

---

(Unterschrift)

## **Erklärung zur Nutzung von generativer KI und KI-gestützten Technologien im Schreibprozess**

Bei der Erstellung dieser Arbeit habe ich, Imanuel Köthnig folgende Tools verwendet: Claude, Gemini und ChatGPT.

Art der Nutzung:

- Verbesserung der sprachlichen Qualität und Lesbarkeit
- Schreibassistent z. B. zum Erstellen von Inhaltsverzeichnissen, Gliederungen, ersten Sätzen und Absätzen
- Auffinden von relevanten Zitaten, die als solche gekennzeichnet sind
- Auffinden von relevanten wissenschaftlichen Quellen, die als solche gekennzeichnet sind
- Übersetzung von Zitaten oder Textabschnitten, die als solche gekennzeichnet sind (etwa: „Translated with DeepL“)
- Zusammenfassung von Information
- Texttranskription von Audio- oder Videodateien
- Erstellen von Bild- oder Videomaterial
- Erstellen bzw. verbessern von Programmiercode (bspw. R- oder Python-Code)
- Recherche zu Begriffen
- Erstellen von Begriffsdefinitionen
- Sonstiges [bitte erläutern]:

Nach der Nutzung dieses Tools bzw. Dienstes habe ich den Inhalt überprüft, nach Bedarf bearbeitet und ich übernehme die volle Verantwortung für den Inhalt dieser Arbeit. Ich bestätige, dass diese Arbeit keine längeren Passagen (z.B. Zusammenfassung/Abstract der Arbeit, ganze Absätze im Text) an rein KI-generiertem Text enthält.

München, 19.02.2026

---

(Unterschrift)

## Appendix B: Zusätzliche Ergebnisse

**Tabelle B1**



*Ergebnisse der Repeated-Measures ANOVA*



| AV          | Effekt                                 | <i>df</i>      | <i>F</i>    | <i>p</i>    | $\eta_p^2$   |
|-------------|----------------------------------------|----------------|-------------|-------------|--------------|
| Bias        | Methode                                | (1, 11)        | 0.40        | .540        | 0.035        |
|             | Kamera                                 | (1, 11)        | 1.53        | .241        | 0.122        |
|             | Kalibrierung                           | (1, 11)        | 0.03        | .857        | 0.003        |
|             | Methode x Kamera                       | (1, 11)        | 0.26        | .621        | 0.023        |
|             | Methode x Kalibrierung                 | (1, 11)        | 0.13        | .722        | 0.012        |
|             | Kamera x Kalibrierung                  | (1, 11)        | 0.11        | .748        | 0.010        |
|             | Methode x Kamera x Kalibrierung        | (1, 11)        | 0.76        | .402        | 0.065        |
| Steigung    | Methode                                | (1, 11)        | 15.01       | .003        | 0.577        |
|             | Kamera                                 | (1, 11)        | 53.84       | < .001      | 0.830        |
|             | Kalibrierung                           | (1, 11)        | 7.26        | .021        | 0.397        |
|             | Methode x Kamera                       | (1, 11)        | 0.03        | .857        | 0.003        |
|             | Methode x Kalibrierung                 | (1, 11)        | 2.27        | .160        | 0.171        |
|             | Kamera x Kalibrierung                  | (1, 11)        | 0.40        | .540        | 0.035        |
|             | <b>Methode x Kamera x Kalibrierung</b> | <b>(1, 11)</b> | <b>6.82</b> | <b>.024</b> | <b>0.383</b> |
| Korrelation | Methode                                | (1, 11)        | 22.97       | < .001      | 0.676        |
|             | Kamera                                 | (1, 11)        | 338.62      | < .001      | 0.969        |
|             | <b>Kalibrierung</b>                    | <b>(1, 11)</b> | <b>6.09</b> | <b>.031</b> | <b>0.357</b> |
|             | Methode x Kamera                       | (1, 11)        | 59.73       | < .001      | 0.844        |
|             | Methode x Kalibrierung                 | (1, 11)        | 4.47        | .058        | 0.289        |
|             | Kamera x Kalibrierung                  | (1, 11)        | 1.37        | .267        | 0.110        |
|             | Methode x Kamera x Kalibrierung        | (1, 11)        | 3.82        | .077        | 0.258        |



*Anmerkung.*  $N = 12$ . Die Freiheitsgrade wurden nach Greenhouse-Geisser korrigiert.  $\eta_p^2$  = partielles Eta-Quadrat; Interpretation nach Cohen (2013):  $\geq .01$  = kleiner Effekt,  $\geq .06$  = mittlerer Effekt,  $\geq .14$  = großer Effekt. Die Korrelationswerte wurden vor der Analyse Fisher-z-transformiert. Bias, Steigung und Korrelation beziehen sich auf die horizontale Blickachse (x-Koordinate). Fett gedruckte Effekte weichen in ihrer Signifikanz von den LMM-Ergebnissen ab (siehe Tabelle 2).



## Abbildung B1

*Blickverlauf (Eyetracker) während der Videokalibrierung bei variierender Zielgeschwindigkeit in Reihenfolge der Versuchsdurchführung*












*Anmerkung.* Dargestellt sind die mittels EyeLink 1000 erfassten Blickverläufe einer Neglect-Patientin während acht Kalibrierungsdurchgängen. Der Farbverlauf kodiert den zeitlichen Fortschritt (blau = Beginn, rot = Ende). Die nummerierten Kreise (0–9) markieren die Soll-Positionen der Kalibrierungspunkte, wobei 0/5 den Start- und Mittelpunkt bezeichnet. Obere vier Panels: Durchgänge mit Startrichtung links oben (200–500 px/s). Untere vier Panels: Durchgänge mit Startrichtung rechts unten (200–500 px/s). Grauer Rahmen = Bildschirmbereich (1920 × 1080 px). Bildschirmkoordinaten mit invertierter Y-Achse (0 = oben).


## Abbildung B2

*Vergleich der Computer-Vision-basierten Blickschätzung während der Videokalibrierung in Reihenfolge der Versuchsdurchführung*









*Anmerkung.* Dargestellt sind die mittels MediaPipe (linke Spalte) und PTGaze (rechte Spalte) geschätzten Blickpositionen derselben Kalibrierungsdurchgänge wie in Abbildung B1. Der Farbverlauf kodiert den zeitlichen Fortschritt (blau = Beginn, rot = Ende). Die nummerierten Kreise markieren die Soll-Positionen der Kalibrierungspunkte. Zielgeschwindigkeiten und Startrichtungen wie angegeben. Grauer Rahmen = Bildschirmbereich ( $1920 \times 1080$  px). Bildschirmkoordinaten mit invertierter Y-Achse (0 = oben).

## Appendix C: Pipelineübersicht

**CONFIG.PY.** Dieses Skript enthält die zentrale Definition aller Zustandsvariablen für alle Skripte der Pipeline. Es wird nicht ausgeführt.

**MASTER\_CLI.PY.** Dies ist die zentrale Steuerungsdatei der gesamten Analyse-Pipeline. Sie orchestriert alle `debug_.py` Skripte über ein interaktives Command-Line-Interface (CLI), verwaltet mehrere Versuchspersonen (VPs) parallel, bietet intelligentes Cache-Management zur Vermeidung redundanter Berechnungen, und koordiniert verschiedene Konfigurationen (Video-FPS, Kalibrierungs-Modi, Methoden).

**0\_PHASE\_DETECTION.PY.** Dieses Skript findet automatisch heraus, wann welche Phase des Experiments im Video stattfand (z.B. "Kalibrierung startet bei Sekunde 15"). Dazu analysiert es Audio-Pieptöne (Marker), die während der Aufnahme eingespielt wurden, und gleicht sie mit einem JSON-Protokoll ab, das die geplanten Zeitpunkte enthält. Da Video und Experiment nicht perfekt synchron laufen (Drift), korrigiert es zeitliche Verschiebungen mathematisch.

**1\_VIDEO\_ANALYSIS.PY.** Dieses Skript verarbeitet das Webcam-Video Frame für Frame und extrahiert die Pupillenpositionen mittels MediaPipe (Iris-Landmarks). Es nutzt die automatische Phasendetektion aus Skript 0, um nur relevante Trial-Abschnitte zu verarbeiten (spart Zeit), oder verarbeitet im Fallback-Modus das gesamte Video. Zusätzlich erkennt es Blinks (Augen geschlossen) und Kopfhaltung (Head-Pose).

**1\_VIDEO\_ANALYSIS\_PTG.PY.** Dieses Skript verarbeitet das Webcam-Video Frame für Frame und schätzt die Blickrichtung (Gaze) mittels `ptgaze` (ETH-XGaze CNN-Modell). Im Gegensatz zu MediaPipe (Pupillenpositionen in Pixel) liefert `ptgaze` direkt Blickwinkel in Grad (pitch/yaw). Es nutzt die Phasendetektion aus Skript 0 für gezielte Trial-Extraktion und erkennt zusätzlich Blinks und Bad Samples (außerhalb Monitor, niedrige Confidence).

**2\_OFFLINE\_CALIBRATION.PY.** Dieses Skript erstellt ein mathematisches Kalibrierungsmodell, das rohe Pupillenpositionen (in Pixeln aus `debug_1`) in Bildschirmkoordinaten umwandelt. Es nutzt die Kalibrierungsphasen aus `debug_0` (`phases_detected.json`), extrahiert für jeden Kalibrierpunkt die Pupillenposition aus dem Video und trainiert ein Regressionsmodell (linear oder polynomial). Das Ergebnis wird als `.pkl`-Datei gespeichert

und von debug\_5 verwendet, um die Pupillendaten des gesamten Experiments zu kalibrieren.

**2\_OFFLINE\_CALIBRATION\_PTG.PY.** Dieses Skript erstellt ein mathematisches Kalibrierungsmodell für ptgaze-Daten, das rohe Blickwinkel (pitch/yaw in Grad aus debug\_1\_ptgaze) in Bildschirmkoordinaten umwandelt. Es ist funktional identisch zu offline\_calibration.py, nutzt aber ptgaze-Gaze-Angles statt MediaPipe-Pupillenpositionen als Input. Das trainierte Modell wird als .pkl-Datei gespeichert und von debug\_5\_ptgaze verwendet.

**3\_EYETRACKER\_LOAD.PY.** Dieses Skript lädt die Daten vom EyeLink (EDF/ASC-Dateien) und strukturiert sie in Trial-basierte Blöcke. Es erkennt automatisch die Experimentphasen (Fixation + Trial) über Messages im Datenstrom, extrahiert Samples, Fixationen, Sakkaden und Blinks, und exportiert die Daten als CSV. Die strukturierten Blöcke werden von debug\_4 zur Synchronisation mit den Webcam-Daten verwendet.

**4\_SYNCHRONIZATION.PY.** Dieses Skript synchronisiert die Webcam-Zeitachse (debug\_1) mit der EyeLink-Zeitachse (debug\_3), indem es den bereits berechneten Offset aus debug\_0 (phases\_detected.json) anwendet. Es ordnet außerdem jedes Webcam-Frame dem entsprechenden Trial zu und überträgt optional MediaPipe-Blink-Daten auf ptgaze (da MediaPipe-Blink-Detection stabiler ist).

**5\_CALIBRATION\_APPLY.PY.** Dieses Skript wendet das trainierte Kalibrierungsmodell (aus offline\_calibration.py) auf die Pupillendaten an und transformiert rohe Pixelkoordinaten in kalibrierte Bildschirmkoordinaten und Gradsehwinkel.

**5\_CALIBRATION\_APPLY\_PTG.PY.** Dieses Skript wendet das trainierte ptgaze-Kalibrierungsmodell (aus offline\_calibration\_ptgaze.py) auf die Gaze-Angles-Daten an und transformiert rohe Blickwinkel (pitch, yaw in Grad) in kalibrierte Bildschirmkoordinaten und finale Gradsehwinkel. Es ist funktional identisch zu debug\_5\_partial\_calibration.py, nutzt aber Gaze Angles statt Pupillenpositionen als Input.

**6\_COMPARISON.PY.** Dieses Skript führt den finalen 3-Wege-Vergleich zwischen den Gaze-Schätzungen durch: MediaPipe vs. ptgaze vs. EyeLink (Modus 2) oder MediaPipe vs. ptgaze (Modus 1). Es berechnet für jeden Trial den mittleren Blickwinkel unter Ausschluss von Blinks und außerhalb-Monitor-Samples, wendet paarweise Vergleichsmetriken

an (Pearson-Korrelation, Bland-Altman-Analyse, Lateralisierungs-Übereinstimmung), und erstellt Visualisierungen zur Qualitätskontrolle.

## **0\_PHASE\_DETECTION.PY**

### **Ablauf Step-by-Step:**

1. JSON-Log laden und Format erkennen
  - Lädt die Datei `experiment_sync_log.json` (enthält: geplante Zeitpunkte aller Events)
  - Erkennt, welche Version des Formats vorliegt
  - Übernimmt Metadaten (z.B. Bildschirmgröße, Anzahl Trials)
2. Audio aus Video extrahieren
  - Holt die Tonspur aus der Videodatei
  - Bereitet sie für Frequenzanalyse vor (z.B. Spektrogramm)
3. Initiale Synchronisationspunkte finden
  - Sucht nach dem ersten 1760 Hz Piepston (Kalibrierungs-Marker)
  - Dieser muss isoliert sein (mind. 30 Sek. Stille davor) → klarer Startpunkt
  - Berechnet initialen Offset: "Video-Sekunde X = Experiment-Sekunde Y"
4. Alle Audio-Marker sammeln
  - Detektiert drei Frequenzen im gesamten Video:
    - 1760 Hz = Kalibrierung startet
    - 440 Hz = Fixationskreuz erscheint (Trial-Vorbereitung)
    - 880 Hz = Trial (Aufgabe) startet
  - Speichert jeden gefundenen Marker mit Zeitstempel
5. Multi-Anchor-Regression (Drift-Korrektur)
  - Problem: Video läuft nicht exakt synchron zum Experiment (z.B. 59,97 fps statt 60)
  - Lösung: Nutzt alle gefundenen Marker als Referenzpunkte ("Anker")
  - Berechnet lineare Regression → findet beste Zeitverschiebung/Streckung
6. Phasen rekonstruieren
  - Wendet korrigierten Offset auf alle Events an
  - Erstellt Zeitstempel für:

- Kalibrierungen (z.B. "Kal. 1: 15.2s - 24.8s")
- Trials (z.B. "Trial 1: Fixation 30.1s, Stimulus 32.0s")

## 7. Post-Validierung

- Prüft: Wurden alle erwarteten Marker gefunden? (mind. 75%)
- Prüft: Passen die Abstände zwischen Markern? (max.  $\pm 500$ ms Abweichung)

## 8. QC-Reports generieren

- Spektrogramm: Zeigt Audio-Frequenzen über Zeit (visuell prüfbar)
- Statistik-Plots: Zeigt Abweichungen der Marker
- Sync-Kandidaten: Zeigt gefundene Sync-Punkte zur Kontrolle

## 9. Export

- Speichert phases\_detected.json → wird von nächsten Skripten genutzt
- Speichert Event-Tabelle (CSV) zur manuellen Prüfung
- Speichert QC-Plots als Bilder

# 1\_VIDEO\_ANALYSIS.PY

## Ablauf Step-by-Step:

### 1. Prüfe: Phasen-Detektion verfügbar?

- Sucht nach phases\_detected.json (aus debug\_0)
- Falls vorhanden → Phase-Modus (nur Trials verarbeiten)
- Falls nicht → Legacy-Modus (ganzes Video)

### 2. Video laden

- Öffnet Videodatei (.mp4)
- Liest Metadaten: FPS, Auflösung, Framelänge

### 3. MediaPipe Face Mesh initialisieren

- Lädt vortrainiertes Modell für Gesichts-Landmarks
- 478 Landmarks pro Gesicht, davon 5 pro Iris (links/rechts)

### 4. Frame-by-Frame Verarbeitung (Hauptschleife)

- 4a) Gesicht detektieren: MediaPipe sucht Gesicht im Frame
- 4b) Iris-Landmarks extrahieren: 5 Punkte pro Auge → Mittelpunkt = Pupillenposition

- 4c) Qualitätsprüfung:
    - Wie viele Landmarks sichtbar? (0-5 pro Auge → Quality 0.0-1.0)
    - Augenabstand plausibel? (min/max IPD-Check)
  - 4d) Blink Detection:
    - Berechnet EAR (Eye Aspect Ratio) aus Lidabstand
    - $EAR < \text{Threshold}$  → Augen geschlossen
  - 4e) Daten sammeln: Speichert alles in Liste
5. QS-Video erstellen (Quality Control)
- Zeichnet pro Frame:
    - Grüne Kreise: Linke/Rechte Pupille einzeln
    - Gelber Kreis: Qualitätsgewichteter Mittelwert
    - Info-Overlay: EAR-Balken, Blink-Counter, Head-Pose
  - Speichert als debug\_1\_pupil\_video.mp4
6. CSV exportieren
- Spalten: frame, timestamp\_ms, trial\_number, left/right\_pupil\_x/y\_px\_raw, avg\_pupil\_x/y\_px\_raw
  - Wichtig: Nur ROH-Daten (keine Glättung, keine Spiegelung)
  - Zusätzlich: confidence, left/right\_quality, head\_yaw/pitch/roll, is\_blink, avg\_ear
7. Statistik ausgeben
- Detection Rate (% erfolgreiche Frames)
  - Mittelwert/Streuung der Pupillenposition
  - Durchschnittliche Confidence/Quality
  - Anzahl Blinks

## 1\_VIDEO\_ANALYSIS\_PTG.PY

### Ablauf Step-by-Step:

1. Prüfe: Phasen-Detektion verfügbar?
  - Sucht nach phases\_detected.json (aus debug\_0)
  - Falls vorhanden → Phase-Modus (nur Trials verarbeiten)
  - Falls nicht → Legacy-Modus (ganzes Video)

## 2. Video laden

- Öffnet Videodatei (.mp4)
- Liest Metadaten: FPS, Auflösung, Framelänge

## 3. ptgaze Gaze Estimator initialisieren

- Lädt ETH-XGaze Modell (vortrainiert auf MPIIFaceGaze/ETH-XGaze Dataset)
- Initialisiert MediaPipe Face Mesh (für Face Detection)
- Initialisiert BlinkDetector (MediaPipe EAR-basiert)
- Initialisiert BadSampleDetector (Outside Monitor + Confidence)

## 4. Frame-by-Frame Verarbeitung (Hauptschleife)

- 4a) Gesicht detektieren: MediaPipe Face Mesh findet Gesicht
- 4b) Gaze Estimation: ptgaze CNN berechnet Blickrichtung
  - Input: Face Bounding Box + Eye Regions
  - Output: gaze\_pitch\_deg (oben/unten), gaze\_yaw\_deg (links/rechts)
  - Zusätzlich: gaze\_vector (3D Unit Vector)
- 4c) Head-Pose Extraktion:
  - Berechnet yaw/pitch/roll (Kopfdrehung)
- 4d) Blink Detection:
  - MediaPipe EAR (Eye Aspect Ratio)
  - $EAR < \text{Threshold} \rightarrow$  Augen geschlossen
- 4e) Daten sammeln: Speichert alles in Liste

## 5. QS-Video erstellen (ptgaze Visualizer)

- Zeichnet pro Frame:
  - Face Bounding Box (Gesichtserkennung)
  - Gaze Vector (3D Linie vom Gesicht in Blickrichtung)
  - Head-Pose Axes (X/Y/Z Koordinatensystem am Kopf)
  - Info-Overlay: Pitch/Yaw, EAR-Balken, Blink-Counter, Warnungen
- Speichert als debug\_1\_ptgaze\_video.mp4

## 6. CSV exportieren

- Spalten: frame, timestamp\_ms, trial\_number
- Gaze: gaze\_pitch\_deg, gaze\_yaw\_deg (in Grad!), gaze\_vector\_x/y/z

- Quality: confidence, detected
- Blink: is\_blink, left/right/avg\_ear, eyes\_closed
- Head-Pose: head\_yaw/pitch/roll
- Bad Samples: outside\_monitor, corrupt\_sample

## 7. Statistik ausgeben

- Detection Rate (% erfolgreiche Frames)
- Mittelwert/Streuung Blickwinkel (Pitch/Yaw)
- Durchschnittliche Confidence
- Anzahl Blinks
- Good Samples (ohne Blinks, ohne Bad Flags)

## 2\_OFFLINE\_CALIBRATION.PY

### Ablauf Step-by-Step:

1. Kalibrierungsmodus festlegen (NEU v3.3)
  - Liest CALIB\_MODE aus Environment-Variable
  - Verfügbare Modi: FullCalib, BegEnd, OnlyBeg, OnlyEnd, BegFirst10, BegSecond10, etc.
  - Bestimmt: Welche Phasen (beg/mid/end) + welche Punkte + Fixationen ja/nein
2. Prüfe: phases\_detected.json vorhanden?
  - Standard-Modus → Lädt phases\_detected.json
  - Temporal Pooling-Modus → Lädt phases\_detected\_beg.json, \*\_mid.json, \*\_end.json
3. Extrahiere Kalibrierpunkte aus JSON
  - Liest für jede Kalibrierphase (beg/mid/end):
    - Punkt-ID, Bildschirmposition (x, y), Video-Zeitstempel
  - Filtert nach Kalibrierungsmodus (z.B. nur erste 10 Punkte)
4. Video öffnen
  - Öffnet Video einmal und cached es
  - Verhindert 32× VideoCapture() bei 32 Punkten → 3-5× schneller
5. Für jeden Kalibrierpunkt: Pupillenposition extrahieren

- 5a) Video zu Zeitstempel springen
  - Nutzt Video-Zeit aus JSON (bereits drift-korrigiert durch debug\_0!)
- 5b) Zeitfenster definieren
  - Standard: 0.5s-3.0s nach Marker (EXTRACTION\_WINDOW)
- 5c) Frame-by-Frame-Extraktion
  - Detektiert Pupille in jedem Frame (MediaPipe, wie debug\_1)
  - Filtert nach Confidence (MIN\_CONFIDENCE)
- 5d) Aggregation
  - Median über alle Frames im Fenster (robust gegen Outliers)
  - Optional: Extrahiert auch Head-Pose (Yaw/Pitch/Roll)
- 5e) Sammeln
  - Speichert: Pupillenposition, Bildschirmziel, Punkt-Typ
- 6. Optional: Fixationspunkte hinzufügen
  - Nutzt Trial-Fixationen als zusätzliche Kalibrierpunkte
  - Zielposition: Bildschirmmitte
  - Extrahiert Pupille 0.6s-2.4s nach Fixation-Start
- 7. Validierung
  - Prüft: Mindestens 8 Punkte erfolgreich extrahiert?
  - Falls nein → Abbruch mit Fehler
- 8. Head-Pose-Referenz berechnen
  - Falls ENABLE\_HEAD\_POSE\_CORRECTION = True:
    - Berechnet Median-Head-Pose über alle Punkte
    - Speichert als Referenz (für adaptive Korrektur in debug\_5)
- 9. Gewichtung berechnen
  - Punkt-Typ-Gewichtung:
    - Normale Kalibrierpunkte: 1.0
    - Center (Mitte):  $1.0 - \text{CENTER\_CALIBRATION\_WEIGHT}$
    - Fixationen-Center:  $\text{CENTER\_CALIBRATION\_WEIGHT}$
  - Temporale Gewichtung (nur bei Temporal Pooling):
    - Neuere Punkte (end) bekommen höheres Gewicht

- `weight *= exp(TEMPORAL_DECAY_FACTOR * t)`

## 10. Modell trainieren

- 10a) Daten vorbereiten:
  - Input (X): Pupillenpositionen [(x\_pupil, y\_pupil), ...]
  - Output (y): Bildschirmpositionen [(x\_screen, y\_screen), ...]
- 10b) Regression wählen:
  - `POLYNOMIAL_DEGREE = 1` → Linear (2 Parameter pro Achse)
  - `POLYNOMIAL_DEGREE = 2` → Quadratisch (6 Parameter, korrigiert Verzerrung)
- 10c) Training:
  - Trainiert zwei separate Modelle (X-Achse, Y-Achse)
  - Nutzt Ridge-Regression (bei Polynom, verhindert Overfitting)
  - Wendet Gewichte an (`sample_weight`)
- 10d) Qualitätsmetrik:
  - Berechnet  $R^2$  (Coefficient of Determination)
  - $R^2 > 0.7$  = gut,  $< 0.7$  = Warnung

## 11. Modell speichern (.pkl)

- Dateiname: `calibration_{video_name}_{timestamp}.pkl`
- Inhalt:
  - `model_x`, `model_y` (trainierte Regressionsmodelle)
  - `screen_params` (Bildschirm-Dimensionen)
  - `r2_scores` (Qualität)
  - `reference_head_pose` (optional)
  - `calib_mode`, `point_types`, `pupil_points`, etc.

## 12. Video-Cache schließen

- Gibt alle gecachten VideoCapture-Objekte frei

## 2\_OFFLINE\_CALIBRATION\_PTG.PY

### Ablauf Step-by-Step:

1. Kalibrierungsmodus festlegen (analog zu MediaPipe)
  - Liest `CALIB_MODE` aus Environment-Variable

- Identische Modi wie offline\_calibration.py
- 2. Prüfe: phases\_detected.json vorhanden?
  - Standard-Modus → phases\_detected.json
  - Temporal Pooling → phases\_detected\_beg/mid/end.json
- 3. Extrahiere Kalibrierpunkte aus JSON
  - Identisch zur MediaPipe-Version
  - Filtert nach Kalibrierungsmodus
- 4. Video öffnen (Performance-Optimierung!)
  - Identisch zur MediaPipe-Version (gecacht)
- 5. Für jeden Kalibrierpunkt: Gaze Angles extrahieren
  - 5a) Video zu Zeitstempel springen
  - 5b) Zeitfenster definieren (0.5s-3.0s)
  - 5c) Frame-by-Frame-Extraktion:
    - Nutzt ptgaze Gaze Detector (statt MediaPipe)
    - Detektiert Gesicht + schätzt Blickrichtung (CNN)
    - Output: pitch\_deg, yaw\_deg (statt pupil\_x, pupil\_y)
  - 5d) Aggregation:
    - Median über alle Frames (pitch und yaw separat)
    - Optional: Extrahiert Head-Pose
  - 5e) Sammeln:
    - Speichert: (pitch, yaw) ← in pupil\_measurements (Name bleibt!)
    - Speichert: Bildschirmziel, Punkt-Typ
- 6. Optional: Fixationspunkte hinzufügen
  - Identisch zur MediaPipe-Version
  - Extrahiert Gaze Angles statt Pupillenpositionen
- 7. Validierung
  - Mindestens 8 Punkte? (gleich wie MediaPipe)
- 8. Head-Pose-Referenz berechnen
  - Identisch zur MediaPipe-Version
- 9. Gewichtung berechnen

- Identisch zur MediaPipe-Version

#### 10. Modell trainieren

- 10a) Daten vorbereiten:
  - Input (X): Gaze Angles [(pitch\_deg, yaw\_deg), ...]
  - Output (y): Bildschirmpositionen [(x\_screen, y\_screen), ...]
- 10b) Regression wählen:
  - Identisch (Linear oder Polynomial Degree 2)
- 10c) Training:
  - Trainiert zwei Modelle: (pitch, yaw) → screen\_x und (pitch, yaw) → screen\_y
- 10d) Qualitätsmetrik:
  - $R^2$  wie bei MediaPipe

#### 11. Modell speichern (.pkl)

- Dateiname: calibration\_ptgaze\_{video}\_{timestamp}.pkl
- Wichtig: input\_type: 'gaze\_angles' (statt 'pupil\_pixels')
- Sonst identische Struktur

#### 12. Video-Cache schließen

- Identisch zur MediaPipe-Version

### 3\_EYETRACKER\_LOAD.PY

#### Ablauf Step-by-Step:

1. Modus-Check
  - Prüft: Ist ANALYSIS\_MODE = 2?
  - Falls Modus 1 → Warnung + Exit (EyeLink nicht benötigt)
2. Datei-Format erkennen
  - Input: .edf (binär) oder .asc (Text)
  - Falls EDF → Konvertierung zu ASC via edf2asc Tool
3. ASC-Datei parsen (Hauptaufgabe)
  - 3a) Alle Daten einlesen:
    - Samples: Zeitstempel, x/y-Position, Pupillengröße (z.B. 1000 Hz)
    - EFIX (Fixationen): Start/End-Zeit, Position, Dauer

- ESACC (Sakkaden): Start/End-Koordinaten, Amplitude, Geschwindigkeit
- EBLINK (Blinks): Start/End-Zeit, Dauer
- MSG (Messages): Experiment-Marker (z.B. "start\_trial\_1")
- 3b) Messages analysieren:
  - Sucht nach Trial-Markern:
    - start\_fixation\_X → Fixationskreuz erscheint (440 Hz Audio)
    - end\_fixation\_X → Fixationskreuz verschwindet (880 Hz Audio)
    - start\_trial\_X → Stimulus (Bild) erscheint
    - end\_trial\_X → Trial endet
  - Extrahiert Trial-Nummer (X = 1-24, oder "practice" für Übungstrial)
- 4. Trial-Struktur aufbauen
  - Für jeden Trial werden zwei Blöcke erstellt:
    - Fixation-Block: Von start\_fixation\_X bis end\_fixation\_X
    - Trial-Block: Von start\_trial\_X bis end\_trial\_X
- 5. Daten zeitbasiert zuordnen
  - Filtert Samples/Fixationen/Sakkaden nach Zeitstempel
  - Ordnet sie dem entsprechenden Block zu
  - Beispiel: Fixationen zwischen 1000ms-2500ms → gehören zu Fixation-Block 1
- 6. Validierung & Timeline-Analyse
  - Prüft:
    - Wurden alle erwarteten Trials gefunden?
    - Sind Messages vollständig?
    - Stimmen die Zeitabstände? (Gap zwischen Fixation und Trial ~0-10ms)
  - Zeigt Timeline der ersten 3 Trials zur Kontrolle
- 7. Export (3-4 Dateien)
  - debug\_3\_blocks\_overview.csv → PRIMÄR: Zusammenfassung aller Blöcke

- debug\_3\_metadata.json → Recording-Infos (Sample-Rate, Dauer, etc.)
- debug\_3\_eyetracker\_data.csv → Optional: Alle Samples
- debug\_3\_fixations.csv → Optional: Alle Fixationen mit Block-Zuordnung

#### 4\_SYNCHRONIZATION.PY

##### Ablauf Step-by-Step:

1. Modus-Check
  - Ist ANALYSIS\_MODE = 2?
  - Falls Modus 1 → Exit (Synchronisation nicht nötig)
2. Prüfe: phases\_detected.json vorhanden?
  - Falls NEIN → Abbruch (debug\_0 muss zuerst laufen)
  - Falls JA → Lade Offset daraus
3. Lade Offset aus phases\_detected.json
  - Liest sync\_info['offset\_ms'] (bereits von debug\_0 berechnet)
  - Prüft: Dual-Anchor? → Nutze offset\_880hz\_ms (für Trials optimiert)
  - Sonst: Nutze gemischten Offset
4. Lade Webcam-Daten
  - MediaPipe: debug\_1\_pupil\_data.csv
  - Optional ptgaze: debug\_1\_ptgaze\_data.csv (falls vorhanden)
5. Wende Offset an (Hauptaufgabe)
  - Eine Zeile Code: timestamp\_ms\_synced = timestamp\_ms + offset\_ms
  - Effekt: Webcam-Zeit wird auf EyeLink-Zeit gemappt
  - Fügt Spalten hinzu: timestamp\_ms\_synced, sync\_method, sync\_confidence
6. Trial-Zuordnung aus phases\_detected.json
  - Extrahiert alle Trials aus JSON
  - Für jeden Trial: Start = Fixation-Start, Ende = Stimulus-Ende
  - Ordnet jedes Webcam-Frame einem Trial zu (1-24)
  - Speichert in Spalte: trial\_assignment
  - Ordne jedes Webcam-Frame einer Phase zu (fixation oder stimulus)
  - Speichert in Spalte: phase\_type

## 7. Blink-Merge (nur für ptgaze)

- Problem: ptgaze-Blink-Detection instabil bei 25 Hz Videos
- Lösung: Übertrage MediaPipe-Blink-Daten auf ptgaze
- Methode:
  - Binary (is\_blink, eyes\_closed) → Nearest-Neighbor
  - Continuous (avg\_eye, left\_eye, right\_eye) → Lineare Interpolation
  - Counter (blink\_count) → Forward-Fill

## 8. Validierung (optional)

- Falls debug\_3\_blocks\_overview.csv vorhanden:
  - Prüft Coverage: Wie viele Webcam-Frames liegen in Fixationsphasen?
  - Erwartet: ~80 % Coverage (bei gutem Offset)

## 9. Visualisierung

- Plot mit 3 Panels:
  - Offset-Übersicht (konstanter Wert aus debug\_0)
  - Samples pro Trial (Bar-Chart)
  - Coverage pro Fixationsphase (Farbcodiert: Grün/Orange/Rot)

## 10. Export (2-4 Dateien)

- debug\_4\_pupil\_data\_synced.csv → Synchronisierte MediaPipe-Daten
- debug\_4\_ptgaze\_gaze\_synced.csv → Synchronisierte ptgaze-Daten (optional)
- debug\_4\_sync\_info.json → Metadaten (Offset, Coverage, etc.)
- debug\_4\_sync\_quality.png → Visualisierung

## 5\_CALIBRATION\_APPLY.PY

### Ablauf Step-by-Step:

#### 1. Lade Kalibrierungsmodell (.pkl)

- Lädt trainiertes Polynomial-Modell
- Validiert:  $R^2$  ausreichend? Input-Type korrekt?
- Extrahiert: Modelle (model\_x, model\_y), Polynomial-Transformer, Metadaten

## 2. Spalten-Validierung

- Erkennt CSV-Version: v2.2 (\*\_raw) oder v2.1 (\*\_final)
- Bestimmt Input-Spalten: avg\_pupil\_x\_px\_raw, avg\_pupil\_y\_px\_raw

## 3. Polynomial-Prediction

- 5a) Daten vorbereiten:
  - Input: Korrigierte Pupillenpositionen [(x\_px, y\_px), ...]
  - Filtert nach Confidence
- 5b) Feature-Transformation:
  - Falls Polynomial Grad 2:  $[x, y] \rightarrow [1, x, y, x^2, xy, y^2]$
  - Falls Linear: Keine Transformation
  - Auto-Korrektur bei Feature-Mismatch
- 5c) Prediction:
  - `screen_x = model_x.predict(features)`
  - `screen_y = model_y.predict(features)`
  - Clipping auf `[0, SCREEN_WIDTH_PX]`

## 4. Gradsehwinkel-Transformation

- Konvertiert Bildschirm-Pixel  $\rightarrow$  Gradsehwinkel
- Nutzt Viewing-Distance + Screen-Dimensionen
- Berechnet:  $\text{deg\_x} = \arctan2(\text{pixels\_cm}, \text{distance\_cm}) * 180/\pi$

## 5. Outside-Monitor Detection

- Berechnet Monitor-Grenzen aus Screen-Parametern
- Markiert Samples außerhalb (Spalte: outside\_monitor)

## 6. Blink-Validierung

- Prüft ob Blink-Spalten vorhanden (is\_blink, avg\_ear, etc.)
- Gibt Warnung falls fehlend (wichtig für debug\_6)
- Statistik: N Frames mit geschlossenen Augen, N Blinks

## 7. Manueller Gaze-Offset (Fallback)

- Falls `ENABLE_MANUAL_GAZE_OFFSET = True`
- Addiert festen Offset auf finale Gradsehwinkel
- Nutzen: Quick-Fix für systematische Verschiebungen

8. Qualitäts-Metriken hinzufügen
  - calibration\_r2\_x, calibration\_r2\_y (aus Modell)
  - prediction\_confidence (kombiniert Sync + Detection)
  - outlier\_filtered (Boolean-Maske)
9. Deduplizierung (Failsafe)
  - Entfernt doppelte Timestamps (aus debug\_1 Trial-Overlap)
  - Sortiert nach Zeit, behält ersten Eintrag
10. Export
  - debug\_5\_pupil\_data\_calibrated.csv → Finale Daten
  - debug\_5\_calibration\_info.json → Metadaten\_

## 5\_CALIBRATION\_APPLY\_PTG.PY

### Ablauf Step-by-Step:

1. Lade ptgaze-Kalibrierungsmodell (.pkl)
  - Sucht nach calibration\_ptgaze\_\*.pkl (neueste Datei)
  - Validiert: input\_type = 'gaze\_angles' (WICHTIG!)
  - Falls input\_type = 'pupil\_pixels' → Fehler (falsches PKL!)
2. Spalten-Validierung
  - Prüft: gaze\_pitch\_deg, gaze\_yaw\_deg vorhanden?
  - Falls fehlend → Abbruch
3. Polynomial-Prediction
  - 3a) Daten vorbereiten:
    - Input: Gaze Angles [(pitch\_deg, yaw\_deg), ...]
    - Filtert nach Confidence
  - 3b) Feature-Transformation:
    - Falls Polynomial Grad 2: [pitch, yaw] → [1, pitch, yaw, pitch<sup>2</sup>, pitch·yaw, yaw<sup>2</sup>]
    - Falls Linear: Keine Transformation
  - 3c) Prediction:
    - screen\_x = model\_x.predict(features)
    - screen\_y = model\_y.predict(features)

- Clipping auf [0, SCREEN\_WIDTH\_PX]
- 4. Gradsehwinkel-Transformation
  - Konvertiert Bildschirm-Pixel → Finale Gradsehwinkel
  - Nutzt Viewing-Distance + Screen-Dimensionen
  - Identisch zur MediaPipe-Version
- 5. Plausibilitäts-Check
  - Prüft:  $|\text{deg\_x}| \leq \text{MAX\_PLAUSIBLE\_DEG\_X}$
  - Markiert implausible Samples
- 6. Outside-Monitor Detection
  - Berechnet Monitor-Grenzen aus Screen-Parametern
  - Markiert Samples außerhalb (wichtig für Qualitätskontrolle)
- 7. Blink-Validierung
  - Prüft ob Blink-Spalten vorhanden (von MediaPipe übertragen via debug\_4!)
  - Gibt Warnung falls fehlend
- 8. Qualitäts-Metriken hinzufügen
  - calibration\_method (z.B. "polynomial\_degree\_2\_ptgaze")
  - calibration\_r2\_x, calibration\_r2\_y
  - calibration\_source (PKL-Dateiname)
- 9. Deduplizierung (Failsafe)
  - Identisch zur MediaPipe-Version
- 10. Export
  - debug\_5\_ptgaze\_calibrated.csv → Finale Daten
  - debug\_5\_ptgaze\_calibration\_info.json → Metadaten\*\_

## 6\_COMPARISON.PY

### Ablauf Step-by-Step:

1. Modus-Erkennung
  - Liest ANALYSIS\_MODE aus config.py
  - Modus 1: Nur MediaPipe vs. ptgaze (kein EyeLink)
  - Modus 2: Alle drei Methoden (MediaPipe, ptgaze, EyeLink)

## 2. Daten laden

- MediaPipe: debug\_5\_pupil\_data\_calibrated.csv
- ptgaze: debug\_5\_ptgaze\_calibrated.csv
- EyeLink (nur Modus 2): debug\_3\_eyetracker\_data.csv
- phases\_detected.json: Trial-Grenzen und Phasen-Informationen

## 3. Trial-Liste extrahieren

- Liest alle experimentellen Trials aus phases\_detected.json
- Unterscheidet zwischen Fixations- und Stimulus-Phase
- Ignoriert Practice-Trials

## 4. Für jeden Trial: Mittelwert berechnen (mit Filterung)

- Phasen-Selektion: Nutzt nur Stimulus-Phase (7 s Bildbetrachtung)
- Blink-Filterung: Entfernt Frames mit geschlossenen Augen + Post-Blink-Recovery
- Outside-Monitor-Filterung: Entfernt Frames außerhalb der Monitorgrenzen
- Valid-Ratio-Check: Mindestens 50 % valide Samples erforderlich
- Mittelwert-Berechnung: Mean über alle validen Frames

## 5. Filterungs-Statistik ausgeben

- Gesamtanzahl gefilterter Frames (Blinks, Outside-Monitor)
- Anzahl rejected Trials pro Methode
- Vergleich der Filterraten zwischen Methoden

## 6. Gesamt-Mittelwerte berechnen

- Mean und Standardabweichung über alle validen Trials
- Tabellarische Übersicht: MediaPipe | ptgaze | EyeLink

## 7. Fixationszeit-Analyse (nur bei EyeLink)

- Berechnet Fixationsanteil aus EyeLink-Daten
- Qualitätsbewertung: >85 % = sehr gut, 70–85 % = gut, <50 % = schlecht

## 8. Paarweise Metriken berechnen

- Für jedes Methodenpaar:
  - Pearson r und Spearman  $\rho$  (Korrelationen)
  - MAE und RMSE (Fehlermaße)
  - Bias und Bland-Altman Limits of Agreement

- Lateralisierungs-Übereinstimmung (links/rechts/mitte)

## 9. Visualisierungen erstellen

- Scatter Plots mit Korrelationskoeffizienten
- Bland-Altman Plots mit Bias und 95 %-LoA
- MAE-Vergleich als Balkendiagramm

## 10. Export

- debug\_6\_three\_way\_comparison.csv: Trial-weise Ergebnisse
- debug\_6\_three\_way\_metrics.json: Alle Metriken
- debug\_6\_three\_way\_comparison.png: Visualisierung

## **MASTER\_CLI.PY**

### **Ablauf Step-by-Step:**

#### 1. Initialisierung

- Lädt VP-Daten-Manager (scannt Ordnerstruktur)
- Prüft R-Verfügbarkeit (für Statistik-Modus)
- Zeigt Hauptmenü

#### 2. Modus-Wahl

- Analysemodus: VP-Daten analysieren (debug\_0 >> debug\_6)
- Statistikmodus: Datensatz für R vorbereiten (ruft statistical\_cli auf)

#### 3. Konfiguration festlegen (NEU v2.2: VOR VP-Auswahl!)

- 3a) Video-Auswahl: 60 Hz, 25 Hz, oder beide
- 3b) Kalibrierungs-Modi: FullCalib, BegEnd, OnlyBeg, Custom, etc.
- 3c) PKL-Quelle: Automatisch oder manuell
- 3d) Analyse-Modus: Modus 1 (Standalone) oder Modus 2 (Comparison)
- 3e) Methoden: MediaPipe, ptgaze, oder beide

#### 4. VP-Auswahl (basierend auf Config)

- Einzelne VP
- Mehrere VPs (Komma-getrennt)
- Alle VPs
- Intelligente Filter:

- VPs ohne passende Analyse (für diese Config)
  - VPs mit fehlgeschlagenen Runs
- Zeigt Status pro VP
- 5. Cache-Dialog (pro VP!)
  - Scannt vorhandene Analyse-Ordner
  - Prüft Kompatibilität (gleicher Video-FPS, gleicher Modus?)
  - Drei Strategien:
    - Automatisch: Nutze alle kompatiblen Daten
    - Keine Cache: Alles neu berechnen
    - Individuell: User entscheidet pro VP und Step
  - Zeigt welche Steps aus Cache kommen
- 6. Zusammenfassung & Bestätigung
  - Zeigt geplante Runs ( $N \text{ VPs} \times M \text{ Videos} \times K \text{ Modi}$ )
  - Cache-Statistik (X Steps aus Cache, Y neu)
  - Geschätzte Dauer ( $\sim 15 \text{ min/Run}$ , reduziert bei Cache)
- 7. Ausführung (Batch-Processing)
  - Für jede VP:
    - Lädt VP-Daten
    - Setzt Environment-Variablen (für Skript-Kommunikation)
    - Initialisiert AnalysisPipeline
    - Für jede Config-Kombination:
      - Erstellt RunConfiguration
      - Führt Pipeline aus (`debug_0 >> debug_6`)
      - Trackt Erfolg/Fehler
  - Fehlertoleranz: Ein fehlgeschlagener Run stoppt nicht die gesamte Batch
- 8. Batch-Zusammenfassung
  - Statistik: N erfolgreich, M fehlgeschlagen, K übersprungen
  - Details zu erfolgreichen Runs (Dauer, Schritte)
  - Details zu Fehlern (welcher Step, welche Fehlermeldung)
  - Details zu Skips (Grund)

## Appendix D: Versionsübersicht Experimentalsoftware

### Version 1

- JSON-Log (experiment\_sync\_log)
- Kalibrierungsdokumentation (calibration\_timing\_beg, \_mid, \_end)
- Skript: FVE\_Empira\_v51
  - Settings.Monitor.Distance: 680
  - Settings.CustomCalib.FixationDuration: 5.00
- Skript: CalibrationPresenterML
  - Margin\_x = ... \* 0.06
  - Margin\_y = ... \* 0.08

### Version 2

- Skript: FVE\_Empira\_v51
  - Settings.Monitor.Distance 700
- Skript: CalibrationPresenterML
  - Margin\_x = ... \* 0.18
  - Margin\_y = ... \* 0.20

### Version 3:

- Skript: FVE\_Empira\_v51
  - Settings.CustomCalib.FixationDuration 4.00

### Version 4

- Erweiterung des JSON-Log um zusätzliche Metadaten (z. B. Monitor.Distance oder FixationDuration)

## Appendix E: Transkript Instruktionen

Vor der Eyetracker-Kalibrierung:

Es folgt die Eyetracker-Kalibrierung. Verfolgen Sie bitte den Kreis mit ihren Augen und schauen dabei genau auf das Zentrum des Kreises. Bitte bewegen Sie Ihren Kopf dabei nicht, sondern nur Ihre Augen!

Vor der ersten, zweiten und dritten Videokalibrierung:

Es folgt die **erste/zweite/dritte** Videokalibrierung. Verfolgen Sie bitte das Fixationskreuz mit ihren Augen sowohl bei der Bewegung als auch beim Stillstand und schauen dabei immer genau auf den schwarzen Punkt in der Mitte des Kreises. Bitte bewegen Sie Ihren Kopf dabei nicht, sondern nur Ihre Augen!

Vor dem ersten und zweiten Teil der Bildpräsentation:

Es folgt der **erste/zweite** Teil der Bildpräsentation. Solange das Fixationskreuz zu sehen und die Töne und die Audio-Ansage zu hören ist, schauen Sie bitte wieder nur auf den schwarzen Punkt in der Mitte des Fixationskreuzes. Während die Bilder zu sehen sind, schauen Sie sie sich so an, wie sie auch sonst Bilder anschauen würden. Sie dürfen sie frei betrachten und erkunden. Die erste Abfolge von Fixation und Bild ist ein Beispieldurchgang. Bitte bewegen Sie Ihren Kopf dabei nicht, sondern nur Ihre Augen!